

Tipos de Estudios Estadísticos

Diseño, análisis e implementación con R



Alfredo Sánchez Alberca
asalber@ceu.es
<https://aprendeconalf.es>

Índice de contenidos

Prefacio	6
Licencia	6
1. Introducción a los tipos de estudios estadísticos	8
1.1. Elementos comunes a todo estudio estadístico	8
1.2. Criterios de clasificación	9
1.2.1. Según la intervención del investigador	9
1.2.2. Según la finalidad del estudio	9
1.2.3. Según la secuencia temporal	10
1.2.4. Según la direccionalidad	10
1.3. Mapa de los tipos de estudio	11
I. Diseños de estudio	12
2. Estudios descriptivos	13
2.1. Definición y características	13
2.2. Ventajas e inconvenientes	14
2.3. Medidas propias de este diseño	14
2.3.1. Razón	15
2.3.2. Proporción	15
2.3.3. Tasa	16
2.4. Realización con R	18
2.5. Cuándo utilizar este diseño	21
3. Estudios transversales	23
3.1. Definición y características	23
3.2. Ventajas e inconvenientes	24
3.3. Medidas propias de este diseño	24
3.3.1. Prevalencia	24
3.3.2. Razón de prevalencias	25
3.4. Realización con R	27
3.5. Cuándo utilizar este diseño	30
4. Estudios de cohortes	32
4.1. Definición y características	32
4.2. Ventajas e inconvenientes	33

4.3.	Medidas propias de este diseño	34
4.3.1.	Incidencia acumulada	34
4.3.2.	Riesgo relativo	34
4.3.3.	Riesgo atribuible	35
4.3.4.	Ejemplo numérico	36
4.4.	Realización con R	37
4.4.1.	Cálculo de las medidas a partir de la tabla de contingencia	37
4.4.2.	Análisis del tiempo hasta el evento con datos de seguimiento . . .	38
4.5.	Cuándo utilizar este diseño	40
5.	Estudios de casos y controles	41
5.1.	Definición y características	41
5.2.	Ventajas e inconvenientes	42
5.3.	Medidas propias de este diseño	42
5.4.	Realización con R	45
5.5.	Casos y controles apareados	47
5.6.	Cuándo utilizar este diseño	48
6.	Estudios ecológicos	49
6.1.	Definición y características	49
6.2.	Ventajas e inconvenientes	50
6.3.	Medidas propias de este diseño	51
6.4.	Realización con R	53
6.5.	Cuándo utilizar este diseño	56
7.	Estudios experimentales	58
7.1.	Definición y características	58
7.1.1.	Aleatorización	58
7.1.2.	Grupo control y placebo	59
7.1.3.	Cegamiento	59
7.2.	Ventajas e inconvenientes	60
7.3.	Medidas propias de este diseño	61
7.3.1.	Reducción relativa del riesgo	61
7.3.2.	Reducción absoluta del riesgo	62
7.3.3.	Número necesario a tratar	62
7.3.4.	Ejemplo numérico	63
7.4.	Realización con R	64
7.4.1.	Cálculo de las medidas a partir de la tabla de contingencia	64
7.4.2.	Cálculo del tamaño muestral	66
7.5.	Cuándo utilizar este diseño	68
8.	Estudios cuasiexperimentales	69
8.1.	Definición y características	69
8.1.1.	Diseño de un solo grupo antes-después	69

8.1.2.	Diseño con grupo de control no equivalente	70
8.1.3.	Series temporales interrumpidas	70
8.2.	Ventajas e inconvenientes	70
8.3.	Medidas propias de este diseño	71
8.4.	Realización con R	72
8.4.1.	Cálculo de la diferencia en diferencias	72
8.4.2.	Diseño de un solo grupo antes-después	74
8.5.	Cuándo utilizar este diseño	76
9.	Encuestas y diseño de muestreo	77
9.1.	Definición y características	77
9.1.1.	Muestreo aleatorio simple (MAS)	78
9.1.2.	Muestreo estratificado	78
9.1.3.	Muestreo por conglomerados	78
9.1.4.	Muestreo sistemático	79
9.2.	Ventajas e inconvenientes	79
9.3.	Medidas propias de este diseño	80
9.3.1.	Error de muestreo	80
9.3.2.	Tamaño muestral necesario	81
9.4.	Realización con R	82
9.4.1.	Cálculo del tamaño muestral necesario	82
9.4.2.	Comparación entre muestreo aleatorio simple y muestreo estratificado	84
9.5.	Cuándo utilizar este diseño	88
II.	Selección del contraste estadístico	89
10.	Selección del contraste estadístico	90
10.1.	Tabla de decisión	90
10.2.	El conjunto de datos de ejemplo	93
10.3.	Estructura de los capítulos	95
11.	Contrastes para una población	96
11.1.	Una variable cuantitativa	96
11.1.1.	Estadísticos descriptivos	96
11.1.2.	Gráficos	97
11.1.3.	Contraste de normalidad de Shapiro-Wilk	99
11.1.4.	Test t para la media de una población	100
11.2.	Una variable cualitativa	101
11.2.1.	Estadísticos descriptivos	101
11.2.2.	Gráficos	102
11.2.3.	Test binomial para una proporción	103
11.2.4.	Test Z para una proporción	104

12. Contrastes para dos poblaciones independientes	106
12.1. Variable dependiente cuantitativa	106
12.1.1. Estadísticos descriptivos por grupo	106
12.1.2. Representación gráfica	107
12.1.3. Comprobación de la normalidad	109
12.1.4. Test F de Fisher de comparación de varianzas	110
12.1.5. Test t de comparación de medias de poblaciones independientes	111
12.1.6. Test U de Mann-Whitney	112
12.2. Variable dependiente cualitativa	113
12.2.1. Test Chi-cuadrado de independencia	114
12.2.2. Test exacto de Fisher	115
12.3. Resumen	116
13. Contrastes para dos poblaciones pareadas	117
13.1. Variable dependiente cuantitativa: comparar <code>notaA</code> con <code>notaB</code>	117
13.1.1. Test t para datos pareados	121
13.1.2. Test de Wilcoxon para datos pareados	123
13.2. Variable dependiente cualitativa: comparar <code>calificacionA</code> con <code>calificacionB</code>	124
13.2.1. Test de McNemar	124
13.3. Para saber más	126
14. Contrastes para más de dos poblaciones independientes	127
14.1. Estadísticos descriptivos por grupo	127
14.1.1. Test de Levene de comparación de varianzas	130
14.1.2. ANOVA de un factor	131
14.1.3. Test de Kruskal-Wallis (no paramétrico)	134
14.2. Variable dependiente cualitativa	136
14.3. Cierre	136
15. Contrastes para más de dos poblaciones relacionadas (medidas repetidas)	137
15.1. Preparación de los datos: de formato ancho a formato largo	137
15.2. Comparación de las medidas repetidas	141
15.2.1. ANOVA de medidas repetidas de un factor	141
15.2.2. Test de Friedman	144
15.3. Resumen	146
16. Relación y predicción entre dos variables	147
16.1. Relación entre dos variables cuantitativas	147
16.2. Regresión simple	148
16.3. Regresión logística simple	149
16.4. Cierre de esta parte del libro	150

Prefacio

¡Bienvenida/os al libro de Tipos de Estudios Estadísticos!

Este libro presenta los principales tipos de estudios estadísticos que se emplean en la investigación científica, especialmente en ciencias de la salud, ciencias sociales y ciencias experimentales, con un enfoque práctico centrado en su diseño, sus medidas características y su implementación con R.

Cada capítulo está dedicado a un tipo de estudio y sigue una misma estructura: definición y características del diseño, ventajas e inconvenientes frente a otros diseños, las medidas estadísticas propias de ese tipo de estudio, y ejemplos completos resueltos con R.

Este libro se complementa con los siguientes recursos:

- [Manual de Estadística](#), donde se explican los fundamentos de estadística descriptiva, probabilidad e inferencia utilizados a lo largo de este libro.
- [Colección de problemas resueltos](#)
- [Prácticas de Estadística con R](#)

Licencia

Esta obra está bajo una licencia Reconocimiento – No comercial – Compartir bajo la misma licencia 3.0 España de Creative Commons. Para ver una copia de esta licencia, visite <https://creativecommons.org/licenses/by-nc-sa/3.0/es/>.

Con esta licencia eres libre de:

- Copiar, distribuir y mostrar este trabajo.
- Realizar modificaciones de este trabajo.

Bajo las siguientes condiciones:

- **Reconocimiento** Debe reconocer los créditos de la obra de la manera especificada por el autor o el licenciador (pero no de una manera que sugiera que tiene su apoyo o apoyan el uso que hace de su obra).
- **No comercial** No puede utilizar esta obra para fines comerciales.

- **Compartir bajo la misma licencia** Si altera o transforma esta obra, o genera una obra derivada, sólo puede distribuir la obra generada bajo una licencia idéntica a ésta.

Al reutilizar o distribuir la obra, tiene que dejar bien claro los términos de la licencia de esta obra.

Estas condiciones pueden no aplicarse si se obtiene el permiso del titular de los derechos de autor.

Nada en esta licencia menoscaba o restringe los derechos morales del autor.

1. Introducción a los tipos de estudios estadísticos

Cualquier investigación que utilice datos para responder a una pregunta científica se apoya en un *estudio estadístico*: un plan que determina qué individuos se observan, qué variables se miden, si el investigador interviene sobre ellos, y en qué momento o momentos del tiempo se recogen los datos.

Definición 1.1 (Estudio estadístico). Un *estudio estadístico* es un proceso planificado de recogida, organización y análisis de datos sobre una población o muestra, con el fin de describir un fenómeno, buscar asociaciones entre variables o establecer relaciones de causalidad.

La elección del tipo de estudio no es un detalle metodológico secundario: condiciona qué conclusiones pueden extraerse de los datos, qué medidas estadísticas tienen sentido calcular, y qué amenazas a la validez de los resultados hay que vigilar (sesgos de selección, factores de confusión, pérdidas de seguimiento, etc.). Este libro dedica un capítulo a cada uno de los tipos de estudio más habituales, mostrando cómo diseñarlos, qué medidas les son propias y cómo analizarlos con R.

Para situar cada capítulo dentro de un mapa común, en este primer capítulo se presentan los criterios que se utilizan habitualmente para clasificar los estudios estadísticos.

1.1. Elementos comunes a todo estudio estadístico

Antes de clasificar los estudios conviene recordar algunos conceptos, desarrollados con detalle en el [Manual de Estadística](#), que se emplearán a lo largo de todo el libro:

- **Población**: conjunto de individuos sobre los que se quiere obtener conclusiones.
- **Muestra**: subconjunto de la población que realmente se observa.
- **Variable de exposición o factor de estudio**: característica cuyo efecto se quiere investigar (un tratamiento, un hábito, una exposición ambiental, etc.).
- **Variable de respuesta o resultado**: característica sobre la que se mide el efecto (una enfermedad, un evento, una puntuación, etc.).
- **Unidad de observación**: el elemento sobre el que se recogen los datos, que no siempre coincide con el individuo (puede ser un grupo, una región, un periodo de tiempo...).

1.2. Criterios de clasificación

1.2.1. Según la intervención del investigador

El criterio más importante distingue entre estudios en los que el investigador se limita a observar la realidad y estudios en los que el investigador manipula activamente alguna condición.

Definición 1.2 (Estudio observacional). Un *estudio observacional* es aquel en el que el investigador se limita a observar y medir las variables de interés tal y como se presentan de forma natural, sin intervenir en la asignación de los individuos a los grupos de exposición.

Definición 1.3 (Estudio experimental). Un *estudio experimental* es aquel en el que el investigador interviene activamente, asignando de forma controlada la exposición o el tratamiento a los individuos, habitualmente mediante aleatorización.

Los estudios observacionales permiten detectar asociaciones entre variables, pero por sí solos rara vez permiten establecer relaciones de causa-efecto, porque no se puede descartar que la asociación observada se deba a un **factor de confusión**: una tercera variable relacionada tanto con la exposición como con el resultado. Los estudios experimentales, al controlar la asignación de la exposición mediante aleatorización, están diseñados precisamente para eliminar esta amenaza y poder establecer causalidad.

Interpretación

Como regla general, la evidencia científica sobre relaciones causales es tanto más fuerte cuanto mayor es el grado de control que ejerce el investigador sobre la asignación de la exposición. Los [ensayos clínicos aleatorizados](#) se consideran el diseño de referencia (*gold standard*) para establecer causalidad, mientras que los estudios observacionales ocupan una posición más débil en esta jerarquía.

1.2.2. Según la finalidad del estudio

Definición 1.4 (Estudio descriptivo). Un *estudio descriptivo* tiene como objetivo describir la frecuencia o distribución de una o varias variables en una población, sin plantear hipótesis sobre relaciones causales entre ellas.

Definición 1.5 (Estudio analítico). Un *estudio analítico* tiene como objetivo poner a prueba una hipótesis sobre la asociación o relación causal entre una exposición y un resultado, comparando grupos de individuos.

Dentro de los estudios observacionales, los [estudios de cohortes](#), de [casos y controles](#) y [ecológicos](#) son analíticos, mientras que los [estudios descriptivos](#) propiamente dichos y los [estudios transversales](#) tienen, en su forma más simple, una finalidad principalmente descriptiva.

1.2.3. Según la secuencia temporal

Definición 1.6 (Estudio transversal). Un estudio es *transversal* (o de corte, del inglés *cross-sectional*) cuando la exposición y el resultado se miden en un único momento del tiempo, sobre los mismos individuos.

Definición 1.7 (Estudio longitudinal). Un estudio es *longitudinal* cuando los individuos se observan a lo largo de un periodo de tiempo, lo que permite establecer la secuencia temporal entre la exposición y el resultado.

Establecer con claridad qué ocurrió primero, la exposición o el resultado, es esencial para poder hablar de causalidad, ya que la causa debe preceder siempre al efecto. Esta es una de las principales limitaciones de los estudios transversales.

1.2.4. Según la direccionalidad

Entre los estudios longitudinales, es habitual distinguir además según la dirección en la que se recorre el tiempo respecto al momento en que se inicia la investigación:

Definición 1.8 (Estudio prospectivo). Un estudio es *prospectivo* cuando se parte de la exposición, en el presente, y se sigue a los individuos hacia el futuro para observar la aparición del resultado.

Definición 1.9 (Estudio retrospectivo). Un estudio es *retrospectivo* cuando se parte del resultado, ya ocurrido, y se indaga hacia atrás en el tiempo en busca de la exposición.

! Importante

Los términos *prospectivo/retrospectivo* (dirección temporal de la recogida de información) y *cohorte/casos y controles* (forma de seleccionar la muestra) no son sinónimos, aunque a menudo se solapan: lo habitual es que un estudio de cohortes sea prospectivo y un estudio de casos y controles sea retrospectivo, pero existen diseños de [cohortes retrospectivas](#) que combinan ambos aspectos.

1.3. Mapa de los tipos de estudio

La siguiente tabla resume los tipos de estudio que se desarrollan en los capítulos siguientes, clasificados según los criterios anteriores.

Tipo de estudio	Intervención	Finalidad	Secuencia temporal
Estudio descriptivo	Observacional	Descriptiva	Variable
Estudio transversal	Observacional	Descriptiva / analítica	Transversal
Estudio de cohortes	Observacional	Analítica	Longitudinal
Estudio de casos y controles	Observacional	Analítica	Longitudinal (retrospectivo)
Estudio ecológico	Observacional	Analítica	Variable
Estudio experimental / ensayo clínico	Experimental	Analítica	Longitudinal (prospectivo)
Estudio cuasiexperimental	Experimental (sin aleatorización)	Analítica	Longitudinal
Encuesta y muestreo	Observacional	Descriptiva / analítica	Transversal (habitualmente)

A mayor control del diseño, mayor fuerza de la evidencia



Figura 1.1.: Jerarquía habitual de la evidencia científica según el tipo de estudio.

Cada uno de los capítulos siguientes sigue la misma estructura: definición y características del diseño, ventajas e inconvenientes, medidas estadísticas propias del tipo de estudio, y un ejemplo completo resuelto con R.

Parte I.

Diseños de estudio

2. Estudios descriptivos

Como se vio en el [capítulo de introducción](#), la finalidad de un estudio puede ser puramente descriptiva o analítica. El estudio descriptivo es el diseño observacional más elemental de todos: no compara grupos, no contrasta hipótesis y no pretende establecer relaciones causales. Su único objetivo es cuantificar y describir con precisión cómo se distribuye un fenómeno (una enfermedad, un hábito, una característica cualquiera) en una población o en un conjunto de individuos, sirviendo habitualmente como primer paso de una investigación más amplia.

2.1. Definición y características

Definición 2.1 (Estudio descriptivo). Un *estudio descriptivo* es un estudio observacional cuyo único objetivo es cuantificar la frecuencia, la distribución o las características de un fenómeno en una población o en un grupo de individuos, sin comparar grupos de exposición ni plantear hipótesis sobre relaciones causa-efecto.

En la práctica, los estudios descriptivos adoptan habitualmente alguna de estas formas:

- **Reporte de caso** (*case report*): descripción detallada de un único individuo con una característica, enfermedad o evolución clínica de interés, generalmente por su rareza o por presentar rasgos inesperados.
- **Serie de casos** (*case series*): descripción de un conjunto de individuos, todos ellos con una misma característica (por ejemplo, todos los pacientes diagnosticados de una enfermedad en un hospital durante un periodo determinado), sin comparación con ningún grupo que no la presente.
- **Estudio descriptivo de frecuencia poblacional**: cuantificación de la presencia de un fenómeno en toda una población o en una muestra representativa de ella, mediante medidas como proporciones o tasas, habitualmente desagregadas por variables como el tiempo, el lugar o las características de las personas (la tríada clásica *tiempo-lugar-persona* de la vigilancia epidemiológica).

Lo que caracteriza a los tres es la ausencia de un **grupo de comparación**: no existen individuos “no expuestos” o “sin la característica” frente a los que contrastar los resultados. Por ello, un estudio descriptivo puede informar, por ejemplo, de que el 8 % de una muestra de pacientes ingresados presenta una determinada complicación, pero **no puede** establecer si esa frecuencia es alta o baja en comparación con otro grupo, ni identificar qué factores

la explican, ni mucho menos afirmar que exista una relación de causalidad. Para eso son necesarios los diseños analíticos que se desarrollan en los capítulos siguientes.

2.2. Ventajas e inconvenientes

Ventajas

- Son rápidos, sencillos y económicos de llevar a cabo en comparación con cualquier diseño analítico o experimental.
- No requieren un grupo de comparación ni una hipótesis previa, por lo que son ideales para explorar fenómenos sobre los que apenas existe información.
- Son la herramienta natural para generar nuevas hipótesis que después se pondrán a prueba con diseños analíticos.
- Constituyen la base de los sistemas de vigilancia epidemiológica, al permitir detectar cambios en la frecuencia de una enfermedad a lo largo del tiempo.
- Son, con frecuencia, el único diseño posible cuando el fenómeno de estudio es muy poco frecuente (enfermedades raras) o cuando se trata de fenómenos nuevos de los que apenas hay casos documentados.

Inconvenientes

- No permiten establecer asociaciones entre variables, al carecer de grupo de comparación.
- No permiten en ningún caso establecer relaciones de causalidad.
- Los reportes y series de casos suelen basarse en muestras pequeñas y no representativas (a menudo pacientes de un único centro), lo que limita mucho la generalización de los resultados.
- Son especialmente vulnerables al sesgo de selección, ya que los casos que llegan a describirse suelen ser los más llamativos o los que acuden a centros concretos.
- No permiten controlar factores de confusión, al no compararse ningún grupo.

2.3. Medidas propias de este diseño

Los estudios descriptivos se apoyan en tres medidas de frecuencia muy sencillas, pero que conviene definir con precisión porque son los ladrillos con los que se construyen prácticamente todas las medidas de los diseños analíticos que se estudiarán en los capítulos siguientes (riesgos, *odds*, incidencias, etc.).

2.3.1. Razón

Definición 2.2 (Razón). Una *razón* (*ratio*) es el cociente entre dos cantidades de naturaleza distinta, no necesariamente relacionadas como parte y todo, es decir, el numerador no está necesariamente incluido en el denominador.

$$R = \frac{a}{b}$$

donde a y b son los tamaños de dos grupos o cantidades diferentes.

! Importante

Como a y b pueden ser cantidades de cualquier magnitud y no existe una relación de inclusión entre ellas, se tiene que

$$R \geq 0,$$

sin que exista, en general, ninguna cota superior.

i Interpretación

- Una razón se interpreta como el número de veces que la cantidad del numerador contiene, o representa, a la cantidad del denominador.
- Por ejemplo, la *razón de masculinidad* de una población es el cociente entre el número de hombres y el número de mujeres. Una razón de masculinidad de 0.9 indica que hay 0.9 hombres por cada mujer.

2.3.2. Proporción

Definición 2.3 (Proporción). Una *proporción* es el cociente entre el número de individuos que presentan una determinada característica y el número total de individuos del grupo, de modo que el numerador está incluido en el denominador.

$$P = \frac{a}{a+b} = \frac{a}{n}$$

donde a es el número de individuos con la característica de interés y $n = a + b$ es el tamaño total del grupo.

! Importante

Al estar el numerador incluido en el denominador, toda proporción cumple

$$0 \leq P \leq 1,$$

y puede expresarse también como porcentaje multiplicándola por 100.

i Interpretación

- Si $P = 0$ ningún individuo del grupo presenta la característica.
- Si $P = 1$ todos los individuos del grupo presentan la característica.
- Cuanto más próxima esté P a 1, mayor es la frecuencia relativa de la característica en el grupo.

2.3.3. Tasa

Definición 2.4 (Tasa). Una *tasa* (*rate*) es una proporción que incorpora explícitamente el tiempo en su denominador, expresado habitualmente en unidades de **persona-tiempo** (personas-año, personas-mes, etc.), es decir, la suma de los periodos de tiempo que cada individuo permanece en riesgo de que ocurra el fenómeno de interés.

$$T = \frac{\text{número de eventos nuevos}}{\text{personas-tiempo en riesgo}} \cdot k$$

donde k es una constante (10, 100, 1,000, 100,000...) que se elige para expresar la tasa con cifras manejables.

! Importante

Como el numerador no está incluido en el denominador (que tiene unidades de tiempo y no de individuos), una tasa

$$T \geq 0$$

no está acotada superiormente y, a diferencia de la proporción, **no es adimensional**: sus unidades son “eventos por persona-tiempo”.

i Interpretación

- La tasa mide la *velocidad* con la que ocurren nuevos eventos en una población, teniendo en cuenta el tiempo real que cada individuo ha estado expuesto al

riesgo.

- Dos poblaciones pueden tener el mismo número absoluto de eventos y, sin embargo, tasas muy distintas si el tiempo de seguimiento o el tamaño de la población en riesgo difieren.
- La proporción es adecuada cuando todos los individuos se observan durante el mismo periodo de tiempo; cuando el tiempo de seguimiento varía de un individuo a otro (por incorporaciones tardías, pérdidas de seguimiento o fallecimientos por otras causas), la tasa es la medida correcta porque cada individuo aporta solo el tiempo que realmente estuvo en riesgo.

Ejemplo 2.1. Se sigue durante el año 2026 a 8 personas sanas para observar la aparición de una determinada enfermedad. No todas permanecen en riesgo el año completo: algunas la desarrollan antes de que termine el seguimiento (y dejan de estar en riesgo) y otra abandona el estudio antes de tiempo (pérdida de seguimiento).

Individuo	Meses en riesgo	¿Caso nuevo?	Motivo de fin de seguimiento
Individuo 1	12	No	Fin del estudio
Individuo 2	12	No	Fin del estudio
Individuo 3	5	Sí	Aparición de la enfermedad
Individuo 4	12	No	Fin del estudio
Individuo 5	8	Sí	Aparición de la enfermedad
Individuo 6	12	No	Fin del estudio
Individuo 7	3	No	Pérdida de seguimiento
Individuo 8	12	No	Fin del estudio

El total de meses-persona observados es $12 + 12 + 5 + 12 + 8 + 12 + 3 + 12 = 76$ meses-persona, lo que equivale a $76/12 = 6.33$ personas-año. El número de casos nuevos es 2 (individuos 3 y 5). La tasa de incidencia es, por tanto,

$$T = \frac{2}{6.33} \cdot 1\,000 = 315.9 \text{ casos por cada } 1\,000 \text{ personas-año.}$$

Nótese que el individuo 7, aunque solo se observó durante 3 meses, contribuye igualmente al denominador con esos 3 meses-persona, y que ni él ni los individuos que desarrollan la enfermedad aportan tiempo en riesgo más allá del momento en que dejan de estarlo. (Se trata de un ejemplo con un tamaño muestral reducido con fines exclusivamente ilustrativos; en la práctica las tasas se calculan sobre poblaciones de miles o millones de personas-año).

2.4. Realización con R

Supongamos que un servicio de urgencias hospitalario registra, durante un mes, todos los casos atendidos de una determinada enfermedad infecciosa, anotando la edad, el sexo y la gravedad del cuadro clínico. Se trata de una serie de casos: no hay ningún grupo de comparación, solo se describe la frecuencia con la que se presenta cada característica dentro de la serie.

```
casos <- tibble(
  id = 1:28,
  edad = c(4, 67, 45, 2, 78, 34, 56, 81, 29, 5,
           72, 41, 19, 63, 8, 55, 39, 74, 47, 3,
           68, 52, 27, 9, 61, 33, 76, 48),
  sexo = c("Mujer", "Hombre", "Mujer", "Mujer", "Hombre", "Hombre", "Mujer", "Mujer",
           "Hombre", "Mujer", "Hombre", "Mujer", "Hombre", "Mujer", "Hombre", "Hombre",
           "Mujer", "Mujer", "Hombre", "Mujer", "Mujer", "Hombre", "Mujer", "Hombre",
           "Hombre", "Mujer", "Mujer", "Hombre"),
  gravedad = c("Leve", "Grave", "Moderada", "Leve", "Grave", "Moderada", "Leve", "Grave",
              "Leve", "Leve", "Moderada", "Leve", "Leve", "Moderada", "Leve", "Moderada",
              "Leve", "Grave", "Moderada", "Leve", "Grave", "Leve", "Leve", "Leve",
              "Moderada", "Leve", "Grave", "Moderada")
)

casos
```

```
# A tibble: 28 x 4
      id  edad sexo  gravedad
  <int> <dbl> <chr>   <chr>
1     1     4 Mujer    Leve
2     2    67 Hombre  Grave
3     3    45 Mujer   Moderada
4     4     2 Mujer    Leve
5     5    78 Hombre  Grave
6     6    34 Hombre  Moderada
7     7    56 Mujer    Leve
8     8    81 Mujer    Grave
9     9     29 Hombre  Leve
10    10     5 Mujer    Leve
# i 18 more rows
```

Con `dplyr` es inmediato calcular la proporción de casos que corresponde a cada categoría de gravedad, la primera medida descriptiva de interés:

```
proporciones_gravedad <- casos |>
  count(gravedad) |>
  mutate(proporcion = n / sum(n),
         porcentaje = round(100 * proporcion, 1))

proporciones_gravedad
```

```
# A tibble: 3 x 4
  gravedad      n proporcion porcentaje
  <chr>    <int>      <dbl>      <dbl>
1 Grave         6    0.214        21.4
2 Leve        14    0.5         50
3 Moderada      8    0.286        28.6
```

También puede describirse la razón entre sexos de la serie, y la proporción de casos graves dentro de cada grupo de edad, agrupando previamente la edad en tramos:

```
# Razón hombres / mujeres en la serie de casos
razon_sexo <- casos |>
  count(sexo) |>
  pivot_wider(names_from = sexo, values_from = n) |>
  mutate(razon_masculinidad = Hombre / Mujer)

razon_sexo
```

```
# A tibble: 1 x 3
  Hombre Mujer razon_masculinidad
  <int> <int>      <dbl>
1    13    15    0.867
```

```
# Proporción de casos graves por tramo de edad
casos_edad <- casos |>
  mutate(tramo_edad = case_when(
    edad < 15 ~ "0-14 años",
    edad < 65 ~ "15-64 años",
    TRUE ~ "65 o más años"
  )) |>
  group_by(tramo_edad) |>
  summarise(n = n(),
            graves = sum(gravedad == "Grave"),
            proporcion_graves = round(graves / n, 2))
```

```
casos_edad
```

```
# A tibble: 3 x 4
  tramo_edad      n graves proporcion_graves
  <chr>          <int> <int>          <dbl>
1 0-14 años         6     0            0
2 15-64 años       15     0            0
3 65 o más años     7      6           0.86
```

Si, además, se conociera cuántos días ha permanecido cada paciente ingresado (por ejemplo, porque los casos graves requieren hospitalización), podría calcularse una tasa de nuevos casos graves por cada 1000 días-paciente de estancia, lo que ilustra cómo la misma lógica de las tasas se aplica también dentro de un estudio descriptivo:

```
estancias <- casos |>
  filter(gravedad %in% c("Moderada", "Grave")) |>
  mutate(dias_estancia = c(6, 9, 4, 10, 5, 3, 8, 7, 6, 11, 4, 9, 7, 5))

tasa_complicacion <- estancias |>
  summarise(
    dias_persona = sum(dias_estancia),
    casos_graves = sum(gravedad == "Grave"),
    tasa_x1000 = round(1000 * casos_graves / dias_persona, 1)
  )

tasa_complicacion
```

```
# A tibble: 1 x 3
  dias_persona casos_graves tasa_x1000
  <dbl>          <int>          <dbl>
1      94             6          63.8
```

Por último, un diagrama de barras permite visualizar de un vistazo la distribución de la gravedad de los casos, la representación gráfica más habitual de una variable cualitativa en un estudio descriptivo:

```
ggplot(proporciones_gravedad, aes(x = fct_reorder(gravedad, proporcion, .desc = TRUE),
  y = proporcion)) +
  geom_col(fill = "steelblue") +
  geom_text(aes(label = paste0(porcentaje, "%")), vjust = -0.5) +
  scale_y_continuous(labels = scales::percent, limits = c(0, max(proporciones_gravedad$porcentaje)))
```

```
labs(x = "Gravedad del cuadro clínico", y = "Proporción de casos",
     title = "Gravedad de los casos atendidos en urgencias") +
theme_minimal()
```




Figura 2.1.: Distribución de la gravedad de los casos registrados en urgencias durante el mes.

Los resultados describen la serie de casos, pero no permiten ir más allá: puede afirmarse que algo más de la mitad de los casos de esta serie fueron leves y que la proporción de cuadros graves es mayor entre los mayores de 65 años, pero no puede concluirse que la edad *cause* una mayor gravedad, porque no se dispone de ningún grupo de comparación con el que contrastar esa diferencia ni se han controlado otros factores que pudieran explicarla.

2.5. Cuándo utilizar este diseño

Un estudio descriptivo es la elección adecuada cuando todavía se sabe poco sobre un fenómeno y el objetivo prioritario es simplemente cuantificarlo: en las primeras fases de un brote epidemiológico, en la vigilancia rutinaria de enfermedades, al documentar un caso clínico inusual, o al estudiar enfermedades tan raras que reunir un grupo de comparación resulta inviable. Su gran ventaja es la sencillez y la rapidez con la que aporta una primera fotografía del problema, que sirve para generar hipótesis sobre posibles factores asociados.

Sin embargo, en cuanto la pregunta de investigación pasa de “¿con qué frecuencia ocurre esto?” a “¿por qué ocurre?” o “¿qué lo explica?”, un diseño descriptivo deja de ser suficiente y es necesario recurrir a un diseño analítico, como el [estudio transversal](#) o el [estudio de cohortes](#), que sí incorporan un grupo de comparación frente al que contrastar los resultados.

3. Estudios transversales

Como se adelantó en el [capítulo de introducción](#), un estudio transversal es un tipo de estudio observacional en el que la exposición y el resultado se miden en un único momento del tiempo sobre los mismos individuos. A diferencia de los diseños longitudinales, que siguen a los sujetos a lo largo del tiempo, el estudio transversal puede entenderse como una “fotografía” de la población: se toma una muestra en un instante concreto y se registra simultáneamente el estado de todas las variables de interés.

3.1. Definición y características

Definición 3.1 (Estudio transversal). Un *estudio transversal* (también llamado *estudio de prevalencia* o, en inglés, *cross-sectional study*) es un estudio observacional en el que se selecciona una muestra de la población general, sin tener en cuenta ni la exposición ni el resultado de los individuos, y se miden todas las variables de interés en un único momento del tiempo.

La característica que define a este diseño es la forma de seleccionar la muestra: los individuos se eligen de la población general (por ejemplo, mediante un muestreo aleatorio), sin condicionar la selección al hecho de estar expuestos o no, ni al hecho de presentar o no el resultado de interés. Esto lo distingue tanto del [estudio de cohortes](#), que selecciona la muestra según la exposición, como del [estudio de casos y controles](#), que la selecciona según el resultado.

Un estudio transversal puede tener dos finalidades distintas, que a menudo se combinan en la práctica:

- **Uso descriptivo:** estimar la prevalencia de una enfermedad, una opinión, un hábito o cualquier otro fenómeno en la población, sin comparar grupos. Este es el uso más habitual y el que da nombre alternativo al diseño (estudio de prevalencia).
- **Uso analítico:** comparar la prevalencia del resultado entre distintos subgrupos definidos por una variable de exposición, con el fin de detectar posibles asociaciones. Sin embargo, como la exposición y el resultado se miden al mismo tiempo, no es posible establecer con certeza cuál precedió a cuál, por lo que las asociaciones observadas deben interpretarse con cautela.

3.2. Ventajas e inconvenientes

- **Rapidez y bajo coste:** al no requerir seguimiento de los individuos, los estudios transversales suelen ejecutarse en mucho menos tiempo y con muchos menos recursos que los diseños longitudinales.
- **Sencillez:** no es necesario localizar y mantener el contacto con los participantes durante un periodo prolongado, por lo que las pérdidas de seguimiento no son un problema.
- **Utilidad para la planificación sanitaria:** al estimar la prevalencia de un problema de salud, son la herramienta natural para dimensionar recursos y priorizar políticas públicas.
- **Imposibilidad de establecer causalidad:** al medirse la exposición y el resultado en el mismo momento, no se puede determinar la secuencia temporal entre ambas, lo que impide concluir que la exposición precede (y por tanto puede causar) al resultado.
- **Sesgo de prevalencia-incidencia (o sesgo de Neyman):** la muestra solo incluye a los individuos que en ese momento tienen la enfermedad, es decir, a los supervivientes o casos de duración suficiente para ser detectados en el corte transversal. Los casos que se curan rápidamente o que fallecen pronto tienden a quedar excluidos, sesgando las estimaciones.
- **Poco adecuado para enfermedades raras o de corta duración:** si la prevalencia es muy baja o el episodio es muy breve, la probabilidad de capturar casos en un único corte temporal es pequeña, por lo que se necesitarían muestras enormes para obtener estimaciones precisas.

3.3. Medidas propias de este diseño

3.3.1. Prevalencia

La medida más característica del estudio transversal es la prevalencia, que cuantifica qué proporción de la población presenta el resultado de interés en el momento del corte.

Definición 3.2 (Prevalencia). Dada una muestra de n individuos representativa de una población, de los cuales a presentan el resultado de interés (casos) en el momento del estudio, la *prevalencia* (puntual) se define como

$$P = \frac{a}{n}$$

Habitualmente se expresa como porcentaje (multiplicando por 100) o como número de casos por cada 1000, 10 000 o 100 000 habitantes, según la frecuencia del fenómeno estudiado.

! Importante

Como la prevalencia es una proporción, se cumple que

$$0 \leq P \leq 1,$$

siendo 0 cuando ningún individuo de la muestra presenta el resultado y 1 (o el 100 %) cuando todos lo presentan.

i Interpretación

- Cuanto más próxima esté P a 0, menos extendido está el fenómeno en la población.
- Cuanto más próxima esté P a 1, más extendido está el fenómeno en la población.
- La prevalencia depende tanto de la frecuencia con la que aparecen los casos nuevos (incidencia) como de la duración media del episodio: una enfermedad crónica de larga duración puede tener una prevalencia alta aunque su incidencia sea baja.

Ejemplo 3.1. En un estudio transversal se seleccionó una muestra aleatoria de $n = 500$ habitantes de una ciudad y se midió su presión arterial en una única visita. De ellos, $a = 45$ presentaban hipertensión arterial en el momento de la medición. La prevalencia puntual de hipertensión en esta muestra es

$$P = \frac{a}{n} = \frac{45}{500} = 0.09.$$

Es decir, la prevalencia estimada de hipertensión en esta población es del 9 %, o dicho de otra forma, de aproximadamente 90 casos por cada 1000 habitantes.

3.3.2. Razón de prevalencias

Cuando el estudio transversal se emplea con finalidad analítica, comparando la prevalencia del resultado entre expuestos y no expuestos, la medida de asociación habitual es la razón de prevalencias.

Definición 3.3 (Razón de prevalencias). Dada una tabla de contingencia que cruza una variable de exposición binaria con un resultado binario,

	Resultado	No resultado	Total
Expuestos	a	b	$a + b$
No expuestos	c	d	$c + d$

la *razón de prevalencias* (RP) se define como el cociente entre la prevalencia del resultado en el grupo de expuestos, $P_1 = \frac{a}{a+b}$, y la prevalencia del resultado en el grupo de no expuestos, $P_0 = \frac{c}{c+d}$,

$$RP = \frac{P_1}{P_0}.$$

! Importante

La razón de prevalencias es siempre un número no negativo,

$$RP \geq 0,$$

sin límite superior.

i Interpretación

- Si $RP = 1$, la prevalencia del resultado es igual en expuestos y no expuestos, por lo que no hay asociación (en el corte estudiado) entre la exposición y el resultado.
- Si $RP > 1$, la prevalencia del resultado es mayor entre los expuestos, lo que sugiere una asociación positiva entre exposición y resultado.
- Si $RP < 1$, la prevalencia del resultado es menor entre los expuestos, lo que sugiere que la exposición podría ser un factor protector.
- Al tratarse de un diseño transversal, esta asociación no permite concluir causalidad: no se puede descartar que sea el resultado el que influya sobre la exposición, o que ambos estén influidos por un tercer factor.

Ejemplo 3.2. En el mismo estudio transversal sobre 1000 personas, se registró además si cada individuo era fumador. La tabla de contingencia entre el hábito tabáquico y la presencia de bronquitis crónica en el momento de la encuesta fue la siguiente:

	Bronquitis	Sin bronquitis	Total
Fumadores	60	240	300
No fumadores	35	665	700

La prevalencia de bronquitis crónica en fumadores es $P_1 = \frac{60}{300} = 0.20$, y en no fumadores es $P_0 = \frac{35}{700} = 0.05$. La razón de prevalencias es por tanto

$$RP = \frac{P_1}{P_0} = \frac{0.20}{0.05} = 4.$$

Es decir, en el momento del corte, la prevalencia de bronquitis crónica entre los fumadores es 4 veces la de los no fumadores.

3.4. Realización con R

A continuación se simula un estudio transversal sobre $n = 180$ individuos, en el que se mide una variable de exposición binaria (exposición a un contaminante ambiental) y una variable de resultado binaria (presencia de una afección respiratoria), ambas registradas en el mismo momento del tiempo.

```
set.seed(123)
n <- 180

# Exposición: el 40% de la muestra está expuesta al contaminante
exposicion <- rbinom(n, size = 1, prob = 0.4)

# La probabilidad de presentar la afección depende de la exposición
p_afeccion <- ifelse(exposicion == 1, 0.30, 0.12)
resultado <- rbinom(n, size = 1, prob = p_afeccion)

datos <- tibble(
  id = 1:n,
  exposicion = factor(exposicion, levels = c(0, 1), labels = c("No expuesto", "Expuesto")),
  resultado = factor(resultado, levels = c(0, 1), labels = c("Sin afección", "Con afección"))
)

datos
```

```
# A tibble: 180 x 3
      id exposicion resultado
  <int> <fct>      <fct>
1     1 No expuesto Sin afección
2     2 Expuesto   Sin afección
3     3 No expuesto Sin afección
4     4 Expuesto   Sin afección
5     5 Expuesto   Sin afección
6     6 No expuesto Sin afección
7     7 No expuesto Sin afección
8     8 Expuesto   Sin afección
9     9 No expuesto Con afección
10    10 No expuesto Con afección
# i 170 more rows
```

En primer lugar se calcula la prevalencia global de la afección en toda la muestra:

```
prevalencia_global <- mean(datos$resultado == "Con afección")
prevalencia_global
```

```
[1] 0.1611111
```

A continuación se calcula la prevalencia por grupo de exposición, junto con el número de casos y el tamaño de cada grupo:

```
tabla_prevalencias <- datos |>
  group_by(exposicion) |>
  summarise(
    casos = sum(resultado == "Con afección"),
    n = n(),
    prevalencia = casos / n
  )
```

```
tabla_prevalencias
```

```
# A tibble: 2 x 4
  exposicion  casos     n prevalencia
  <fct>      <int> <int>      <dbl>
1 No expuesto    10   110     0.0909
2 Expuesto      19    70     0.271
```

Con estas dos prevalencias se obtiene la razón de prevalencias, comparando el grupo expuesto con el grupo no expuesto:

```
rp <- tabla_prevalencias$prevalencia[tabla_prevalencias$exposicion == "Expuesto"] /
  tabla_prevalencias$prevalencia[tabla_prevalencias$exposicion == "No expuesto"]
```

```
rp
```

```
[1] 2.985714
```

La prevalencia de la afección entre los expuestos al contaminante es, en esta muestra, aproximadamente 3 veces la de los no expuestos, lo que apunta a una posible asociación entre la exposición y el resultado (que, tratándose de un diseño transversal, no puede interpretarse como causal).

Por último, se calcula un intervalo de confianza al 95 % para la prevalencia de cada grupo mediante `prop.test()`, y se representan gráficamente las prevalencias con sus intervalos de confianza:

```
intervalos <- tabla_prevalencias |>
  rowwise() |>
  mutate(
    ic = list(broom::tidy(prop.test(casos, n)))
  ) |>
  unnest(ic) |>
  select(exposicion, casos, n, prevalencia, conf.low, conf.high)

intervalos
```

```
# A tibble: 2 x 6
  exposicion  casos      n prevalencia conf.low conf.high
  <fct>      <int> <int>      <dbl>    <dbl>    <dbl>
1 No expuesto    10   110      0.0909    0.0469    0.165
2 Expuesto       19    70      0.271     0.175     0.393
```

```
ggplot(intervalos, aes(x = exposicion, y = prevalencia, fill = exposicion)) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = conf.low, ymax = conf.high), width = 0.15) +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_brewer(palette = "Set2") +
  labs(
    x = "Grupo de exposición",
    y = "Prevalencia",
    title = "Prevalencia de la afección respiratoria según exposición"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 3.1.: Prevalencia de la afección respiratoria según la exposición al contaminante, con intervalos de confianza al 95 %.

El gráfico confirma que la prevalencia estimada en el grupo expuesto es notablemente superior a la del grupo no expuesto, y que los intervalos de confianza de ambos grupos no se solapan, lo que refuerza la idea de que la diferencia observada difícilmente se debe solo al azar. No obstante, al tratarse de un corte transversal, esta asociación debería confirmarse con un diseño longitudinal, como un [estudio de cohortes](#), antes de extraer conclusiones sobre causalidad.

3.5. Cuándo utilizar este diseño

El estudio transversal es la herramienta de elección cuando el objetivo principal es estimar la prevalencia de un fenómeno en un momento dado, por ejemplo para planificar recursos sanitarios o describir el estado de salud de una población. También resulta útil como paso previo, exploratorio y económico, para generar hipótesis sobre posibles asociaciones que después se pondrán a prueba con diseños más robustos. Sin embargo, cuando el objetivo es establecer la secuencia temporal entre una exposición y un resultado, o argumentar una posible relación de causalidad, el estudio transversal no es el diseño adecuado: conviene recurrir entonces a un [estudio de cohortes](#), que sigue a los individuos desde la exposición hacia el resultado, o a un [estudio de casos y controles](#), que parte del resultado para indagar retrospectivamente en la exposición. La elección entre estas alternativas dependerá de la

frecuencia del resultado, del tiempo y los recursos disponibles, y de si interesa priorizar la rapidez o la solidez causal de las conclusiones.

4. Estudios de cohortes

Un *estudio de cohortes* es un estudio observacional, analítico y longitudinal en el que se parte de un grupo de individuos expuestos a un determinado factor y de un grupo de individuos no expuestos a él, todos ellos libres de la enfermedad o el resultado de interés en el momento inicial, y se les sigue en el tiempo para comprobar quiénes desarrollan dicho resultado. A diferencia del estudio transversal, en el que exposición y resultado se observan en un único instante, en el estudio de cohortes la secuencia temporal entre exposición y resultado queda garantizada por diseño, lo que lo convierte en uno de los diseños observacionales con mayor capacidad para sugerir relaciones causales. Los conceptos generales de estudio observacional, analítico y longitudinal se presentaron en el [capítulo de introducción](#).

4.1. Definición y características

Definición 4.1 (Estudio de cohortes). Un *estudio de cohortes* es un estudio observacional en el que se identifican dos o más grupos (cohortes) de individuos libres del resultado de interés, definidos según su nivel de exposición a un factor de estudio, y se les sigue durante un periodo de tiempo para comparar la frecuencia con la que desarrollan dicho resultado.

La característica esencial de este diseño es que la formación de los grupos se realiza en función de la exposición, no del resultado: primero se clasifica a los individuos en expuestos y no expuestos, y después se observa la aparición de la enfermedad o evento de interés. Esto contrasta con el estudio de casos y controles, en el que ocurre justo lo contrario.

Según el momento en que se recogen los datos respecto al momento en que se realiza el análisis, se distinguen dos variantes:

Definición 4.2 (Cohorte prospectiva). Una *cohortes prospectiva* es aquella en la que la exposición se determina en el momento presente y el seguimiento de los individuos se realiza hacia adelante en el tiempo, recogiendo los datos del resultado a medida que van ocurriendo.

Definición 4.3 (Cohorte retrospectiva o histórica). Una *cohorte retrospectiva o histórica* es aquella en la que tanto la exposición como el seguimiento y la aparición del resultado ya han ocurrido en el pasado en el momento en que se inicia el estudio, de modo que el investigador reconstruye la historia de exposición y resultado a partir de registros u otras fuentes de información existentes.

i Interpretación

La diferencia entre una cohorte prospectiva y una retrospectiva no está en la lógica del diseño, que es idéntica en ambos casos (de la exposición hacia el resultado), sino en el momento en que se sitúa el investigador respecto al calendario de los hechos. En la cohorte prospectiva el investigador espera a que ocurran los eventos; en la retrospectiva, los eventos ya ocurrieron y se reconstruyen a partir de historiales clínicos, registros administrativos u otras fuentes documentales.

4.2. Ventajas e inconvenientes

El diseño de cohortes presenta una serie de ventajas frente a otros estudios observacionales:

- Permite calcular directamente la incidencia de la enfermedad, tanto en expuestos como en no expuestos, ya que se parte de individuos libres de la enfermedad y se observa su aparición a lo largo del tiempo.
- Es especialmente adecuado para el estudio de exposiciones poco frecuentes, ya que permite seleccionar deliberadamente un número suficiente de individuos expuestos.
- Al hacer un seguimiento de los individuos, permite estudiar simultáneamente varios resultados o enfermedades asociados a una misma exposición.
- Al respetar la secuencia temporal exposición-resultado, reduce algunos sesgos que afectan a los estudios transversales y facilita la interpretación causal.

Frente a estas ventajas, el diseño también presenta importantes inconvenientes:

- Suele requerir un coste económico y una duración elevados, sobre todo en su variante prospectiva, ya que hay que esperar a que se acumulen suficientes casos.
- Las pérdidas de seguimiento (individuos que abandonan el estudio antes de que finalice) pueden introducir sesgos si no son aleatorias respecto a la exposición o al resultado.
- No resulta eficiente para el estudio de enfermedades raras, pues sería necesario seguir a un número muy elevado de individuos para observar un número suficiente de casos.

4.3. Medidas propias de este diseño

El objetivo central de un estudio de cohortes es comparar la frecuencia con la que aparece el resultado de interés en el grupo de expuestos frente al grupo de no expuestos. Para ello se emplean tres medidas: la incidencia acumulada, el riesgo relativo y el riesgo atribuible.

4.3.1. Incidencia acumulada

Definición 4.4 (Incidencia acumulada). La *incidencia acumulada* o *riesgo* de un grupo es la proporción de individuos que, estando libres de la enfermedad al inicio del seguimiento, la desarrollan a lo largo de un periodo de tiempo fijo. Si a es el número de casos nuevos que aparecen en un grupo de n individuos seguidos durante dicho periodo, la incidencia acumulada se define como

$$IA = \frac{a}{n}$$

! Importante

Al ser una proporción, la incidencia acumulada cumple

$$0 \leq IA \leq 1,$$

y suele expresarse también en tanto por ciento o por cada 1000, 10000, etc. individuos, según la frecuencia del resultado.

4.3.2. Riesgo relativo

Definición 4.5 (Riesgo relativo). El *riesgo relativo* (RR) es el cociente entre la incidencia acumulada en el grupo de expuestos (IA_E) y la incidencia acumulada en el grupo de no expuestos ($IA_{\bar{E}}$):

$$RR = \frac{IA_E}{IA_{\bar{E}}}$$

! Importante

El riesgo relativo es un cociente de dos proporciones, por lo que

$$RR \geq 0.$$

Interpretación

- Si $RR = 1$, la incidencia es igual en expuestos y no expuestos, por lo que no existe asociación entre la exposición y el resultado.
- Si $RR > 1$, la incidencia es mayor en expuestos, por lo que la exposición se comporta como un *factor de riesgo*. Un $RR = 3$ indica que el riesgo de desarrollar el resultado es tres veces mayor en expuestos que en no expuestos.
- Si $RR < 1$, la incidencia es menor en expuestos, por lo que la exposición se comporta como un *factor protector*.

4.3.3. Riesgo atribuible

Definición 4.6 (Riesgo atribuible). El *riesgo atribuible* (RA) es la diferencia entre la incidencia acumulada en el grupo de expuestos y la incidencia acumulada en el grupo de no expuestos:

$$RA = IA_E - IA_{\bar{E}}$$

El riesgo atribuible mide, en términos absolutos, el exceso de incidencia del resultado que puede achacarse a la exposición. Cuando además se calcula la proporción que ese exceso representa sobre la incidencia total de los expuestos, se obtiene la *fracción atribuible en expuestos*,

$$FAE = \frac{RA}{IA_E} = \frac{IA_E - IA_{\bar{E}}}{IA_E},$$

que indica qué proporción de los casos que ocurren entre los expuestos se podrían evitar eliminando la exposición.

Interpretación

Mientras que el riesgo relativo informa sobre la fuerza de la asociación (en términos multiplicativos), el riesgo atribuible informa sobre el impacto en salud pública de la exposición: dos exposiciones pueden tener el mismo RR pero un RA muy distinto si las incidencias de base son muy diferentes.

4.3.4. Ejemplo numérico

Ejemplo 4.1. Se lleva a cabo un estudio de cohortes prospectivo para investigar la relación entre el hábito de fumar y la aparición de bronquitis crónica. Se reclutan 600 individuos libres de bronquitis crónica, de los cuales 200 son fumadores y 400 no fumadores, y se les sigue durante 10 años. Al finalizar el seguimiento se obtiene la siguiente tabla de frecuencias:

	Bronquitis	No bronquitis	Total
Fumadores	40	160	200
No fumadores	20	380	400

Incidencias acumuladas. La incidencia acumulada en fumadores es

$$IA_E = \frac{40}{200} = 0.2 = 20 \%,$$

y la incidencia acumulada en no fumadores es

$$IA_{\bar{E}} = \frac{20}{400} = 0.05 = 5 \%.$$

Riesgo relativo.

$$RR = \frac{IA_E}{IA_{\bar{E}}} = \frac{0.2}{0.05} = 4.$$

El riesgo de desarrollar bronquitis crónica en los fumadores es 4 veces el riesgo en los no fumadores, por lo que el tabaco se comporta como un claro factor de riesgo.

Riesgo atribuible.

$$RA = IA_E - IA_{\bar{E}} = 0.2 - 0.05 = 0.15 = 15 \%.$$

De cada 100 fumadores, 15 desarrollan bronquitis crónica como consecuencia directa de fumar (los otros 5 de los 20 casos por 100 se habrían producido igualmente por otras causas). La fracción atribuible en expuestos es

$$FAE = \frac{RA}{IA_E} = \frac{0.15}{0.2} = 0.75 = 75 \%,$$

es decir, el 75 % de los casos de bronquitis crónica que aparecen entre los fumadores podrían evitarse si dejaran de fumar.

4.4. Realización con R

4.4.1. Cálculo de las medidas a partir de la tabla de contingencia

El primer paso es reproducir con R el cálculo manual del ejemplo anterior, construyendo la tabla de contingencia como una matriz y calculando a partir de ella las incidencias acumuladas, el riesgo relativo y el riesgo atribuible.

```
# Tabla de contingencia: filas = exposición, columnas = resultado (bronquitis, no bronquitis)
tabla <- matrix(c(40, 160, 20, 380),
               nrow = 2, byrow = TRUE,
               dimnames = list(Exposicion = c("Fumadores", "No fumadores"),
                              Resultado = c("Bronquitis", "No bronquitis")))
tabla
```

	Resultado	
Exposicion	Bronquitis	No bronquitis
Fumadores	40	160
No fumadores	20	380

```
# Incidencias acumuladas
ia_expuestos <- tabla["Fumadores", "Bronquitis"] / sum(tabla["Fumadores", ])
ia_no_expuestos <- tabla["No fumadores", "Bronquitis"] / sum(tabla["No fumadores", ])
c(IA_expuestos = ia_expuestos, IA_no_expuestos = ia_no_expuestos)
```

IA_expuestos	IA_no_expuestos
0.20	0.05

```
# Riesgo relativo
rr <- ia_expuestos / ia_no_expuestos
rr
```

```
[1] 4
```

```
# Riesgo atribuible y fracción atribuible en expuestos
ra <- ia_expuestos - ia_no_expuestos
fae <- ra / ia_expuestos
c(RA = ra, FAE = fae)
```

RA	FAE
0.15	0.75

Los resultados, $IA_E = 0.2$, $IA_{\bar{E}} = 0.05$, $RR = 4$ y $RA = 0.15$, coinciden exactamente con los obtenidos a mano.

4.4.2. Análisis del tiempo hasta el evento con datos de seguimiento

En muchos estudios de cohortes no todos los individuos completan el mismo periodo de seguimiento: algunos abandonan el estudio antes de que termine y otros lo finalizan sin haber desarrollado el resultado. En ambos casos se dice que su tiempo de seguimiento está *censurado*. El análisis de supervivencia, implementado en el paquete `survival`, permite tener en cuenta esta censura al comparar la incidencia acumulada entre grupos.

En el siguiente ejemplo se simula una cohorte de 150 individuos, 75 expuestos y 75 no expuestos, con tiempos hasta el evento generados a partir de una distribución exponencial (los expuestos tienen, en promedio, un tiempo hasta el evento menor) y con un tiempo máximo de seguimiento de 10 años que censura a los individuos que no han presentado el evento antes de esa fecha.

```
set.seed(123)

n_grupo <- 75

cohorte <- tibble(
  id = 1:(2 * n_grupo),
  grupo = rep(c("Expuesto", "No expuesto"), each = n_grupo),
  # Tiempo hasta el evento: mayor tasa (menor tiempo medio) en expuestos
  tiempo_evento = c(rexp(n_grupo, rate = 0.15),
                    rexp(n_grupo, rate = 0.06)),
  tiempo_max = 10,
  tiempo = pmin(tiempo_evento, tiempo_max),
  evento = as.numeric(tiempo_evento <= tiempo_max)
)

cohorte %>%
  group_by(grupo) %>%
  summarise(n = n(),
            casos = sum(evento),
            incidencia_acumulada = mean(evento))
```

```
# A tibble: 2 x 4
  grupo      n casos incidencia_acumulada
  <chr>   <int> <dbl>          <dbl>
1 Expuesto    75    58          0.773
2 No expuesto  75    34          0.453
```

Con los tiempos y el indicador de evento se construye un objeto de supervivencia con `Surv()` y se ajusta una curva de Kaplan-Meier por grupo con `survfit()`:


```
ajuste <- survfit(Surv(tiempo, evento) ~ grupo, data = cohorte)
summary(ajuste)$table
```

	records	n.max	n.start	events	rmean	se(rmean)	median
grupo=Expuesto	75	75	75	58	5.631611	0.4008646	5.665241
grupo=No expuesto	75	75	75	34	7.518551	0.3681156	NA
	0.95LCL	0.95UCL					
grupo=Expuesto	3.924564	7.335592					
grupo=No expuesto	7.613148	NA					

Para representar gráficamente las curvas se extraen los datos del ajuste con `broom::tidy()`, que devuelve un data frame con la probabilidad de supervivencia estimada en cada instante y grupo, y se dibuja con `ggplot2`. La incidencia acumulada de cada grupo es el complementario de la probabilidad de supervivencia ($1 - S(t)$):

```
ajuste_df <- broom::tidy(ajuste) %>%
  mutate(grupo = str_remove(strata, "grupo="),
         incidencia_acumulada = 1 - estimate)

ggplot(ajuste_df, aes(x = tiempo, y = incidencia_acumulada, color = grupo)) +
  geom_step(linewidth = 1) +
  labs(x = "Tiempo de seguimiento (años)",
       y = "Incidencia acumulada estimada",
       color = "Grupo",
       title = "Incidencia acumulada de bronquitis crónica según exposición") +
  scale_y_continuous(labels = scales::percent) +
  theme_minimal()
```



Las curvas muestran cómo la incidencia acumulada crece más deprisa y alcanza un nivel más alto en el grupo de expuestos que en el de no expuestos a lo largo de todo el periodo de seguimiento, lo que es coherente con un factor de riesgo. A diferencia del cálculo directo de incidencias con una tabla de contingencia, este enfoque aprovecha toda la información disponible de cada individuo, incluida la de quienes son censurados antes de que finalice el seguimiento, en lugar de descartarlos o tratarlos como si no hubieran desarrollado el resultado.

4.5. Cuándo utilizar este diseño

El estudio de cohortes es la opción preferible cuando se dispone de tiempo y recursos suficientes, la exposición de interés es poco frecuente, o se quiere estudiar el efecto de una exposición sobre varios resultados a la vez, ya que permite calcular directamente incidencias, riesgos relativos y riesgos atribuibles. Cuando el resultado de interés es una enfermedad rara, con periodos de latencia muy largos o cuando se necesita una respuesta rápida y con un coste reducido, resulta más eficiente recurrir a un [estudio de casos y controles](#), que parte del resultado en lugar de la exposición. Y cuando ni siquiera se necesita establecer una secuencia temporal entre exposición y resultado, sino simplemente describir su asociación en un momento dado, puede bastar con un [estudio transversal](#), mucho más rápido y barato de ejecutar aunque no permita calcular incidencias ni establecer con claridad la dirección de la relación.

5. Estudios de casos y controles

El estudio de casos y controles es un diseño observacional y analítico que, a diferencia del [estudio de cohortes](#), recorre el tiempo en sentido inverso: en lugar de partir de la exposición y esperar a que aparezca el resultado, se parte del resultado, ya ocurrido, y se indaga hacia atrás en busca de la exposición pasada. Por este motivo se trata, casi siempre, de un diseño retrospectivo (véase el [capítulo de introducción](#) para la distinción entre los criterios de clasificación de los estudios). Se seleccionan dos grupos de individuos definidos por su estado respecto al resultado (los *casos*, que presentan la enfermedad o el evento de interés, y los *controles*, que no lo presentan) y se compara la frecuencia con la que unos y otros estuvieron expuestos en el pasado al factor de estudio.

5.1. Definición y características

Definición 5.1 (Estudio de casos y controles). Un *estudio de casos y controles* es un estudio observacional, analítico y habitualmente retrospectivo en el que se seleccionan dos grupos de individuos según la presencia (*casos*) o ausencia (*controles*) del resultado de interés, y se compara retrospectivamente la proporción de expuestos al factor de estudio en cada uno de los dos grupos.

El diseño se articula en torno a dos decisiones críticas, de las que depende en buena medida la validez del estudio:

- **Selección de los casos.** Deben definirse con criterios diagnósticos claros y explícitos, de forma que no haya ambigüedad sobre quién es o no un caso. Es preferible utilizar casos *incidentes* (de nueva aparición) frente a casos *prevalentes* (ya existentes en el momento del estudio), porque estos últimos pueden reflejar factores asociados a la supervivencia con la enfermedad más que a su aparición.
- **Selección de los controles.** Deben proceder de la misma población de la que surgen los casos (la llamada *población base* o *population at risk*), de modo que, si hubieran desarrollado la enfermedad, habrían sido incluidos como casos. Un control mal elegido —que no sea representativo de esa población base— es la fuente de sesgo más frecuente y más difícil de corregir en este tipo de estudios.

Una consecuencia importante de este diseño es que **no permite calcular directamente ni la incidencia ni la prevalencia** de la enfermedad. El motivo es que el número de casos y de controles no surge de muestrear aleatoriamente la población y observar cuántos

enferman, sino que lo fija de antemano el propio investigador (por ejemplo, todos los casos disponibles en un hospital durante un periodo, junto con el doble de controles). Al no respetarse la proporción real de enfermos y sanos en la población, cualquier medida que dependa de esa proporción —como el riesgo relativo o la incidencia acumulada— queda distorsionada. Como se verá más adelante, esta limitación es precisamente la que obliga a recurrir a la *odds ratio* como medida de asociación propia de este diseño.

5.2. Ventajas e inconvenientes

Ventajas:

- Son estudios rápidos y baratos de realizar, ya que no requieren seguimiento de los individuos en el tiempo.
- Son especialmente adecuados para el estudio de enfermedades raras, porque parten de un número fijo de casos ya identificados en lugar de esperar a que aparezcan en una cohorte.
- Resultan también apropiados cuando el periodo de latencia entre la exposición y la enfermedad es muy largo, ya que evitan años de seguimiento.
- Permiten estudiar simultáneamente varias exposiciones o factores de riesgo distintos para un mismo resultado.

Inconvenientes:

- Son susceptibles al **sesgo de memoria** (*recall bias*): los casos, al haber sufrido la enfermedad, tienden a recordar y declarar con más detalle exposiciones pasadas que los controles.
- Son susceptibles al **sesgo de selección de controles**, si estos no son verdaderamente representativos de la población base de la que proceden los casos.
- No permiten calcular directamente la incidencia ni la prevalencia de la enfermedad, como se ha explicado.
- La secuencia temporal entre exposición y resultado, al reconstruirse retrospectivamente, puede ser difícil de establecer con certeza en algunos casos.

5.3. Medidas propias de este diseño

Como la incidencia no puede calcularse en este diseño, no es posible obtener el riesgo relativo tal y como se define en un [estudio de cohortes](#). La medida de asociación propia de los estudios de casos y controles es la *razón de momios* u *Odds Ratio* (OR), que compara la *odds* (el momio) de haber estado expuesto entre los casos con la de haber estado expuesto entre los controles.

Partiendo de una tabla de contingencia 2×2 que cruza la exposición con la condición de caso o control,

	Casos	Controles	Total
Expuestos	a	b	$a + b$
No expuestos	c	d	$c + d$
Total	$a + c$	$b + d$	n

Definición 5.2 (Odds ratio). La *odds* (o momio) de exposición entre los casos es el cociente entre el número de casos expuestos y el número de casos no expuestos,

$$\text{Odds}_{\text{casos}} = \frac{a}{c},$$

y la odds de exposición entre los controles es el cociente entre el número de controles expuestos y el número de controles no expuestos,

$$\text{Odds}_{\text{controles}} = \frac{b}{d}.$$

La *Odds Ratio* (OR) se define como el cociente entre ambas odds,

$$OR = \frac{\text{Odds}_{\text{casos}}}{\text{Odds}_{\text{controles}}} = \frac{a/c}{b/d} = \frac{a \cdot d}{b \cdot c}.$$

! Importante

Al ser un cociente de dos cantidades positivas, la odds ratio verifica

$$OR > 0,$$

y $OR = 1$ indica ausencia de asociación entre la exposición y el resultado, ya que en ese caso la odds de exposición es idéntica en casos y en controles.

i Interpretación

- Si $OR = 1$, la exposición no está asociada con la enfermedad.
- Si $OR > 1$, la exposición está asociada positivamente con la enfermedad: los expuestos tienen una odds mayor de ser casos, por lo que la exposición se comporta como un **factor de riesgo**.
- Si $OR < 1$, la exposición está asociada negativamente con la enfermedad: los expuestos tienen una odds menor de ser casos, por lo que la exposición se comporta como un **factor protector**.

i Relación con el riesgo relativo

En un estudio de cohortes la medida natural de asociación es el riesgo relativo (RR), que compara directamente las incidencias (probabilidades) de enfermar entre expuestos y no expuestos. En un estudio de casos y controles no es posible calcular incidencias, por lo que el RR no puede obtenerse directamente. Sin embargo, cuando la enfermedad estudiada es **poco frecuente** en la población (el llamado *supuesto de enfermedad rara*, por ejemplo con una prevalencia inferior al 10 %), la probabilidad de enfermar es muy pequeña tanto en expuestos como en no expuestos, de modo que la odds de enfermar (probabilidad entre 1 menos probabilidad) se aproxima mucho a la propia probabilidad. En estas condiciones puede demostrarse que la odds ratio calculada en el estudio de casos y controles constituye una buena aproximación del riesgo relativo poblacional, $OR \approx RR$, lo que permite interpretarla de forma similar aunque los diseños sean muy distintos.

La incertidumbre muestral de la OR se cuantifica mediante su intervalo de confianza. Como la distribución de la OR es muy asimétrica, el intervalo se construye habitualmente sobre su logaritmo, que se aproxima mejor a una distribución normal.

Definición 5.3 (Intervalo de confianza de la odds ratio (método de Woolf)). El error estándar del logaritmo de la odds ratio se estima como

$$SE(\ln OR) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}},$$

y el intervalo de confianza al $(1 - \alpha) \cdot 100\%$ para la OR, conocido como método de Woolf, se obtiene deshaciendo el logaritmo tras construir el intervalo en escala logarítmica,

$$IC_{(1-\alpha) \cdot 100\%} = \exp \left(\ln(OR) \pm z_{1-\alpha/2} \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}} \right).$$

Para un nivel de confianza del 95 %, $z_{0.975} = 1.96$.

Ejemplo 5.1. Se quiere estudiar la asociación entre el consumo habitual de tabaco y la aparición de cáncer de pulmón mediante un estudio de casos y controles. Se seleccionan 100 casos (pacientes recién diagnosticados de cáncer de pulmón) y 200 controles (pacientes sin cáncer de pulmón, similares en edad y sexo), y se les pregunta retrospectivamente si han sido fumadores habituales. Los resultados se resumen en la siguiente tabla:

	Casos	Controles	Total
Fumadores	70	80	150
No fumadores	30	120	150
Total	100	200	300

Con $a = 70$, $b = 80$, $c = 30$ y $d = 120$, la odds ratio es

$$OR = \frac{a \cdot d}{b \cdot c} = \frac{70 \cdot 120}{80 \cdot 30} = \frac{8400}{2400} = 3.5.$$

Es decir, la odds de haber fumado es 3.5 veces mayor entre los casos (pacientes con cáncer de pulmón) que entre los controles, lo que sugiere que el tabaco se comporta como un factor de riesgo para esta enfermedad. Como se trata de una enfermedad poco frecuente en la población general, esta OR puede interpretarse aproximadamente como el riesgo relativo.

Para calcular el intervalo de confianza al 95 %, se obtiene primero el error estándar del logaritmo de la OR,

$$SE(\ln OR) = \sqrt{\frac{1}{70} + \frac{1}{80} + \frac{1}{30} + \frac{1}{120}} = \sqrt{0.0143 + 0.0125 + 0.0333 + 0.0083} = \sqrt{0.0684} = 0.2615,$$

y como $\ln(3.5) = 1.2528$, el intervalo en escala logarítmica es

$$1.2528 \pm 1.96 \cdot 0.2615 = 1.2528 \pm 0.5125 = (0.7403, 1.7653),$$

que, deshaciendo el logaritmo, da el intervalo de confianza para la OR

$$IC_{95\%} = (e^{0.7403}, e^{1.7653}) = (2.10, 5.84).$$

Como el intervalo no contiene el valor 1, la asociación entre tabaco y cáncer de pulmón es estadísticamente significativa al 95 % de confianza.

5.4. Realización con R

El siguiente código reproduce en R el ejemplo anterior, calculando la OR y su intervalo de confianza al 95 % a partir de la tabla 2×2 para comprobar que coincide con el cálculo manual.

```
# Tabla 2x2: filas = expuestos/no expuestos, columnas = casos/controles
tabla <- matrix(c(70, 80, 30, 120),
               nrow = 2, byrow = TRUE,
               dimnames = list(
                 Exposicion = c("Fumador", "No fumador"),
                 Grupo = c("Casos", "Controles")
               ))
tabla
```

Exposicion	Grupo	
	Casos	Controles
Fumador	70	80
No fumador	30	120

```

a <- tabla["Fumador", "Casos"]
b <- tabla["Fumador", "Controles"]
c_ <- tabla["No fumador", "Casos"]
d <- tabla["No fumador", "Controles"]

# Odds ratio
or <- (a * d) / (b * c_)

# Error estándar del logaritmo de la OR (método de Woolf)
se_log_or <- sqrt(1 / a + 1 / b + 1 / c_ + 1 / d)

# Intervalo de confianza al 95%
z <- qnorm(0.975)
ic_inferior <- exp(log(or) - z * se_log_or)
ic_superior <- exp(log(or) + z * se_log_or)

resultado <- tibble(
  medida = "Odds Ratio",
  estimacion = or,
  ic_95_inferior = ic_inferior,
  ic_95_superior = ic_superior
)
resultado

```

```

# A tibble: 1 x 4
  medida      estimacion ic_95_inferior ic_95_superior
  <chr>         <dbl>         <dbl>         <dbl>
1 Odds Ratio      3.5           2.10          5.84

```

El resultado coincide con el obtenido a mano: $OR = 3.5$ con un intervalo de confianza al 95 % de (2.10, 5.84).

Una forma habitual de representar gráficamente una odds ratio junto con su intervalo de confianza es el llamado *forest plot*, que muestra la estimación puntual y su incertidumbre en relación con la línea de referencia $OR = 1$ (ausencia de asociación).

```
ggplot(resultado, aes(x = or, y = medida)) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "grey40") +
  geom_errorbarh(aes(xmin = ic_95_inferior, xmax = ic_95_superior), height = 0.1) +
  geom_point(size = 3, color = "steelblue") +
  scale_x_log10() +
  labs(
    x = "Odds Ratio (escala logarítmica)",
    y = NULL,
    title = "Tabaco y cáncer de pulmón"
  ) +
  theme_minimal()
```




Figura 5.1.: Odds ratio del consumo de tabaco y su intervalo de confianza al 95 %.

El punto se sitúa claramente a la derecha de la línea de referencia $OR = 1$, y todo el intervalo de confianza queda también por encima de ella, lo que confirma gráficamente que el consumo de tabaco está asociado de forma significativa con un mayor riesgo de cáncer de pulmón en esta muestra.

5.5. Casos y controles apareados

En ocasiones, cada caso se *aparea* (*matching*) con uno o varios controles que comparten con él ciertas características que se sabe o se sospecha que actúan como factores de

confusión, como la edad, el sexo o el centro de reclutamiento. El objetivo del apareamiento es asegurar que casos y controles sean lo más comparables posible en esas variables, de forma que cualquier diferencia observada en la exposición sea más difícilmente atribuible a ellas. Por ejemplo, a cada caso de 55 años se le podrían asignar dos controles también de 55 años y del mismo sexo.

El apareamiento tiene, sin embargo, un coste analítico: la tabla 2×2 simple ya no resulta válida para comparar los grupos, porque las observaciones dejan de ser independientes (cada caso está ligado a su control o controles concretos). El análisis de datos apareados requiere métodos estadísticos específicos, como el **test de McNemar** para el caso de un control por caso, o la regresión logística condicional cuando hay varios controles por caso, que quedan fuera del alcance de este capítulo introductorio.

5.6. Cuándo utilizar este diseño

El estudio de casos y controles es la opción de elección cuando la enfermedad o el evento de interés es raro, cuando su periodo de latencia es muy largo, o cuando se dispone de poco tiempo y presupuesto para completar la investigación. También resulta muy útil como paso exploratorio para generar hipótesis sobre múltiples posibles exposiciones a la vez, antes de invertir en un diseño más costoso. Cuando, por el contrario, es la **exposición** la que resulta rara en la población (y no la enfermedad), suele ser preferible recurrir a un [estudio de cohortes](#), que garantiza un número suficiente de expuestos y permite además calcular directamente incidencias y riesgos relativos. En la práctica, ambos diseños se consideran complementarios dentro de la investigación epidemiológica observacional.

6. Estudios ecológicos

Todos los diseños vistos hasta ahora en este libro comparten un rasgo común: la unidad de observación es el individuo. Sin embargo, no siempre se dispone de datos a nivel individual, ni siempre interesa estudiarlos: en ocasiones lo único disponible, o lo único relevante, son datos agregados sobre grupos enteros de personas. El estudio ecológico es el diseño observacional y analítico en el que la unidad de análisis no es el individuo, sino un grupo o agregado de individuos (un país, una región, un colegio, un periodo de tiempo), y en el que se relacionan tasas o promedios agregados de exposición con tasas o promedios agregados de resultado. Como se anticipó en el [capítulo de introducción](#), este diseño ocupa una posición particular entre los estudios analíticos, ya que permite generar hipótesis con gran rapidez pero exige una cautela especial a la hora de interpretar sus resultados.

6.1. Definición y características

Definición 6.1 (Estudio ecológico). Un *estudio ecológico* es un estudio observacional y analítico en el que la unidad de análisis es un grupo o agregado de individuos, denominado *unidad ecológica*, y en el que se estudia la relación entre una medida agregada de exposición (una tasa, una proporción o una media) y una medida agregada de resultado, calculadas ambas para cada unidad ecológica.

Lo que distingue a un estudio ecológico de todos los demás diseños de este libro no es el tipo de medida que se calcula, sino la naturaleza de la unidad de observación. En un estudio de cohortes o de casos y controles, cada fila de la base de datos corresponde a una persona; en un estudio ecológico, cada fila corresponde a un grupo, del que solo se conocen valores resumidos (por ejemplo, el porcentaje de fumadores o la tasa de mortalidad), y se ignora la combinación exacta de exposición y resultado que presenta cada individuo del grupo.

Una **unidad ecológica** puede definirse de muy diversas formas, dependiendo de la disponibilidad de datos agregados y de la pregunta de investigación. Algunos ejemplos habituales son:

- **Áreas geográficas:** países, comunidades autónomas, provincias o municipios, para los que existen estadísticas oficiales agregadas (renta media, tasas de mortalidad, cobertura vacunal, etc.).

- **Instituciones:** colegios, hospitales o empresas, comparados a partir de indicadores agregados de sus miembros (por ejemplo, el gasto medio por alumno y la tasa de graduación de cada colegio).
- **Cohortes de nacimiento o periodos de tiempo:** grupos de personas nacidas en un mismo año, o datos agregados por años calendario, para estudiar tendencias temporales conjuntas de una exposición y un resultado.

6.2. Ventajas e inconvenientes

Ventajas

- Es, con diferencia, uno de los diseños más rápidos y baratos de llevar a cabo, ya que habitualmente no requiere recoger datos nuevos.
- Aprovecha datos agregados ya disponibles, como estadísticas oficiales, registros administrativos o indicadores publicados por organismos públicos, sin necesidad de reclutar y seguir a individuos.
- Es muy útil para generar hipótesis de forma exploratoria, que después podrán confirmarse (o no) con diseños a nivel individual.
- Permite estudiar exposiciones que solo tienen sentido a nivel de grupo, como políticas públicas, normativas, campañas o características del entorno, que no varían entre los individuos de una misma unidad ecológica.
- Permite detectar **efectos contextuales**, es decir, efectos del grupo sobre el individuo que no pueden observarse estudiando únicamente características individuales (por ejemplo, el efecto de vivir en una región con mayor desigualdad de renta, con independencia de la renta propia de cada individuo).

Inconvenientes

- Al no disponer de datos individuales, no se puede saber si, dentro de cada unidad ecológica, son realmente los individuos expuestos los que presentan el resultado, o si exposición y resultado se distribuyen entre personas distintas del mismo grupo.
- La falta de información individual impide controlar adecuadamente los factores de confusión a nivel de persona, que solo pueden ajustarse (si acaso) de forma agregada.
- Los grupos comparados pueden diferir en muchas otras características además de la exposición estudiada, lo que dificulta atribuir la asociación observada a esa exposición concreta.
- Su limitación más importante, hasta el punto de merecer un nombre propio, es la posibilidad de incurrir en una **falacia ecológica**, que se desarrolla con detalle en el apartado siguiente.

6.3. Medidas propias de este diseño

La medida de asociación característica del estudio ecológico es el coeficiente de correlación aplicado, no a datos individuales, sino a las tasas o medias agregadas de las n unidades ecológicas comparadas.

Definición 6.2 (Coeficiente de correlación ecológica). Dadas n unidades ecológicas, para cada una de las cuales se dispone de una medida agregada de exposición x_i (una tasa, proporción o media) y una medida agregada de resultado y_i , el *coeficiente de correlación ecológica* es el coeficiente de correlación de Pearson calculado sobre esos n pares de valores agregados,

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde $\bar{x}$ y $\bar{y}$ son las medias de las medidas agregadas de exposición y de resultado, respectivamente, en las n unidades ecológicas.

! Importante

Al ser un coeficiente de correlación de Pearson, el coeficiente de correlación ecológica siempre verifica

$$-1 \leq r \leq 1.$$

i Interpretación

- El signo de r indica el sentido de la relación entre las unidades ecológicas: si $r > 0$, las unidades con mayor exposición agregada tienden a presentar también mayor resultado agregado; si $r < 0$, ocurre lo contrario.
- Cuanto más se aproxima $|r|$ a 1, más fuerte es la relación lineal observada entre las medidas agregadas.
- Si r es próximo a 0, no se observa relación lineal entre la exposición y el resultado a nivel de las unidades ecológicas.
- Es fundamental recordar que r mide una asociación **entre grupos**, no entre individuos, tal y como se explica a continuación.

La principal amenaza a la validez de las conclusiones de un estudio ecológico es la posibilidad de trasladar indebidamente una asociación observada entre grupos a una afirmación sobre los individuos que los componen.

Definición 6.3 (Falacia ecológica). La *falacia ecológica* consiste en inferir, a partir de una asociación observada entre la exposición y el resultado agregados a nivel de grupo, que existe esa misma asociación entre la exposición y el resultado a nivel individual, sin disponer de datos individuales que lo confirmen.

 Advertencia

Una correlación ecológica alta **no implica** que, dentro de cada unidad ecológica, sean precisamente los individuos expuestos los que presenten el resultado. La asociación agregada puede deberse, total o parcialmente, a diferencias entre grupos que nada tienen que ver con la relación individual entre exposición y resultado, e incluso puede tener signo contrario al de la verdadera asociación individual.

Un ejemplo clásico ilustra el problema: si se calcula, para cada comunidad autónoma, el porcentaje de población nacida en el extranjero y la tasa media de alfabetización, es posible encontrar una correlación ecológica positiva (las comunidades con mayor proporción de población extranjera presentan, en promedio, tasas de alfabetización más altas), simplemente porque la población extranjera tiende a concentrarse en las regiones más urbanas y con mejores sistemas educativos. Concluir de ahí que, a nivel individual, las personas nacidas en el extranjero tienen mayor probabilidad de saber leer y escribir que las nacidas en España sería un error: los datos agregados no informan sobre qué personas concretas, dentro de cada comunidad, son las que están alfabetizadas, y la relación individual podría ser incluso la contraria.

Ejemplo 6.1. Se dispone de datos agregados de 7 países sobre el consumo medio de alcohol per cápita (x , en litros de alcohol puro al año) y la tasa de mortalidad por cirrosis hepática (y , casos por cada 100 000 habitantes):

País	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
País 1	2	5	-6	-10	60	36	100
País 2	4	8	-4	-7	28	16	49
País 3	6	11	-2	-4	8	4	16
País 4	8	15	0	0	0	0	0
País 5	10	18	2	3	6	4	9
País 6	12	20	4	5	20	16	25
País 7	14	28	6	13	78	36	169
Total	56	105			200	112	368

Las medias agregadas son $\bar{x} = 56/7 = 8$ litros y $\bar{y} = 105/7 = 15$ casos por cada 100 000 habitantes. Con las sumas de la tabla, el coeficiente de correlación ecológica resulta

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2} \sqrt{\sum(y_i - \bar{y})^2}} = \frac{200}{\sqrt{112} \sqrt{368}} = \frac{200}{203.02} \approx 0.985.$$

Existe, por tanto, una correlación ecológica positiva y muy fuerte entre el consumo medio de alcohol y la mortalidad por cirrosis a nivel de país: los países con mayor consumo agregado tienden a presentar también una mayor tasa agregada de mortalidad por esta causa. Esta asociación es coherente con lo que se sabe a nivel clínico sobre el alcohol y la cirrosis, pero conviene insistir en que, por sí sola, esta correlación agregada de 7 países no demuestra que sean los individuos que más beben dentro de cada país los que fallecen por cirrosis: para eso haría falta un diseño con datos individuales, como un [estudio de cohortes](#).

6.4. Realización con R

A continuación se construye un conjunto de datos agregados por región, con el consumo medio diario de sal (x , en gramos por persona y día) y la tasa de hipertensión arterial (y , casos por cada 1000 habitantes) de 18 regiones ficticias, tal y como podrían obtenerse a partir de estadísticas sanitarias oficiales.

```
set.seed(123)

n_regiones <- 18

datos_ecologicos <- tibble(
  region = paste("Región", 1:n_regiones),
  consumo_sal = round(rnorm(n_regiones, mean = 8, sd = 1.8), 1)
) |>
  mutate(
    tasa_hipertension = round(15 + 6 * consumo_sal + rnorm(n_regiones, mean = 0, sd = 10), 1)
  )

datos_ecologicos
```

```
# A tibble: 18 x 3
  region      consumo_sal tasa_hipertension
  <chr>      <dbl>      <dbl>
1 Región 1         7         64
2 Región 2        7.6        55.9
3 Región 3       10.8        69.1
4 Región 4         8.1        61.4
5 Región 5         8.2        53.9
6 Región 6       11.1        74.3
7 Región 7         8.8        61.5
8 Región 8         5.7        32.3
9 Región 9         6.8        64.2
```

10 Región 10	7.2	59.7
11 Región 11	10.2	64.8
12 Región 12	8.6	79.1
13 Región 13	8.7	71.5
14 Región 14	8.2	61.2
15 Región 15	7	66
16 Región 16	11.2	91
17 Región 17	8.9	76.6
18 Región 18	4.5	48.9

Cada fila representa una región completa, no una persona: `consumo_sal` es el consumo medio agregado de esa región, y `tasa_hipertension` es la tasa agregada de hipertensión en esa misma región.

El coeficiente de correlación ecológica entre ambas variables agregadas se calcula con `cor()`, y su significación estadística con `cor.test()`:

```
correlacion <- cor(datos_ecologicos$consumo_sal, datos_ecologicos$tasa_hipertension)
correlacion
```

```
[1] 0.7283621
```

```
test_correlacion <- cor.test(datos_ecologicos$consumo_sal, datos_ecologicos$tasa_hipertension)
test_correlacion
```

```
Pearson's product-moment correlation
```

```
data: datos_ecologicos$consumo_sal and datos_ecologicos$tasa_hipertension
t = 4.252, df = 16, p-value = 0.0006086
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3962304 0.8919307
sample estimates:
      cor
0.7283621
```

El coeficiente de correlación ecológica es 0.73, lo que indica una asociación positiva y fuerte entre el consumo medio de sal y la tasa de hipertensión a nivel regional, y el contraste de hipótesis asociado sugiere que esta correlación es difícilmente atribuible al azar.

A continuación se ajusta una recta de regresión sobre los datos agregados con `lm()`:

```
modelo_ecologico <- lm(tasa_hipertension ~ consumo_sal, data = datos_ecologicos)
summary(modelo_ecologico)
```

Call:

```
lm(formula = tasa_hipertension ~ consumo_sal, data = datos_ecologicos)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-18.794	-5.341	-0.536	7.163	13.146

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	21.887	10.171	2.152	0.047028 *
consumo_sal	5.124	1.205	4.252	0.000609 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.98 on 16 degrees of freedom

Multiple R-squared: 0.5305, Adjusted R-squared: 0.5012

F-statistic: 18.08 on 1 and 16 DF, p-value: 0.0006086

Y se representa el diagrama de dispersión de las 18 regiones junto con la recta de regresión ajustada:

```
ggplot(datos_ecologicos, aes(x = consumo_sal, y = tasa_hipertension)) +
  geom_point(size = 3, color = "steelblue") +
  geom_smooth(method = "lm", se = TRUE, color = "firebrick") +
  labs(
    x = "Consumo medio de sal (g/día)",
    y = "Tasa de hipertensión (casos por 1000 hab.)",
    title = "Correlación ecológica entre consumo de sal e hipertensión"
  ) +
  theme_minimal()
```




Figura 6.1.: Relación ecológica entre el consumo medio de sal y la tasa de hipertensión en 18 regiones.

Cada punto del gráfico representa una región entera, no una persona. La nube de puntos y la recta ajustada muestran una relación positiva clara entre el consumo medio de sal y la tasa de hipertensión a nivel regional: las regiones que, en promedio, consumen más sal presentan también, en promedio, tasas de hipertensión más altas. Sin embargo, estos datos agregados no permiten afirmar que sean precisamente las personas que más sal consumen, dentro de cada región, las que desarrollan hipertensión: podría haber diferencias entre regiones (edad media de la población, acceso a la sanidad, otros hábitos dietéticos) que expliquen parte de esta asociación agregada, y la propia falacia ecológica advierte de que la relación a nivel individual debería confirmarse con un diseño que recoja datos de cada persona.

6.5. Cuándo utilizar este diseño

El estudio ecológico resulta especialmente útil como primera aproximación rápida y económica a una pregunta de investigación, cuando ya existen estadísticas agregadas disponibles y no es viable, al menos en una fase inicial, recoger datos a nivel individual. También es el diseño de elección, y en muchos casos el único posible, cuando la exposición que se quiere estudiar es en sí misma una característica de grupo (una política sanitaria, una normativa medioambiental, una campaña de salud pública) que no varía entre los individuos de una misma unidad ecológica y que, por tanto, no podría analizarse

comparando personas dentro de un mismo grupo. Sin embargo, precisamente por la amenaza de la falacia ecológica, cualquier asociación encontrada con este diseño debe tratarse como una hipótesis preliminar, no como una conclusión establecida. Cuando el objetivo final es determinar si la exposición y el resultado están realmente asociados a nivel de persona, es necesario confirmar los hallazgos ecológicos con un diseño que recoja datos individuales, como un [estudio de cohortes](#) o un [estudio de casos y controles](#), antes de trasladar las conclusiones a los individuos.

7. Estudios experimentales

A diferencia de los diseños observacionales estudiados en los capítulos anteriores, en los que el investigador se limita a observar lo que ocurre de forma natural, en un *estudio experimental* es el propio investigador quien decide, de forma activa, qué tratamiento o exposición recibe cada individuo. Esta capacidad de intervenir sobre la exposición, unida a la asignación aleatoria de los sujetos a los distintos grupos, convierte al estudio experimental en el diseño con mayor capacidad para establecer relaciones causales de todos los vistos hasta ahora. Dentro de los estudios experimentales, el *ensayo clínico aleatorizado* es, con diferencia, el más utilizado, especialmente en la evaluación de nuevos fármacos y tratamientos, y constituye el paradigma de este tipo de diseño. Los conceptos generales de estudio experimental frente a observacional se presentaron en el [capítulo de introducción](#).

7.1. Definición y características

Definición 7.1 (Ensayo clínico aleatorizado). Un *ensayo clínico aleatorizado* (ECA) es un estudio experimental, analítico y longitudinal en el que un grupo de individuos se asigna al azar a recibir un tratamiento (o exposición) experimental o un tratamiento de control, y se les sigue en el tiempo para comparar la frecuencia con la que se produce el resultado de interés en ambos grupos.

El ensayo clínico aleatorizado comparte con el estudio de cohortes la lógica general (se parte de la exposición y se observa el resultado a lo largo del tiempo), pero se diferencia de él en un aspecto esencial: mientras que en el estudio de cohortes la exposición la determinan los propios individuos o las circunstancias, en el ensayo clínico es el investigador quien la asigna, y además lo hace de forma aleatoria. Esta doble característica, intervención y aleatorización, es la que dota a este diseño de su extraordinaria capacidad para el control de los factores de confusión. Tres elementos son clave en su diseño: la aleatorización, la existencia de un grupo control (habitualmente con placebo) y el cegamiento.

7.1.1. Aleatorización

Definición 7.2 (Aleatorización). La *aleatorización* es el procedimiento por el cual la asignación de cada individuo al grupo experimental o al grupo control se realiza mediante un mecanismo puramente aleatorio (por ejemplo, un generador de números aleatorios),

de forma que todos los individuos tienen la misma probabilidad de recibir cada uno de los tratamientos.

! Importante

Si el proceso de asignación es realmente aleatorio y el tamaño muestral es suficientemente grande, la aleatorización tiende a repartir por igual entre los grupos tanto los factores de confusión conocidos por el investigador como los que no lo son (o los que ni siquiera se han llegado a identificar). Esto es algo que ningún diseño observacional puede garantizar, por muy cuidadoso que sea el ajuste estadístico posterior, ya que este solo puede corregir el efecto de las variables que se han medido.

i Interpretación

Gracias a la aleatorización, si al final del estudio se observa una diferencia en el resultado entre los dos grupos, esa diferencia puede atribuirse con mucha mayor confianza al tratamiento y no a otras características previas de los individuos, ya que estas se distribuyen de forma similar (en promedio) en ambos grupos.

7.1.2. Grupo control y placebo

En todo ensayo clínico es necesario disponer de un grupo de comparación, el *grupo control*, que permite valorar qué le hubiera ocurrido a los individuos del grupo experimental si no hubieran recibido el tratamiento en estudio. Sin este grupo de referencia sería imposible saber si la evolución observada en los pacientes tratados se debe al tratamiento o a otros factores, como la evolución natural de la enfermedad.

El grupo control puede recibir un *placebo* (una sustancia o procedimiento inactivo, sin efecto farmacológico, pero indistinguible del tratamiento experimental en apariencia) cuando no existe un tratamiento eficaz conocido para la enfermedad estudiada, o bien el *tratamiento estándar* ya disponible, cuando por motivos éticos no sería admisible dejar sin tratamiento a los pacientes del grupo control. En ambos casos el objetivo es el mismo: aislar el efecto específico del nuevo tratamiento del efecto inespecífico de recibir cualquier atención o intervención.

7.1.3. Cegamiento

Definición 7.3 (Cegamiento). El *cegamiento* (o enmascaramiento) es el procedimiento por el cual se oculta a los participantes, a los investigadores, o a ambos, qué tratamiento está recibiendo cada individuo, con el fin de evitar que ese conocimiento influya en el resultado del estudio.

Se distinguen varios niveles de cegamiento:

- En un ensayo *simple ciego*, el paciente desconoce si recibe el tratamiento experimental o el control, pero el investigador sí lo sabe.
- En un ensayo *doble ciego*, ni el paciente ni el investigador que evalúa el resultado conocen el tratamiento asignado.
- En un ensayo *abierto* no existe cegamiento: tanto el paciente como el investigador conocen el tratamiento asignado, algo inevitable en algunos diseños (por ejemplo, cuando se compara cirugía frente a tratamiento farmacológico).

i Interpretación

El cegamiento reduce el sesgo de información en ambas direcciones: evita que el conocimiento del tratamiento modifique la respuesta del paciente (por ejemplo, mediante el efecto placebo, o comunicando síntomas de forma distinta según lo que espera sentir) y evita que el investigador, de forma consciente o inconsciente, valore el resultado de forma diferente según el tratamiento que sabe que ha recibido cada paciente.

7.2. Ventajas e inconvenientes

El ensayo clínico aleatorizado presenta ventajas muy destacadas frente al resto de diseños estudiados hasta ahora:

- Proporciona la evidencia más sólida para establecer relaciones de causalidad entre una exposición o tratamiento y un resultado, por lo que se considera el patrón de referencia (*gold standard*) de la investigación clínica.
- La aleatorización controla simultáneamente los factores de confusión conocidos y los desconocidos, algo que ningún estudio observacional puede lograr.
- El investigador controla el momento y la forma en que se administra la exposición, lo que reduce muchos de los sesgos de selección e información habituales en los estudios observacionales.
- El cegamiento y el uso de un grupo control con placebo permiten aislar el efecto específico del tratamiento.

Frente a estas ventajas, el diseño presenta también inconvenientes importantes:

- Suele requerir un coste económico y una duración muy elevados, sobre todo cuando el resultado de interés tarda mucho tiempo en manifestarse o es poco frecuente.
- Plantea problemas éticos que limitan notablemente su aplicabilidad: no es aceptable asignar de forma aleatoria una exposición que se sospecha perjudicial, ni negar a un grupo de pacientes un tratamiento del que ya existe evidencia de eficacia.

- Los criterios de inclusión y exclusión, necesarios para garantizar la seguridad de los participantes y la homogeneidad de la muestra, suelen ser muy estrictos, lo que limita la validez externa (la capacidad de generalizar los resultados a la población general de pacientes, más heterogénea que la muestra del ensayo).

7.3. Medidas propias de este diseño

Al igual que en el estudio de cohortes, en un ensayo clínico se comparan las incidencias del resultado de interés en el grupo experimental y en el grupo control, a partir de una tabla de contingencia como la siguiente, donde a y c son el número de individuos en los que se produce el evento en el grupo experimental y en el grupo control, respectivamente, y n_e y n_c el número total de individuos en cada grupo:

	Evento	No evento	Total
Experimental	a	b	n_e
Control	c	d	n_c

A partir de esta tabla se define la incidencia del evento en el grupo experimental, $I_e = a/n_e$, y la incidencia del evento en el grupo control, $I_c = c/n_c$. Sobre estas dos incidencias se construyen tres medidas propias de este diseño, especialmente utilizadas cuando el resultado de interés es un evento adverso que el tratamiento pretende evitar: la reducción relativa del riesgo, la reducción absoluta del riesgo y el número necesario a tratar.

7.3.1. Reducción relativa del riesgo

Definición 7.4 (Reducción relativa del riesgo). La *reducción relativa del riesgo* (RRR) es la proporción en la que el tratamiento experimental reduce el riesgo del evento respecto al grupo control, y se define como

$$RRR = \frac{I_c - I_e}{I_c}$$

! Importante

Cuando el tratamiento experimental reduce el riesgo del evento respecto al control ($I_e < I_c$), se tiene que

$$0 < RRR \leq 1,$$

y suele expresarse en tanto por ciento.

Interpretación

Un $RRR = 0.3$ (30 %) indica que el tratamiento experimental reduce el riesgo de sufrir el evento en un 30 % respecto al riesgo del grupo control. La reducción relativa del riesgo es equivalente a $1 - RR$, donde $RR = I_e/I_c$ es el riesgo relativo definido en el estudio de cohortes, por lo que comparte con él la limitación de no informar sobre la magnitud absoluta del riesgo evitado.

7.3.2. Reducción absoluta del riesgo

Definición 7.5 (Reducción absoluta del riesgo). La *reducción absoluta del riesgo* (RAR) es la diferencia entre la incidencia del evento en el grupo control y la incidencia del evento en el grupo experimental, y se define como

$$RAR = I_c - I_e$$

Importante

Cuando el tratamiento experimental reduce el riesgo del evento respecto al control ($I_e < I_c$), se tiene que

$$0 < RAR \leq 1.$$

Interpretación

A diferencia de la reducción relativa, la reducción absoluta del riesgo depende directamente del riesgo basal del grupo control: dos tratamientos pueden tener la misma RRR y una RAR muy distinta si las incidencias de partida son muy diferentes, por lo que la RAR ofrece una idea más realista del beneficio esperado del tratamiento en la práctica.

7.3.3. Número necesario a tratar

Definición 7.6 (Número necesario a tratar). El *número necesario a tratar* (NNT) es el número de pacientes que sería necesario tratar con el tratamiento experimental, en lugar de con el control, para evitar un caso adicional del evento de interés, y se define como el inverso de la reducción absoluta del riesgo:

$$NNT = \frac{1}{RAR}$$

Interpretación

El NNT traduce la reducción absoluta del riesgo a una escala muy intuitiva para la práctica clínica: un $NNT = 10$ significa que, de media, hay que tratar a 10 pacientes con el nuevo tratamiento en lugar de con el control para evitar que uno de ellos sufra el evento. Cuanto menor es el NNT, mayor es la eficacia práctica del tratamiento.

Advertencia

El NNT se calcula siempre como el inverso de la RAR expresada en proporción (no en porcentaje) y, puesto que en la práctica no tiene sentido tratar a una fracción de paciente, el resultado se redondea siempre al entero superior (por ejemplo, un $NNT = 8.3$ se interpreta y se comunica como $NNT = 9$). Además, al depender de la RAR, el NNT no es una propiedad fija del tratamiento, sino que varía con el riesgo basal de la población a la que se aplique: el mismo tratamiento tendrá un NNT mucho más favorable en pacientes de alto riesgo que en pacientes de bajo riesgo, por lo que no debe extrapolarse sin más de una población a otra.

7.3.4. Ejemplo numérico

Ejemplo 7.1. Se lleva a cabo un ensayo clínico aleatorizado, doble ciego y controlado con placebo, para evaluar si un nuevo fármaco reduce la aparición de infarto de miocardio en pacientes con alto riesgo cardiovascular. Se reclutan 500 pacientes, que se asignan aleatoriamente a dos grupos de 250: uno recibe el fármaco experimental y otro recibe un placebo, y se les sigue durante 3 años. Al finalizar el seguimiento se obtiene la siguiente tabla de frecuencias:

	Infarto	No infarto	Total
Fármaco	25	225	250
Placebo	50	200	250

Incidencias. La incidencia de infarto en el grupo experimental es

$$I_e = \frac{25}{250} = 0.10 = 10 \%,$$

y la incidencia de infarto en el grupo control es

$$I_c = \frac{50}{250} = 0.20 = 20 \%.$$

Reducción relativa del riesgo.

$$RRR = \frac{I_c - I_e}{I_c} = \frac{0.20 - 0.10}{0.20} = 0.5 = 50\%.$$

El fármaco reduce el riesgo de sufrir un infarto en un 50 % respecto al riesgo de los pacientes que reciben placebo.

Reducción absoluta del riesgo.

$$RAR = I_c - I_e = 0.20 - 0.10 = 0.10 = 10\%.$$

De cada 100 pacientes tratados con el fármaco, se evitan 10 infartos que sí se habrían producido de haber recibido placebo.

Número necesario a tratar.

$$NNT = \frac{1}{RAR} = \frac{1}{0.10} = 10.$$

Es necesario tratar a 10 pacientes con el nuevo fármaco, en lugar de con placebo, durante 3 años, para evitar un infarto de miocardio adicional. Obsérvese que, a pesar de que la reducción relativa del riesgo parece muy elevada (50 %), el NNT permite valorar el beneficio del tratamiento en términos absolutos y directamente aplicables a la práctica clínica.

7.4. Realización con R

7.4.1. Cálculo de las medidas a partir de la tabla de contingencia

El primer paso es reproducir con R el cálculo manual del ejemplo anterior, construyendo la tabla de contingencia como una matriz y calculando a partir de ella las incidencias, la RRR, la RAR y el NNT.

```
# Tabla de contingencia: filas = grupo, columnas = resultado (infarto, no infarto)
tabla <- matrix(c(25, 225, 50, 200),
               nrow = 2, byrow = TRUE,
               dimnames = list(Grupo = c("Farmaco", "Placebo"),
                              Resultado = c("Infarto", "No infarto")))
tabla
```


Grupo	Resultado	
	Infarto	No infarto
Farmaco	25	225
Placebo	50	200

```
# Incidencias del evento en cada grupo
i_e <- tabla["Farmaco", "Infarto"] / sum(tabla["Farmaco", ])
i_c <- tabla["Placebo", "Infarto"] / sum(tabla["Placebo", ])
c(I_e = i_e, I_c = i_c)
```

```
I_e I_c
0.1 0.2
```

```
# Reducción relativa del riesgo, reducción absoluta del riesgo y NNT
rrr <- (i_c - i_e) / i_c
rar <- i_c - i_e
nnt <- 1 / rar
c(RRR = rrr, RAR = rar, NNT = ceiling(nnt))
```

```
RRR  RAR  NNT
0.5  0.1 10.0
```

Los resultados, $I_e = 0.10$, $I_c = 0.20$, $RRR = 0.5$, $RAR = 0.10$ y $NNT = 10$, coinciden exactamente con los obtenidos a mano.

Para representar gráficamente la diferencia entre grupos conviene acompañar las incidencias observadas de su intervalo de confianza, que puede obtenerse para cada grupo con `prop.test()`:


```
ic_farmaco <- prop.test(tabla["Farmaco", "Infarto"], sum(tabla["Farmaco", ]))
ic_placebo <- prop.test(tabla["Placebo", "Infarto"], sum(tabla["Placebo", ]))

incidencias <- tibble(
  grupo = c("Fármaco", "Placebo"),
  incidencia = c(ic_farmaco$estimate, ic_placebo$estimate),
  ic_inf = c(ic_farmaco$conf.int[1], ic_placebo$conf.int[1]),
  ic_sup = c(ic_farmaco$conf.int[2], ic_placebo$conf.int[2])
)
incidencias
```

```
# A tibble: 2 x 4
  grupo  incidencia ic_inf ic_sup
```

	<chr>	<dbl>	<dbl>	<dbl>
1	Fármaco	0.1	0.0670	0.146
2	Placebo	0.2	0.153	0.256

```
ggplot(incidencias, aes(x = grupo, y = incidencia, fill = grupo)) +
  geom_col(width = 0.6, show.legend = FALSE) +
  geom_errorbar(aes(ymin = ic_inf, ymax = ic_sup), width = 0.15) +
  scale_y_continuous(labels = scales::percent) +
  labs(x = "Grupo",
       y = "Incidencia de infarto de miocardio",
       title = "Incidencia de infarto según grupo de tratamiento",
       subtitle = "Barras de error: intervalo de confianza al 95%") +
  theme_minimal()
```



El gráfico muestra que la incidencia observada en el grupo tratado con el fármaco es claramente inferior a la del grupo placebo, aunque los intervalos de confianza recuerdan que ambas incidencias se han estimado a partir de una muestra y están sujetas a variabilidad muestral.

7.4.2. Cálculo del tamaño muestral

Antes de iniciar un ensayo clínico es necesario determinar cuántos pacientes por grupo se van a reclutar, de forma que el estudio tenga potencia suficiente para detectar la diferencia de incidencias que se considera clínicamente relevante, si esta existe realmente.

El paquete `pwr` permite realizar este cálculo para la comparación de dos proporciones con la función `pwr.2p.test()`, que requiere el tamaño del efecto de Cohen `h` (calculado a partir de las dos proporciones con `ES.h()`), el nivel de significación `sig.level` y la potencia deseada `power`.

Supóngase que, antes de realizar el ensayo del ejemplo anterior, se quiere diseñar un estudio capaz de detectar una reducción de la incidencia de infarto del 20 % (grupo control) al 10 % (grupo experimental), con una potencia del 80 % y un nivel de significación del 5 %:

```
tamano_efecto <- ES.h(p1 = 0.10, p2 = 0.20)
tamano_efecto
```

```
[1] -0.2837941
```

```
calcula_muestra <- pwr.2p.test(h = tamano_efecto, sig.level = 0.05, power = 0.8)
calcula_muestra
```

Difference of proportion power calculation for binomial distribution (arcsine trans

```
      h = 0.2837941
      n = 194.9081
sig.level = 0.05
power = 0.8
alternative = two.sided
```

NOTE: same sample sizes

```
n_por_grupo <- ceiling(calcula_muestra$n)
n_por_grupo
```

```
[1] 195
```

El resultado indica que serían necesarios aproximadamente 195 pacientes por grupo (es decir, un total de 390 pacientes) para tener una probabilidad del 80 % de detectar, con un nivel de significación del 5 %, una diferencia de incidencias como la observada en el ejemplo si esta existe realmente en la población. Con los 250 pacientes por grupo reclutados en el ejemplo anterior, el estudio contaba con potencia más que suficiente para detectar una diferencia de esa magnitud; en la práctica, este cálculo debe realizarse siempre antes de iniciar el reclutamiento, y no a posteriori, para justificar el tamaño de la muestra planificada.

7.5. Cuándo utilizar este diseño

El ensayo clínico aleatorizado es el diseño de elección siempre que sea factible desde el punto de vista ético y práctico llevarlo a cabo, ya que ofrece la evidencia más sólida para establecer que una exposición o tratamiento causa un determinado resultado. Resulta especialmente indicado en las fases de evaluación de nuevos fármacos, vacunas o intervenciones sanitarias, antes de su aprobación y uso generalizado. Sin embargo, cuando no es posible asignar aleatoriamente la exposición, bien porque sería contrario a la ética (por ejemplo, asignar el consumo de tabaco), bien por motivos prácticos, de coste o de tiempo, es necesario recurrir a un [estudio cuasiexperimental](#), que conserva la intervención activa del investigador pero renuncia a la aleatorización, o bien a alguno de los diseños observacionales estudiados en los capítulos anteriores.

8. Estudios cuasiexperimentales

Un **estudio cuasiexperimental** es un tipo de estudio en el que el investigador interviene, es decir, aplica un tratamiento, programa o intervención a los individuos, pero **sin asignar aleatoriamente** a los sujetos a los grupos de tratamiento y de control. Esta ausencia de aleatorización es la característica que lo distingue de los [estudios experimentales](#), tal y como se introdujo en el [capítulo de introducción](#).

Los estudios cuasiexperimentales surgen habitualmente cuando la aleatorización no es posible, no es ética o no es práctica. Es el caso, por ejemplo, de la evaluación de políticas públicas, programas educativos o intervenciones comunitarias, en los que no se puede asignar al azar qué municipios, colegios o pacientes reciben la intervención y cuáles no, ya sea por razones logísticas, legales o de justicia social.

8.1. Definición y características

En un estudio cuasiexperimental el investigador manipula deliberadamente una variable independiente (la intervención o tratamiento) y mide su efecto sobre una o varias variables dependientes, pero los grupos que reciben o no la intervención se forman por procedimientos distintos del azar: por ejemplo, porque ya existían previamente (dos colegios, dos regiones), porque los propios individuos se autoseleccionan, o porque la intervención se aplica a toda una comunidad sin grupo de comparación disponible.

Existen numerosas variantes de diseño cuasiexperimental, entre las que destacan las tres siguientes.

8.1.1. Diseño de un solo grupo antes-después

También llamado diseño *one-group pretest-posttest*, consiste en medir una variable de interés en un único grupo de individuos antes de aplicar la intervención y volver a medirla después. Es el diseño cuasiexperimental más sencillo, ya que no requiere ningún grupo de comparación, pero también el más débil desde el punto de vista de la validez interna, porque cualquier cambio observado entre el antes y el después podría deberse a la intervención, pero también a otros factores que hayan actuado simultáneamente sobre los individuos.

8.1.2. Diseño con grupo de control no equivalente

En este diseño se dispone de dos grupos, uno que recibe la intervención (grupo tratado) y otro que no la recibe (grupo de control o de comparación), y se mide la variable de interés en ambos antes y después de la intervención. La diferencia esencial respecto a un experimento es que los dos grupos no se han formado mediante asignación aleatoria, sino que ya existían como tales (dos aulas, dos hospitales, dos regiones), por lo que pueden diferir sistemáticamente en características que también influyan en el resultado. Es el diseño cuasiexperimental más utilizado en la práctica y el que permite construir el estimador de diferencia en diferencias que se presenta más adelante.

8.1.3. Series temporales interrumpidas

En este diseño se realizan múltiples mediciones de la variable de interés sobre la misma unidad de estudio (una población, una región, una organización) tanto antes como después de que se produzca la intervención, que actúa como una interrupción en la serie temporal. Por ejemplo, registrar la tasa de accidentes de tráfico mes a mes durante varios años antes y después de la entrada en vigor de una nueva ley de seguridad vial. La disponibilidad de varias medidas antes y después, en lugar de una sola, permite valorar si el cambio observado tras la intervención rompe con la tendencia previa o si es simplemente una continuación de una tendencia ya existente.

8.2. Ventajas e inconvenientes

Los estudios cuasiexperimentales presentan las siguientes ventajas:

- Son más factibles, tanto éticamente como en la práctica, que un ensayo controlado aleatorizado, ya que no requieren asignar al azar a los individuos a recibir o no una intervención.
- Permiten evaluar intervenciones a gran escala, como políticas públicas, leyes o programas comunitarios, que no podrían implementarse de forma aleatorizada.
- Suelen ser más baratos y rápidos de llevar a cabo que un experimento, al aprovechar grupos o mediciones ya existentes.

Y también los siguientes inconvenientes:

- Al no existir aleatorización, existe un mayor riesgo de **sesgo de selección**: los grupos comparados pueden diferir sistemáticamente en características relevantes, y no solo en si reciben o no la intervención.
- Es más difícil descartar la presencia de **factores de confusión** que expliquen, total o parcialmente, el cambio observado.

- Están expuestos a amenazas a la validez interna propias de los diseños con medidas repetidas, como la **regresión a la media** (los valores extremos tienden a acercarse a la media en mediciones sucesivas, con independencia de la intervención) o la **historia** (sucesos externos a la intervención, ocurridos entre el antes y el después, que también podrían explicar el cambio).

8.3. Medidas propias de este diseño

En el diseño con grupo de control no equivalente, la medida de efecto más habitual es el estimador de **diferencia en diferencias**.

Definición 8.1 (Diferencia en diferencias (DiD)). Dado un grupo tratado y un grupo de control no equivalente, en los que se mide una variable de interés antes y después de aplicar una intervención sobre el grupo tratado, siendo $\bar{Y}_{t,antes}$ y $\bar{Y}_{t,despues}$ las medias de la variable en el grupo tratado antes y después de la intervención, y $\bar{Y}_{c,antes}$ y $\bar{Y}_{c,despues}$ las medias correspondientes en el grupo de control, se define el estimador de diferencia en diferencias como

$$DiD = (\bar{Y}_{t,despues} - \bar{Y}_{t,antes}) - (\bar{Y}_{c,despues} - \bar{Y}_{c,antes})$$

Interpretación

El estimador DiD representa el efecto atribuible a la intervención una vez descontado el cambio que se habría producido de todos modos, sin necesidad de intervenir. El cambio observado en el grupo de control se utiliza como estimación de la **tendencia contrafactual**, es decir, de lo que habría ocurrido en el grupo tratado si no hubiera recibido la intervención. Restar ese cambio al cambio observado en el grupo tratado permite aislar el efecto propio de la intervención.

Advertencia

El estimador de diferencia en diferencias solo es válido bajo el **supuesto de tendencias paralelas**: en ausencia de la intervención, el grupo tratado y el grupo de control habrían evolucionado de forma paralela, es decir, con el mismo cambio medio entre el antes y el después. Si este supuesto no se cumple, la DiD puede sobrestimar o infraestimar el verdadero efecto de la intervención.

Ejemplo 8.1. Un ayuntamiento implanta un programa de refuerzo escolar en los colegios de su municipio (grupo tratado). Para valorar su efecto, se compara la calificación media de los alumnos en una prueba estandarizada con la de los colegios de un municipio vecino que no recibió el programa (grupo de control), antes y después de su implantación. No es

posible asignar aleatoriamente qué municipio recibe el programa, por lo que se trata de un diseño cuasiexperimental con grupo de control no equivalente.

Las calificaciones medias obtenidas son

Grupo	Antes	Después	Cambio
Tratado (con programa)	5.2	6.4	1.2
Control (sin programa)	5.3	5.6	0.3

El cambio en el grupo tratado es

$$\bar{Y}_{t,despues} - \bar{Y}_{t,antes} = 6.4 - 5.2 = 1.2,$$

y el cambio en el grupo de control, que estima la tendencia que habría seguido el grupo tratado sin el programa, es

$$\bar{Y}_{c,despues} - \bar{Y}_{c,antes} = 5.6 - 5.3 = 0.3.$$

Por tanto, el estimador de diferencia en diferencias es

$$DiD = 1.2 - 0.3 = 0.9.$$

Descontada la tendencia común a ambos municipios, el programa de refuerzo escolar habría producido un aumento medio de 0.9 puntos en la calificación de los alumnos.

8.4. Realización con R

8.4.1. Cálculo de la diferencia en diferencias

A continuación se reproduce en R el cálculo del ejemplo anterior a partir de las cuatro medias observadas.

```
y_t_antes <- 5.2
y_t_despues <- 6.4
y_c_antes <- 5.3
y_c_despues <- 5.6

cambio_tratado <- y_t_despues - y_t_antes
cambio_control <- y_c_despues - y_c_antes
DiD <- cambio_tratado - cambio_control

cambio_tratado
```



```
[1] 1.2
```

```
cambio_control
```

```
[1] 0.3
```


```
DiD
```

```
[1] 0.9
```

El resultado coincide con el obtenido a mano: un cambio de 1.2 puntos en el grupo tratado, un cambio de 0.3 puntos en el grupo de control, y una diferencia en diferencias de 0.9 puntos.

El gráfico clásico de diferencia en diferencias representa, para cada grupo, la evolución de la media entre el antes y el después mediante una línea. La divergencia entre ambas líneas tras la intervención es visualmente atribuible al efecto del programa.

```
datos_did <- tibble(  
  grupo = rep(c("Tratado", "Control"), each = 2),  
  momento = rep(c("Antes", "Después"), times = 2),  
  media = c(y_t_antes, y_t_despues, y_c_antes, y_c_despues)  
) |>  
  mutate(momento = factor(momento, levels = c("Antes", "Después")))  
  
ggplot(datos_did, aes(x = momento, y = media, group = grupo, color = grupo)) +  
  geom_line(linewidth = 1) +  
  geom_point(size = 3) +  
  labs(  
    x = "Momento",  
    y = "Calificación media",  
    color = "Grupo",  
    title = "Diferencia en diferencias del programa de refuerzo escolar"  
  ) +  
  theme_minimal()
```



En el gráfico se aprecia que, aunque ambos grupos mejoran ligeramente entre el antes y el después, el grupo tratado lo hace en mayor medida que el grupo de control, y esa distancia adicional es precisamente la *DiD* calculada.

8.4.2. Diseño de un solo grupo antes-después

Cuando no se dispone de ningún grupo de control, el diseño más simple consiste en comparar las mediciones de los mismos individuos antes y después de la intervención mediante un contraste de datos pareados. A continuación se simula una muestra de 30 individuos a los que se aplica una intervención (por ejemplo, un programa de entrenamiento cognitivo) y se mide su rendimiento antes y después.

```
set.seed(123)
n <- 30
antes <- rnorm(n, mean = 50, sd = 8)
despues <- antes + rnorm(n, mean = 4, sd = 5)

datos_pretest_postest <- tibble(
  individuo = 1:n,
  antes = antes,
  despues = despues
)

datos_pretest_postest
```

```
# A tibble: 30 x 3
  individuo antes despues
      <int> <dbl>   <dbl>
1         1  45.5    51.6
2         2  48.2    50.7
3         3  62.5    70.9
4         4  50.6    59.0
5         5  51.0    59.1
6         6  63.7    71.2
7         7  53.7    60.5
8         8  39.9    43.6
9         9  44.5    47.0
10        10  46.4    48.5
# i 20 more rows
```

Para contrastar si el cambio medio observado es estadísticamente significativo se aplica un contraste t de Student para datos pareados:

```
t.test(datos_pretest_postest$despues, datos_pretest_postest$antes, paired = TRUE)
```

Paired t-test

```
data: datos_pretest_postest$despues and datos_pretest_postest$antes
t = 6.4165, df = 29, p-value = 5.115e-07
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 3.332482 6.450901
sample estimates:
mean difference
 4.891692
```

El p-valor obtenido es prácticamente cero, muy inferior a 0.05, por lo que se rechaza la hipótesis nula de que no existe cambio medio entre el antes y el después: el rendimiento medio tras la intervención es significativamente superior al previo. Sin embargo, al tratarse de un diseño de un solo grupo, este resultado no permite descartar que el cambio se deba a otros factores distintos de la intervención (maduración de los individuos, práctica en la propia prueba, sucesos externos ocurridos durante el estudio, etc.), que es precisamente la principal limitación de este diseño frente al que incorpora un grupo de control no equivalente.

8.5. Cuándo utilizar este diseño

Un estudio cuasiexperimental es la opción adecuada cuando el investigador puede intervenir aplicando un tratamiento o programa, pero no puede asignar aleatoriamente a los individuos o unidades a los grupos de tratamiento y control, como ocurre con frecuencia en la evaluación de políticas públicas, programas educativos o intervenciones comunitarias. Se diferencia así de los [estudios experimentales](#), que deben preferirse siempre que la aleatorización sea posible y ética, ya que ofrecen un control mucho mayor sobre los factores de confusión. Y se diferencia de los [estudios de cohortes](#) en que en estos últimos el investigador no interviene en absoluto, limitándose a observar y seguir en el tiempo a individuos que ya están expuestos o no a un factor por decisión propia o por las circunstancias, sin aplicar ningún tratamiento. En definitiva, el diseño cuasiexperimental ocupa un lugar intermedio entre la observación pura y el experimento controlado, y resulta especialmente útil cuando la pregunta de investigación exige valorar el efecto de una intervención real que no puede aleatorizarse.

9. Encuestas y diseño de muestreo

Como se adelantó en el [capítulo de introducción](#), la encuesta es probablemente el instrumento de recogida de datos más extendido en estadística aplicada: consiste en seleccionar una muestra de individuos de una población y medir sobre ellos, mediante un cuestionario u otro procedimiento de observación, una o varias variables de interés (opiniones, hábitos, características sociodemográficas, intención de voto, etc.). En la mayoría de los casos comparte con el [estudio transversal](#) la misma lógica temporal, ya que las variables se registran en un único momento, sobre una muestra tomada de la población general sin condicionar la selección a ninguna exposición o resultado previo. Sin embargo, mientras que en los capítulos anteriores el foco estaba en el tipo de diseño observacional o experimental, en este capítulo el foco se traslada a una cuestión transversal a todos ellos y crítica para la validez de cualquier estudio: **cómo se selecciona la muestra** a partir de la cual se pretende estimar o inferir características de toda la población.

9.1. Definición y características

Definición 9.1 (Encuesta estadística). Una *encuesta estadística* es un procedimiento de investigación que consiste en seleccionar una muestra de individuos de una población, mediante un método de muestreo determinado, y recoger información sobre ellos (habitualmente a través de un cuestionario) con el fin de estimar características, opiniones o comportamientos de la población de la que proceden.

La validez de las conclusiones de una encuesta depende, en gran medida, de que la muestra seleccionada sea representativa de la población objetivo. Esto exige, en primer lugar, disponer de un marco muestral adecuado.

Definición 9.2 (Marco muestral). El *marco muestral* (en inglés, *sampling frame*) es el listado, registro o procedimiento que permite identificar y acceder a todos los elementos de la población objetivo, de manera que cada uno de ellos pueda ser seleccionado para formar parte de la muestra.

Un marco muestral incompleto o desactualizado (por ejemplo, un censo de población antiguo, o un listado telefónico que excluye a quienes solo disponen de móvil) introduce un sesgo de cobertura, ya que ciertos segmentos de la población tienen probabilidad nula

o muy baja de ser seleccionados, con independencia de lo riguroso que sea el método de muestreo empleado posteriormente.

Cuando se dispone de un marco muestral adecuado, existen varios diseños de **muestreo probabilístico**, en los que cada elemento de la población tiene una probabilidad conocida (y no nula) de ser seleccionado, lo que permite calcular la precisión de las estimaciones y generalizarlas a la población con garantías estadísticas. Los principales son los siguientes.

9.1.1. Muestreo aleatorio simple (MAS)

En el *muestreo aleatorio simple* cada elemento de la población tiene la misma probabilidad de ser seleccionado, y la selección de cada individuo es independiente de la de los demás. Es el diseño de referencia, el más sencillo de analizar, pero exige disponer de un marco muestral completo y puede resultar poco eficiente cuando la población es muy heterogénea o está muy dispersa geográficamente.

9.1.2. Muestreo estratificado

En el *muestreo estratificado* la población se divide previamente en subgrupos o **estratos**, internamente lo más homogéneos posible respecto a la variable de interés y heterogéneos entre sí (por ejemplo, comunidades autónomas, tramos de edad o tipo de centro educativo), y dentro de cada estrato se selecciona una muestra aleatoria simple de manera independiente. Cuando el tamaño de la muestra en cada estrato se reparte en proporción al peso de dicho estrato en la población, se habla de **afijación proporcional**. Al garantizar la presencia de todos los estratos en la proporción adecuada, este diseño suele producir estimaciones más precisas que el muestreo aleatorio simple, para un mismo tamaño de muestra, siempre que los estratos sean realmente homogéneos internamente.

9.1.3. Muestreo por conglomerados

En el *muestreo por conglomerados* (o *por clusters*) la población se divide en grupos naturales o preexistentes (conglomerados), como colegios, manzanas de una ciudad o centros de salud, y en lugar de seleccionar individuos se seleccionan aleatoriamente algunos conglomerados completos, incluyendo a todos sus miembros en la muestra (o, en su versión bietápica, seleccionando después una submuestra dentro de cada conglomerado elegido). Resulta especialmente útil cuando no existe un marco muestral de individuos pero sí de conglomerados, y reduce mucho el coste logístico al concentrar el trabajo de campo en unas pocas zonas. A cambio, suele perder precisión respecto al muestreo aleatorio simple, ya que los individuos de un mismo conglomerado tienden a parecerse entre sí.

9.1.4. Muestreo sistemático

En el *muestreo sistemático* se ordena el marco muestral (por ejemplo, un listado de N individuos), se calcula un intervalo de selección $k = N/n$ (siendo n el tamaño de muestra deseado), se elige aleatoriamente un punto de partida entre 1 y k , y a partir de él se selecciona cada k -ésimo elemento de la lista. Es fácil de aplicar y, cuando el listado no sigue ningún patrón periódico relacionado con la variable de interés, suele proporcionar resultados muy similares a los del muestreo aleatorio simple.

Además de estos diseños probabilísticos, existen métodos de **muestreo no probabilístico**, como el muestreo por conveniencia (se selecciona a los individuos más accesibles) o el muestreo en bola de nieve (los participantes reclutan a su vez a otros participantes). Estos métodos son más rápidos y baratos, pero al no conocerse la probabilidad de selección de cada individuo no permiten calcular la precisión de las estimaciones ni generalizar los resultados a la población con garantías estadísticas, por lo que su uso queda habitualmente restringido a estudios exploratorios o poblaciones muy difíciles de acceder.

9.2. Ventajas e inconvenientes

- **Muestreo aleatorio simple:** es el más sencillo de diseñar y analizar, pero exige un marco muestral completo de individuos y puede resultar poco eficiente (mayor error para el mismo tamaño de muestra) cuando la población es heterogénea.
- **Muestreo estratificado:** mejora la precisión frente al muestreo aleatorio simple cuando existen variables (estratos) fuertemente relacionadas con la variable de interés, y garantiza representación de todos los grupos relevantes; a cambio, requiere conocer de antemano el valor de la variable de estratificación para toda la población, lo que no siempre es posible.
- **Muestreo por conglomerados:** es el más económico y logísticamente viable cuando la población está muy dispersa o no existe un marco muestral de individuos, pero suele ser el menos preciso, ya que los elementos de un mismo conglomerado tienden a ser parecidos entre sí (baja variabilidad interna, alta variabilidad entre conglomerados).
- **Muestreo sistemático:** es muy fácil de implementar sobre un listado ordenado y suele comportarse como el muestreo aleatorio simple, pero puede introducir sesgos graves si el listado presenta algún patrón periódico que coincida con el intervalo de selección k .
- **Muestreo no probabilístico:** es el más rápido y barato, y en ocasiones la única opción viable (por ejemplo, para poblaciones ocultas o de difícil acceso), pero no permite cuantificar el error de muestreo ni generalizar los resultados a la población con garantías estadísticas.

9.3. Medidas propias de este diseño

Además de las medidas descriptivas habituales (proporciones, medias, etc.), calculadas ahora ponderando por el diseño muestral empleado, dos cantidades son especialmente características del diseño de encuestas: el error de muestreo de una estimación y el tamaño muestral necesario para lograr una precisión determinada.

9.3.1. Error de muestreo

Definición 9.3 (Error de muestreo). Dada una muestra aleatoria simple de tamaño n en la que se ha observado una proporción muestral $\hat{p}$ de individuos que presentan una determinada característica, el *error de muestreo* (o margen de error) de $\hat{p}$ para un nivel de confianza $1 - \alpha$ se define como

$$e = z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

donde $z_{\alpha/2}$ es el valor crítico de la distribución normal estándar que deja una probabilidad $\alpha/2$ a su derecha.

! Importante

El error de muestreo es siempre un número no negativo,

$$e \geq 0,$$

y disminuye a medida que aumenta el tamaño de muestra n , concretamente en proporción a $1/\sqrt{n}$: para reducir el error a la mitad es necesario cuadruplicar el tamaño de muestra.

i Interpretación

- El error de muestreo cuantifica cuánto puede diferir, con la confianza especificada, la proporción muestral $\hat{p}$ de la verdadera proporción poblacional p , exclusivamente por el hecho de trabajar con una muestra y no con toda la población.
- El intervalo $(\hat{p} - e, \hat{p} + e)$ es precisamente el intervalo de confianza al nivel $1 - \alpha$ para la proporción poblacional p .
- El error de muestreo no recoge otras fuentes de error ajenas al azar, como el sesgo de no respuesta, el sesgo de cobertura del marco muestral o los errores de medición del cuestionario, que pueden ser tanto o más importantes que el propio error de muestreo.

9.3.2. Tamaño muestral necesario

En la práctica, la pregunta habitual no es “¿qué error tiene mi muestra?” sino la inversa: “¿qué tamaño de muestra necesito para que el error no supere un determinado valor?”. Despejando n de la fórmula del error de muestreo se obtiene la siguiente expresión.

Definición 9.4 (Tamaño muestral necesario). Para estimar una proporción poblacional p con un error de muestreo máximo e y un nivel de confianza $1 - \alpha$, el tamaño de muestra necesario, suponiendo muestreo aleatorio simple sobre una población de tamaño muy superior a la muestra, es

$$n = \frac{z_{\alpha/2}^2 p(1-p)}{e^2}$$

donde p es un valor aproximado (de un estudio previo o piloto) de la proporción que se quiere estimar; si no se dispone de tal valor, se toma $p = 0.5$, ya que es el valor que maximiza $p(1-p)$ y por tanto produce el tamaño de muestra más conservador (el mayor posible).

! Importante

Cuando la población tiene un tamaño finito y conocido N que no es muy superior al tamaño de muestra calculado, puede aplicarse el *factor de corrección para poblaciones finitas*,

$$n_{ajustado} = \frac{n}{1 + \frac{n-1}{N}},$$

que reduce ligeramente el tamaño de muestra necesario. En la práctica, cuando N es grande frente a n (por ejemplo, encuestas sobre la población de un país o una ciudad grande), esta corrección apenas tiene efecto y suele omitirse.

i Interpretación

- El tamaño muestral necesario aumenta con el nivel de confianza exigido (mayor $z_{\alpha/2}$) y disminuye rápidamente al relajar la precisión exigida (mayor e), ya que n depende del cuadrado de e en el denominador.
- El tamaño muestral necesario es máximo cuando $p = 0.5$ y disminuye a medida que p se aleja de 0.5 hacia 0 o hacia 1, ya que fenómenos muy raros o muy comunes son, en cierto sentido, más fáciles de acotar con precisión.
- Esta fórmula corresponde al muestreo aleatorio simple; en diseños estratificados, por conglomerados o sistemáticos, el tamaño necesario puede ser menor o mayor, en función de si el diseño mejora o empeora la precisión respecto al

Ejemplo 9.1. Se quiere diseñar una encuesta para estimar la proporción de la población de una ciudad que está a favor de un determinado proyecto urbanístico, con un error de muestreo máximo de $e = 0.03$ (tres puntos porcentuales) y un nivel de confianza del 95 % ($\alpha = 0.05$, por lo que $z_{\alpha/2} = 1.96$). Al no disponer de información previa sobre la proporción real, se toma el valor más conservador, $p = 0.5$. El tamaño de muestra necesario es

$$n = \frac{z_{\alpha/2}^2 p(1-p)}{e^2} = \frac{1.96^2 \times 0.5 \times 0.5}{0.03^2} = \frac{0.9604}{0.0009} \approx 1067.1.$$

Redondeando hacia arriba, se necesitaría una muestra de $n = 1068$ individuos para garantizar, con una confianza del 95 %, que la proporción estimada no se aleje de la verdadera proporción poblacional en más de tres puntos porcentuales.

9.4. Realización con R

9.4.1. Cálculo del tamaño muestral necesario

En primer lugar se reproduce en R el cálculo manual del Ejemplo 9.1, obteniendo el valor crítico $z_{\alpha/2}$ con `qnorm()` y aplicando directamente la fórmula del tamaño muestral:

```
calcular_n <- function(e, confianza = 0.95, p = 0.5) {  
  alpha <- 1 - confianza  
  z <- qnorm(1 - alpha / 2)  
  n <- (z^2 * p * (1 - p)) / e^2  
  ceiling(n)  
}  
  
n_necesario <- calcular_n(e = 0.03, confianza = 0.95, p = 0.5)  
n_necesario
```

```
[1] 1068
```

El resultado, 1068 individuos, coincide con el obtenido a mano. A continuación se representa cómo varía el tamaño de muestra necesario en función del error de muestreo admitido, para un nivel de confianza del 95 %:

```
errores <- tibble(
  e = seq(0.01, 0.10, by = 0.005)
) |>
  mutate(n = map_dbl(e, ~ calcular_n(.x, confianza = 0.95, p = 0.5)))

ggplot(errores, aes(x = e, y = n)) +
  geom_line(color = "steelblue", linewidth = 1) +
  geom_point(color = "steelblue") +
  scale_x_continuous(labels = scales::percent_format()) +
  scale_y_continuous(labels = scales::comma_format()) +
  labs(
    x = "Error de muestreo admitido",
    y = "Tamaño de muestra necesario",
    title = "Relación entre precisión exigida y tamaño de muestra"
  ) +
  theme_minimal()
```




Figura 9.1.: Tamaño de muestra necesario en función del error de muestreo admitido (confianza del 95 %, $p = 0.5$).

Como cabía esperar, el tamaño de muestra necesario crece muy rápidamente a medida que se exige un error de muestreo menor, debido a la relación cuadrática entre ambas cantidades.

9.4.2. Comparación entre muestreo aleatorio simple y muestreo estratificado

Para comparar la precisión del muestreo aleatorio simple (MAS) frente al muestreo estratificado, se simula una “población” de $N = 4000$ personas repartidas en 4 regiones, con una opinión binaria (a favor / en contra de una medida) cuya prevalencia varía sustancialmente de una región a otra, de forma que la región constituye un buen criterio de estratificación:

```
set.seed(2026)
N <- 4000

poblacion <- tibble(
  id = 1:N,
  region = sample(
    c("Norte", "Sur", "Este", "Oeste"),
    size = N,
    replace = TRUE,
    prob = c(0.30, 0.25, 0.25, 0.20)
  )
)

# La probabilidad de estar a favor depende fuertemente de la región
prob_favor <- c(Norte = 0.75, Sur = 0.30, Este = 0.55, Oeste = 0.40)

poblacion <- poblacion |>
  mutate(
    p_favor = prob_favor[region],
    opinion = rbinom(N, size = 1, prob = p_favor),
    opinion = factor(opinion, levels = c(0, 1), labels = c("En contra", "A favor"))
  )

poblacion
```

```
# A tibble: 4,000 x 4
      id region p_favor opinion
  <int> <chr>   <dbl> <fct>
1     1  Sur     0.3  En contra
2     2  Sur     0.3  En contra
3     3 Norte    0.75 A favor
4     4 Norte    0.75 A favor
5     5  Sur     0.3  En contra
6     6 Norte    0.75 A favor
7     7 Este     0.55 A favor
```

```

8      8 Oeste      0.4  A favor
9      9 Norte      0.75 A favor
10     10 Sur       0.3  A favor
# i 3,990 more rows

```

La proporción real de personas a favor en el conjunto de la población (el parámetro que se desea estimar) es:

```

p_poblacional <- mean(poblacion$opinion == "A favor")
p_poblacional

```

```
[1] 0.51325
```

A partir de esta población se extrae, en primer lugar, una muestra aleatoria simple de $n = 1068$ individuos:

```

muestra_mas <- poblacion |>
  slice_sample(n = n_necesario)

p_mas <- mean(muestra_mas$opinion == "A favor")
p_mas

```

```
[1] 0.5065543
```

A continuación se extrae una muestra estratificada por región, con afijación proporcional, del mismo tamaño total aproximado: se calcula la proporción que representa cada región en la población y se selecciona ese mismo porcentaje dentro de cada estrato:

```

prop_muestral <- n_necesario / N

muestra_estratificada <- poblacion |>
  group_by(region) |>
  slice_sample(prop = prop_muestral) |>
  ungroup()

nrow(muestra_estratificada)

```

```
[1] 1067
```

```
p_estratificado <- mean(muestra_estratificada$opinion == "A favor")
p_estratificado
```

```
[1] 0.5126523
```

Se comprueba que la muestra estratificada respeta, aproximadamente, el peso de cada región en la población:

```
muestra_estratificada |>
  count(region) |>
  mutate(proporcion_muestra = n / sum(n))
```

```
# A tibble: 4 x 3
  region      n proporción_muestra
  <chr> <int>         <dbl>
1 Este    268         0.251
2 Norte   322         0.302
3 Oeste   205         0.192
4 Sur     272         0.255
```

```
poblacion |>
  count(region) |>
  mutate(proporcion_poblacion = n / sum(n))
```

```
# A tibble: 4 x 3
  region      n proporción_poblacion
  <chr> <int>         <dbl>
1 Este   1004         0.251
2 Norte  1207         0.302
3 Oeste   769         0.192
4 Sur    1020         0.255
```

Por último, se comparan gráficamente las tres proporciones: la real de la población y las estimadas por cada uno de los dos métodos de muestreo.

```
comparacion <- tibble(
  metodo = c("Población", "MAS", "Estratificado"),
  proporción = c(p_poblacional, p_mas, p_estratificado)
) |>
  mutate(metodo = factor(metodo, levels = c("Población", "MAS", "Estratificado")))
```

```
ggplot(comparacion, aes(x = metodo, y = proporcion, fill = metodo)) +
  geom_col(width = 0.6) +
  geom_hline(yintercept = p_poblacional, linetype = "dashed", color = "gray30") +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_brewer(palette = "Set2") +
  labs(
    x = NULL,
    y = "Proporción a favor",
    title = "Estimación de la proporción según el diseño de muestreo"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 9.2.: Proporción de personas a favor de la medida: valor poblacional real frente a las estimaciones por muestreo aleatorio simple y por muestreo estratificado.

En esta simulación, la proporción real de personas a favor en la población es del 51.3 %, mientras que la muestra aleatoria simple estima un 50.7 % y la muestra estratificada un 51.3 %. Dado que la región está fuertemente relacionada con la opinión (los estratos son internamente bastante homogéneos) y que la afijación proporcional garantiza que cada región esté representada en su peso exacto, cabe esperar que, en promedio y a lo largo de repeticiones del muestreo, la estimación estratificada se aproxime más a la proporción poblacional que la del muestreo aleatorio simple, cuya composición por

regiones puede variar de una muestra a otra por puro azar. Este es precisamente el motivo por el que, siempre que se disponga de una variable de estratificación adecuada, el muestreo estratificado suele preferirse al muestreo aleatorio simple en las encuestas reales.

9.5. Cuándo utilizar este diseño

El diseño de muestreo no es un tipo de estudio alternativo a los descritos en los capítulos anteriores, sino una dimensión transversal a todos ellos: tanto un [estudio descriptivo](#) como un [estudio transversal](#), un [estudio de cohortes](#) o un ensayo [experimental](#) necesitan seleccionar en algún momento una muestra de la población, y la calidad de ese muestreo condiciona directamente la validez de las conclusiones que se extraigan. Conviene prestar especial atención al diseño muestral, y en particular optar por el muestreo estratificado o por conglomerados frente al muestreo aleatorio simple, cuando la población es muy heterogénea, cuando existen variables conocidas fuertemente relacionadas con el fenómeno de interés, o cuando el coste de acceder a los individuos varía mucho según su localización o su pertenencia a un determinado grupo. Un cálculo previo del tamaño muestral necesario, en función de la precisión exigida y de los recursos disponibles, es también un paso imprescindible en la planificación de cualquier estudio, se trate de una encuesta de opinión, un estudio epidemiológico o un ensayo clínico. En definitiva, ningún análisis estadístico posterior, por sofisticado que sea, puede compensar una muestra mal seleccionada: la calidad del diseño muestral es, junto con el propio diseño del estudio, uno de los pilares sobre los que se sostiene la validez de cualquier investigación estadística.

Parte II.

Selección del contraste estadístico

10. Selección del contraste estadístico

Los capítulos anteriores han mostrado cómo **diseñar** un estudio estadístico: cómo seleccionar la muestra, cómo asignar (o no) la exposición, y en qué momentos recoger los datos. Una vez recogidos los datos según alguno de esos diseños, queda una segunda pregunta, igual de importante: ¿qué **contraste de hipótesis** es el adecuado para analizarlos?

La respuesta depende, sobre todo, de tres factores:

- El **número de variables** que intervienen en el estudio y, si hay más de una, cuál es la variable dependiente (la respuesta que se quiere explicar) y cuál la independiente (el factor que se cree que influye en ella).
- El **tipo de las variables**: cuantitativas, cualitativas ordinales o cualitativas nominales.
- La **naturaleza de las poblaciones o grupos comparados**: si son independientes (individuos distintos en cada grupo) o están relacionadas o pareadas (los mismos individuos medidos varias veces, o emparejados de algún modo).

Esta segunda parte del libro está dedicada precisamente a esta cuestión: cómo elegir, y cómo ejecutar en R, el contraste de hipótesis apropiado en cada situación. A diferencia de la primera parte, aquí el capítulo no se organiza por tipo de diseño de investigación, sino por el **número y la naturaleza de las poblaciones o grupos** que se comparan, que es el criterio que realmente determina qué contraste utilizar. El diseño del estudio (si los datos proceden de un [estudio de cohortes](#), de un [ensayo clínico](#) o de una simple [encuesta](#)) influye en qué conclusiones de causalidad pueden extraerse del resultado del contraste, pero no cambia, en general, qué contraste es el adecuado: eso lo determinan el número de variables, su tipo, y si las poblaciones comparadas son independientes o están pareadas.

10.1. Tabla de decisión

La siguiente tabla resume los contrastes de hipótesis más habituales según estos criterios, y sirve como mapa de esta segunda parte del libro. Cada fila indica, para una combinación de variable(s) independiente(s), variable dependiente y objetivo del análisis, cuál es el contraste apropiado y en qué capítulo se desarrolla.

Variables independientes

Variable dependiente

Objetivo

Contraste

Capítulo

Ninguna (una población)

Cuantitativa

Contrastar la normalidad de una variable

Kolmogorov-Smirnov (muestras grandes) / Shapiro-Wilk

[Contrastes para una población](#)

Cuantitativa normal

Contrastar si la media poblacional tiene un valor determinado

Test t para la media de una población

Ninguna (una población)

Cualitativa (2 categorías)

Contrastar si la proporción de una categoría tiene un valor determinado

Test binomial / Test Z para una proporción

Cualitativa (>2 categorías)

Contrastar si las proporciones de las categorías tienen unos valores determinados

Test Chi-cuadrado de bondad de ajuste

Una cualitativa con 2 categorías, poblaciones independientes

Cuantitativa normal

Contrastar si hay diferencias entre las medias de las dos poblaciones

Test F de Fisher (varianzas) + Test t de comparación de medias

[Contrastes para dos poblaciones independientes](#)

Cuantitativa o cualitativa ordinal

Contrastar si hay diferencias entre las distribuciones de las dos poblaciones

Test U de Mann-Whitney

Cualitativa (2 categorías)

Contrastar si hay relación entre las variables o diferencias entre proporciones

Test Chi-cuadrado de independencia / Test exacto de Fisher

Cualitativa (>2 categorías)

Contrastar si hay relación entre las variables o diferencias entre proporciones

Test Chi-cuadrado de independencia

Una cualitativa con >2 categorías, poblaciones independientes

Cuantitativa normal (varianzas homogéneas)

Contrastar si hay diferencias entre las medias de las poblaciones

Levene (varianzas) + ANOVA de un factor + Tukey/Bonferroni

Cuantitativa o cualitativa ordinal

Contrastar si hay diferencias entre las distribuciones de las poblaciones

Test de Kruskal-Wallis + comparaciones por pares de Wilcoxon

Una cualitativa con 2 categorías, poblaciones pareadas

Cuantitativa normal

Contrastar si hay diferencias entre las medias de las dos poblaciones pareadas

Test t para datos pareados

[Contrastes para dos poblaciones pareadas](#)

Cuantitativa o cualitativa ordinal

Contrastar si hay diferencias entre las distribuciones de las dos poblaciones pareadas

Test de Wilcoxon para datos pareados

Cualitativa (2 categorías)

Contrastar si hay diferencias entre las proporciones de las dos poblaciones pareadas

Test de McNemar

Una cualitativa con >2 categorías, poblaciones relacionadas (medidas repetidas)

Cuantitativa normal

Contrastar si hay diferencias entre las medidas repetidas

ANOVA de medidas repetidas de un factor

[Contrastes para más de dos poblaciones relacionadas](#)

Cuantitativa o cualitativa ordinal

Contrastar si hay diferencias entre las medidas repetidas

Test de Friedman

Una cuantitativa normal

Cuantitativa normal

Contrastar si existe relación lineal / construir un modelo predictivo

Correlación de Pearson / Regresión simple

Relación y predicción entre dos variables

Cuantitativa o cualitativa ordinal

Contrastar si existe relación (de orden) entre las dos variables

Correlación de Spearman

Una cuantitativa

Cualitativa (2 categorías)

Construir un modelo predictivo que explique la variable cualitativa

Regresión logística simple

i Nota

Esta tabla no agota todas las situaciones posibles. Quedan fuera de esta segunda parte, por ser casos más especializados, los contrastes de **concordancia o acuerdo entre dos medidas** de un mismo fenómeno (como el coeficiente Kappa de Cohen para variables cualitativas o el coeficiente de correlación intraclase para variables cuantitativas), así como el ANOVA de dos o más factores y sus interacciones. El [Manual de Estadística](#) desarrolla además, con mucho más detalle, la correlación y la regresión, y el coeficiente chi-cuadrado y de contingencia entre variables cualitativas, por lo que el último capítulo de esta parte remite a él para profundizar en esos contrastes en lugar de repetir aquí su desarrollo.

10.2. El conjunto de datos de ejemplo

Todos los ejemplos de esta segunda parte utilizan un mismo conjunto de datos, `datos-curso.csv`, con las calificaciones de 120 alumnos de una asignatura dividida en tres grupos de clase. Se puede descargar desde el repositorio del libro para reproducir los ejemplos.

```
df <- read_csv("datos/datos-curso.csv")
```

```

Rows: 120 Columns: 16
-- Column specification -----
Delimiter: ","
chr (9): sexo, turno, grupo, trabaja, calificacionA, calificacionB, califica...
dbl (7): notaA, notaB, notaC, notaD, notaE, asinaturas.aprobadas, nota.media

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.

```

```
glimpse(df)
```

```

Rows: 120
Columns: 16
$ sexo           <chr> "Mujer", "Hombre", "Hombre", "Hombre", "Hombre", ~
$ turno          <chr> "Tarde", "Mañana", "Mañana", "Mañana", "Mañana", ~
$ grupo          <chr> "C", "A", "B", "B", "A", "A", "A", "C", "C", "C", ~
$ trabaja        <chr> "N", "N", "N", "N", "N", "S", "N", "S", "N", "N", ~
$ notaA          <dbl> 5.2, 5.7, 8.3, 6.1, 6.2, 8.6, 6.7, 4.1, 5.0, 5.3, ~
$ notaB          <dbl> 6.3, 5.7, 8.8, 6.8, 9.0, 8.9, 7.9, 5.2, 5.0, 6.3, ~
$ notaC          <dbl> 3.4, 4.2, 8.8, 4.0, 5.0, 9.5, 5.6, 1.7, 3.3, 4.8, ~
$ notaD          <dbl> 2.3, 3.5, 8.0, 3.5, 4.4, 8.4, 4.8, 0.3, 2.7, 3.6, ~
$ notaE          <dbl> 2.0, 2.7, 5.5, 2.2, 3.7, 3.9, 4.2, 1.0, 6.0, 2.3, ~
$ calificacionA  <chr> "Aprobado", "Aprobado", "Aprobado", "Aprobado", "~
$ calificacionB  <chr> "Aprobado", "Aprobado", "Aprobado", "Aprobado", "~
$ calificacionC  <chr> "Suspendo", "Suspendo", "Aprobado", "Suspendo", "~
$ calificacionD  <chr> "Suspendo", "Suspendo", "Aprobado", "Suspendo", "~
$ calificacionE  <chr> "Suspendo", "Suspendo", "Aprobado", "Suspendo", "~
$ asinaturas.aprobadas <dbl> 2, 2, 5, 2, 3, 4, 3, 1, 2, 2, 3, 2, 3, 3, 3, 4, 4~
$ nota.media     <dbl> 3.8, 4.3, 7.9, 4.5, 5.7, 7.8, 5.8, 2.5, 4.4, 4.5, ~

```

Las variables que contiene son:

Variable	Descripción
sexo	Sexo del alumno (Hombre / Mujer).
turno	Turno en el que cursa la asignatura (Mañana / Tarde).
grupo	Grupo de clase al que pertenece (A, B o C).
trabaja	Si el alumno compagina los estudios con un trabajo (S / N).

Variable	Descripción
<code>notaA, ..., notaE</code>	Calificación numérica (0-10) obtenida en cinco pruebas o exámenes distintos de la asignatura.
<code>calificacionA, ..., calificacionE</code>	Resultado cualitativo (Aprobado / Suspenso) de cada una de esas cinco pruebas.
<code>asinaturas.aprobadas</code>	Número de asignaturas aprobadas por el alumno ese curso (0 a 5).
<code>nota.media</code>	Nota media del alumno en el curso.

Este conjunto de datos permite ilustrar tanto comparaciones entre **poblaciones independientes** (por ejemplo, comparar `notaA` entre hombres y mujeres, dos grupos de individuos distintos) como comparaciones entre **poblaciones pareadas o medidas repetidas** (por ejemplo, comparar `notaA` con `notaB` para los mismos alumnos, o las cinco notas `notaA` a `notaE` de cada alumno entre sí).

10.3. Estructura de los capítulos

Los capítulos siguientes están organizados por el número de poblaciones o grupos comparados y por si estos son independientes o están relacionados, siguiendo el orden de la tabla de decisión anterior. Cada contraste se presenta con una estructura fija: el **objetivo** del contraste, sus **requisitos** de aplicación, la **hipótesis nula** que pone a prueba, un ejemplo resuelto sobre el conjunto de datos del curso, y la interpretación del resultado.

11. Contrastes para una población

Este primer capítulo de la segunda parte del libro corresponde a la fila más sencilla de la [tabla de decisión](#): no hay ninguna variable independiente, y el objetivo es describir o contrastar una única variable de una única población, sin compararla con ninguna otra. Según el tipo de esa variable, cuantitativa o cualitativa, los estadísticos descriptivos, los gráficos y los contrastes de hipótesis apropiados son distintos, por lo que el capítulo se organiza en dos grandes secciones. Todos los ejemplos utilizan el conjunto de datos `datos-curso.csv` presentado en el capítulo anterior.

11.1. Una variable cuantitativa

11.1.1. Estadísticos descriptivos

Antes de aplicar cualquier contraste conviene describir la variable con sus estadísticos habituales de posición, dispersión y forma. Para la variable `notaA` se obtienen así:

```
nrow(df)
```

```
[1] 120
```

```
mean(df$notaA)
```

```
[1] 6.028333
```

```
sd(df$notaA)
```

```
[1] 1.340524
```

```
min(df$notaA)
```

```
[1] 2.5
```



```
max(df$notaA)
```

```
[1] 9.3
```

```
quantile(df$notaA)
```

```
   0%   25%   50%   75%  100%  
2.500 5.100 5.900 6.825 9.300
```

```
library(moments)  
skewness(df$notaA)
```

```
[1] 0.1373915
```

```
kurtosis(df$notaA) - 3
```


```
[1] -0.102287
```

La muestra está formada por los $n = 120$ alumnos del curso, con una nota media en la prueba A de $\bar{x} = 6.03$ y una desviación típica de $s = 1.34$. Las calificaciones oscilan entre un mínimo de 2.5 y un máximo de 9.3, con una mediana de 5.9 y un rango intercuartílico que va de $Q_1 = 5.1$ a $Q_3 = 6.83$. El coeficiente de asimetría es prácticamente nulo (0.137), lo que indica una distribución casi simétrica con una ligerísima cola hacia la derecha, y el coeficiente de apuntamiento (curtosis menos 3) también es cercano a cero (-0.102), por lo que la distribución no se aparta mucho de la forma acampanada de una normal. Estos dos últimos valores ya anticipan el resultado del contraste de normalidad que se aplica más adelante.


11.1.2. Gráficos

El histograma y el diagrama de caja y bigotes son las representaciones habituales de una variable cuantitativa, y permiten valorar visualmente la forma de la distribución (simetría, apuntamiento, posibles valores atípicos) antes de someterla a un contraste formal.

```
ggplot(df, aes(x = notaA)) +  
  geom_histogram(binwidth = 1, fill = "steelblue", color = "white") +  
  labs(x = "Nota A", y = "Frecuencia")
```



```
ggplot(df, aes(y = notaA)) +  
  geom_boxplot(fill = "steelblue") +  
  labs(y = "Nota A")
```



Ambos gráficos confirman lo que ya sugerían los estadísticos descriptivos: una distribución razonablemente simétrica y centrada alrededor de 6, sin valores atípicos destacables en el

diagrama de caja.

11.1.3. Contraste de normalidad de Shapiro-Wilk

Definición 11.1 (Contraste de normalidad de Shapiro-Wilk). El contraste de Shapiro-Wilk permite comprobar si una muestra de una variable cuantitativa procede de una población con distribución normal. Su hipótesis nula es

$$H_0 : \text{la variable sigue una distribución normal.}$$

Se rechaza esta hipótesis cuando el p-valor del contraste es menor que el nivel de significación fijado (habitualmente 0.05).

Requisitos: una variable cuantitativa. El test de Shapiro-Wilk funciona bien con cualquier tamaño muestral, aunque con muestras muy grandes es tan potente que puede rechazar la normalidad ante desviaciones mínimas y sin relevancia práctica; en ese caso es preferible el contraste de Kolmogorov-Smirnov (`ks.test()`), que compara la función de distribución empírica de los datos con la de una normal teórica y es más adecuado para muestras grandes.

Muchos de los contrastes que se estudian en este libro, como el test t, exigen que la variable analizada siga una distribución normal (o que la muestra sea suficientemente grande, $n \geq 30$, para invocar el teorema central del límite). El contraste de Shapiro-Wilk es la herramienta habitual para comprobar ese requisito antes de aplicarlos. A continuación se contrasta la normalidad de dos variables del conjunto de datos, `notaA` y `notaE`, para mostrar un caso en el que no se rechaza la normalidad y otro en el que sí se rechaza.

Ejemplo 11.1.

```
shapiro.test(df$notaA)
```

Shapiro-Wilk normality test

```
data: df$notaA  
W = 0.99424, p-value = 0.907
```

```
shapiro.test(df$notaE)
```

Shapiro-Wilk normality test

```
data: df$notaE
W = 0.92264, p-value = 4.065e-06
```

Para `notaA` el estadístico es $W = 0.994$ con un p-valor de 0.907, muy superior a 0.05, por lo que no hay evidencia para rechazar H_0 : es razonable asumir que `notaA` sigue una distribución normal. Para `notaE`, en cambio, el p-valor es 4.07×10^{-6} , muy inferior a 0.05, por lo que se rechaza H_0 y se concluye que `notaE` no sigue una distribución normal (coherente con ser una nota con más alumnos suspensos concentrados en valores bajos, lo que genera asimetría).

11.1.4. Test t para la media de una población

Definición 11.2 (Test t para la media de una población). El test t de una muestra permite contrastar si la media de una variable cuantitativa en una población, μ , es igual a un valor de referencia μ_0 . La hipótesis nula es

$$H_0 : \mu = \mu_0,$$

frente a una hipótesis alternativa bilateral ($\mu \neq \mu_0$) o unilateral ($\mu > \mu_0$ o $\mu < \mu_0$), según el interés del estudio.

Requisitos: variable cuantitativa que siga una distribución normal, o bien un tamaño muestral suficientemente grande ($n \geq 30$) para que el teorema central del límite garantice la normalidad de la media muestral aunque la variable original no sea normal.

Como se acaba de comprobar con el contraste de Shapiro-Wilk, `notaA` puede considerarse normal, así que puede aplicarse directamente el test t para comprobar si la nota media de esta prueba difiere de un valor de referencia, por ejemplo si difiere de 5.

Ejemplo 11.2.

```
t.test(df$notaA, mu = 5, alternative = "two.sided")
```

One Sample t-test

```
data: df$notaA
t = 8.4033, df = 119, p-value = 1.08e-13
alternative hypothesis: true mean is not equal to 5
```

```
95 percent confidence interval:
 5.786023 6.270643
sample estimates:
mean of x
 6.028333
```

El estadístico del contraste es $t = 8.40$ con 119 grados de libertad y un p-valor de 1.08×10^{-13} , muy inferior a 0.05, por lo que se rechaza H_0 : la nota media de **notaA** es significativamente distinta de 5. La media muestral, $\bar{x} = 6.03$, junto con el intervalo de confianza al 95 % (de 5.79 a 6.27, que no incluye el valor 5), indica que la nota media real de esta prueba es superior a 5.

11.2. Una variable cualitativa

11.2.1. Estadísticos descriptivos

Para una variable cualitativa, los estadísticos descriptivos habituales son las frecuencias absolutas y relativas (proporciones o porcentajes) de cada categoría. Antes de calcularlas conviene comprobar cuántos alumnos tienen datos perdidos en la variable. Por ejemplo, para **calificacionB**:

```
sum(!is.na(df$calificacionB))
```

```
[1] 115
```

```
table(df$calificacionB)
```

```
Aprobado  Suspenso
      98      17
```

```
prop.table(table(df$calificacionB))
```


```
Aprobado  Suspenso
0.8521739 0.1478261
```

De los 120 alumnos del curso, 5 tienen un dato perdido en **calificacionB**, por lo que la variable se ha podido observar en $n = 115$ alumnos. De ellos, 98 aprobaron esta prueba y 17 la suspendieron, lo que supone una proporción de aprobados del 85.2 % y de suspensos del 14.8 %.


11.2.2. Gráficos

El diagrama de sectores es una representación muy extendida para variables cualitativas, ya que muestra de un vistazo el peso de cada categoría sobre el total. Sin embargo, cuando hay que comparar con precisión el tamaño de varias categorías, el ojo humano distingue peor los ángulos que las alturas, por lo que un diagrama de barras suele ser una alternativa más legible.

```
tabla_pie <- df %>%  
  count(calificacionA) %>%  
  mutate(prop = n / sum(n))  
  
ggplot(tabla_pie, aes(x = "", y = prop, fill = calificacionA)) +  
  geom_col(width = 1) +  
  coord_polar(theta = "y") +  
  labs(x = NULL, y = NULL, fill = "Calificación A") +  
  theme_void()
```



```
ggplot(df, aes(x = calificacionA)) +  
  geom_bar(fill = "steelblue") +  
  labs(x = "Calificación A", y = "Número de alumnos")
```



Los dos gráficos muestran la misma información (una amplia mayoría de aprobados en la prueba A frente a una minoría de suspensos), pero el diagrama de barras permite leer con más precisión el número de alumnos de cada categoría.

11.2.3. Test binomial para una proporción

Definición 11.3 (Test binomial para una proporción). El test binomial exacto permite contrastar si la proporción poblacional de una de las dos categorías de una variable cualitativa dicotómica, p , es igual a un valor de referencia p_0 . La hipótesis nula es

$$H_0 : p = p_0,$$

frente a una alternativa bilateral o unilateral, según el interés del estudio. El contraste se basa directamente en la distribución binomial exacta, sin recurrir a ninguna aproximación.

Requisitos: variable cualitativa con exactamente dos categorías. Al ser un contraste exacto, es válido para cualquier tamaño muestral, incluidas las muestras pequeñas en las que no es aplicable la aproximación normal.

Un objetivo habitual en la evaluación de un curso es comprobar si la tasa de aprobados de una prueba supera un determinado umbral, por ejemplo el 70%. A continuación se contrasta si la proporción de aprobados en `calificacionA` es superior a 0.7.

Ejemplo 11.3.

```
binom.test(x = table(df$calificacionA)["Aprobado"], n = nrow(df), p = 0.7,
           alternative = "greater")
```

Exact binomial test

```
data: table(df$calificacionA)["Aprobado"] and nrow(df)
number of successes = 94, number of trials = 120, p-value = 0.02657
alternative hypothesis: true probability of success is greater than 0.7
95 percent confidence interval:
 0.7123183 1.0000000
sample estimates:
probability of success
      0.7833333
```

De los 120 alumnos, 94 aprobaron la prueba A, una proporción muestral de $\hat{p} = 0.783$. El p-valor del contraste es 0.027, inferior a 0.05, por lo que se rechaza H_0 : hay evidencia suficiente para afirmar que la proporción real de aprobados en la prueba A es superior al 70 %.

11.2.4. Test Z para una proporción

Definición 11.4 (Test Z para una proporción). El test Z para una proporción persigue el mismo objetivo que el test binomial (contrastar si una proporción poblacional p es igual a un valor de referencia p_0 , con hipótesis nula $H_0 : p = p_0$), pero en lugar de usar la distribución binomial exacta se apoya en la aproximación normal a la binomial, con corrección de continuidad.

Requisitos: variable cualitativa con dos categorías y tamaño muestral suficientemente grande ($n \geq 30$, y en particular $np_0 \geq 5$ y $n(1 - p_0) \geq 5$) para que la aproximación normal a la binomial sea razonable. Con muestras pequeñas es preferible el test binomial exacto.

El tamaño de la muestra de este curso, $n = 120$, es suficientemente grande como para aplicar también el test Z sobre el mismo contraste de la proporción de aprobados en calificacionA.

Ejemplo 11.4.

```
prop.test(x = table(df$calificacionA)["Aprobado"], n = nrow(df), p = 0.7,
          alternative = "greater")
```


1-sample proportions test with continuity correction

```
data:  table(df$calificacionA["Aprobado"]) out of nrow(df), null probability 0.7
X-squared = 3.5813, df = 1, p-value = 0.02922
alternative hypothesis: true p is greater than 0.7
95 percent confidence interval:
 0.7111099 1.0000000
sample estimates:
      p
0.7833333
```

El estadístico de este contraste es $\chi^2 = 3.58$ (equivalente a un estadístico Z al cuadrado) con un p-valor de 0.029, también inferior a 0.05. La conclusión coincide con la del test binomial exacto: se rechaza H_0 y se concluye que la proporción de aprobados en la prueba A es significativamente superior al 70 %. El p-valor obtenido con la aproximación normal (0.029) es muy similar al del test exacto (0.027), como cabía esperar con un tamaño muestral de 120 alumnos, aunque en muestras pequeñas ambos contrastes pueden diferir de forma más apreciable.

12. Contrastes para dos poblaciones independientes

Este capítulo desarrolla la primera fila de la [tabla de decisión](#) que involucra a dos variables: aquella en la que la variable independiente es cualitativa con dos categorías, cada una correspondiente a un grupo de individuos **distintos** (poblaciones independientes), y se quiere contrastar si existen diferencias entre esos dos grupos en una variable dependiente, ya sea esta cuantitativa o cualitativa. Los ejemplos utilizan el conjunto de datos `datos-curso.csv` presentado en el [capítulo anterior](#), comparando a los alumnos según su `sexo` (Hombre / Mujer), dos grupos formados por alumnos diferentes y por tanto independientes entre sí.

12.1. Variable dependiente cuantitativa

Cuando la variable dependiente es cuantitativa, el objetivo habitual es comparar la nota obtenida en la primera prueba, `notaA`, entre los alumnos y las alumnas. Antes de aplicar ningún contraste conviene describir y representar gráficamente los datos, y comprobar si es razonable asumir que `notaA` sigue una distribución normal dentro de cada grupo, ya que de ello depende qué contraste es el más apropiado.

12.1.1. Estadísticos descriptivos por grupo

```
library(moments)

df %>%
  group_by(sexo) %>%
  summarise(
    n = n(),
    media = mean(notaA),
    de = sd(notaA),
    minimo = min(notaA),
    Q1 = quantile(notaA, 0.25),
    mediana = median(notaA),
    Q3 = quantile(notaA, 0.75),
```

```

    maximo = max(notaA),
    asimetria = skewness(notaA),
    apuntamiento = kurtosis(notaA)
)

```

```

# A tibble: 2 x 11
  sexo      n media  de minimo  Q1 mediana  Q3 maximo asimetria
  <chr> <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 Hombre   71  6.12  1.23   3.5  5.3   6.1  6.85  9.3   0.249
2 Mujer   49  5.89  1.49   2.5  5    5.7  6.8   9.3   0.135
# i 1 more variable: apuntamiento <dbl>

```

Los dos grupos tienen un tamaño razonable (71 hombres y 49 mujeres), medias muy parecidas (6.12 frente a 5.89) y coeficientes de asimetría y apuntamiento próximos a los valores 0 y 3 propios de la distribución normal, lo que sugiere que ninguno de los dos grupos se aparta mucho de la normalidad.

12.1.2. Representación gráfica

El diagrama de cajas y bigotes y el diagrama de violín permiten comparar visualmente la posición, la dispersión y la forma de la distribución de `notaA` en ambos grupos.

```

ggplot(df, aes(x = sexo, y = notaA, fill = sexo)) +
  geom_boxplot() +
  scale_fill_brewer(palette = "Set2") +
  labs(x = "Sexo", y = "Nota A") +
  theme_minimal() +
  theme(legend.position = "none")

```




Figura 12.1.: Diagrama de cajas y bigotes de la nota A según el sexo.

```
ggplot(df, aes(x = sexo, y = notaA, fill = sexo)) +  
  geom_violin() +  
  scale_fill_brewer(palette = "Set2") +  
  labs(x = "Sexo", y = "Nota A") +  
  theme_minimal() +  
  theme(legend.position = "none")
```




Figura 12.2.: Diagrama de violín de la nota A según el sexo.

Ambos gráficos muestran cajas y formas muy similares en los dos grupos, sin apenas solapamiento asimétrico ni valores atípicos destacados, lo que anticipa que es poco probable encontrar diferencias relevantes entre ambos grupos.

12.1.3. Comprobación de la normalidad

Antes de decidir entre un contraste paramétrico (test t) o no paramétrico (test U de Mann-Whitney) hay que comprobar la normalidad de **notaA en cada grupo por separado**, con el test de Shapiro-Wilk visto en el capítulo de [contrastes para una población](#):

```
df %>%
  group_by(sexo) %>%
  summarise(
    n = n(),
    `p-valor` = shapiro.test(notaA)$p.value
  )
```

```
# A tibble: 2 x 3
  sexo      n `p-valor`
  <chr> <int>   <dbl>
1 Hombre   71    0.872
2 Mujer   49    0.942
```

En ambos grupos el p-valor del test de Shapiro-Wilk es muy superior a 0.05 (0.872 en hombres y 0.942 en mujeres), por lo que no hay evidencia para rechazar la normalidad de `notaA` en ninguno de los dos grupos. Se cumple, por tanto, el requisito para aplicar los contrastes paramétricos (test F y test t) que se muestran a continuación.

12.1.4. Test F de Fisher de comparación de varianzas

Definición 12.1 (Test F de Fisher de comparación de varianzas). El *test F de Fisher* contrasta si las varianzas de una variable cuantitativa son iguales en dos poblaciones independientes. La hipótesis nula es

$$H_0 : \sigma_1^2 = \sigma_2^2$$

frente a la hipótesis alternativa $H_1 : \sigma_1^2 \neq \sigma_2^2$.

Requisitos: la variable dependiente debe ser cuantitativa y seguir una distribución normal en ambas poblaciones (o, alternativamente, cada grupo debe tener un tamaño muestral $n \geq 30$).

Comprobada la normalidad de `notaA` en ambos grupos, puede aplicarse el test F para decidir si, a la hora de comparar las medias, debe asumirse o no que las varianzas poblacionales son iguales.

Ejemplo 12.1.

```
var.test(notaA ~ sexo, data = df)
```

```
F test to compare two variances
```

```
data: notaA by sexo
```

```
F = 0.6769, num df = 70, denom df = 48, p-value = 0.1347
```

```
alternative hypothesis: true ratio of variances is not equal to 1
```

```
95 percent confidence interval:
```

```
0.3953421 1.1293155
```

```
sample estimates:
```

```
ratio of variances
```

```
0.6769032
```

El p-valor del contraste es 0.1347, superior a 0.05, por lo que no se rechaza la hipótesis nula: no hay evidencia de que las varianzas de `notaA` difieran entre hombres y mujeres, y puede asumirse la igualdad de varianzas al aplicar el test t de comparación de medias.

12.1.5. Test t de comparación de medias de poblaciones independientes

Definición 12.2 (Test t de comparación de medias de poblaciones independientes). El *test t de comparación de medias de poblaciones independientes* contrasta si las medias de una variable cuantitativa normal son iguales en dos poblaciones independientes. La hipótesis nula es

$$H_0 : \mu_1 = \mu_2$$

frente a la hipótesis alternativa $H_1 : \mu_1 \neq \mu_2$ (o una alternativa unilateral, si procede).

Requisitos: la variable dependiente debe ser cuantitativa y seguir una distribución normal en ambas poblaciones (o cada grupo debe tener $n \geq 30$). El cálculo del estadístico del contraste depende, además, de si las varianzas poblacionales pueden considerarse iguales o no, lo que se determina con el test F anterior: si las varianzas son homogéneas se emplea la versión clásica del test t (`var.equal = TRUE`); si no lo son, se emplea la corrección de Welch (`var.equal = FALSE`), que es además la opción por defecto en R y una elección razonable siempre que exista alguna duda sobre la igualdad de varianzas.

Como el test F no ha encontrado diferencias significativas entre las varianzas, cabría esperar que ambas versiones del test t den resultados muy parecidos. Se aplica el test t con la corrección de Welch, más conservadora y por tanto más segura como opción por defecto:

Ejemplo 12.2.

```
t.test(notaA ~ sexo, data = df, alternative = "two.sided", var.equal = FALSE)
```

Welch Two Sample t-test

```
data: notaA by sexo
t = 0.89364, df = 89.873, p-value = 0.3739
alternative hypothesis: true difference in means between group Hombre and group Mujer is
95 percent confidence interval:
 -0.2821809  0.7435779
sample estimates:
mean in group Hombre mean in group Mujer
      6.122535         5.891837
```

El p-valor es 0.3739, muy superior a 0.05, por lo que no se rechaza H_0 : no hay evidencia de que la nota media de la primera prueba difiera entre hombres y mujeres. Si se repite el contraste asumiendo varianzas iguales (`var.equal = TRUE`), el resultado es prácticamente idéntico ($t = 0.926$, $p = 0.3563$), como cabía esperar tras el resultado del test F.

El siguiente diagrama de medias, con el intervalo de confianza al 95 % de la media en cada grupo, ilustra gráficamente la conclusión del contraste: los dos intervalos se solapan ampliamente, coherente con la ausencia de diferencias significativas.

```
media_ic <- function(x) {
  m <- mean(x)
  error <- qt(0.975, df = length(x) - 1) * sd(x) / sqrt(length(x))
  data.frame(y = m, ymin = m - error, ymax = m + error)
}

ggplot(df, aes(x = sexo, y = notaA, color = sexo)) +
  stat_summary(fun = "mean", geom = "point", size = 3) +
  stat_summary(fun.data = media_ic, geom = "pointrange") +
  labs(x = "Sexo", y = "Nota A media") +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 12.3.: Media de la nota A por sexo, con su intervalo de confianza al 95 %.

12.1.6. Test U de Mann-Whitney

Definición 12.3 (Test U de Mann-Whitney). El *test U de Mann-Whitney* (también llamado test de la suma de rangos de Wilcoxon) contrasta si las distribuciones de una variable cuantitativa o cualitativa ordinal son iguales en dos poblaciones independientes,

sin necesidad de asumir normalidad. Cuando las dos distribuciones tienen la misma forma y dispersión, el contraste equivale a comparar sus medianas. La hipótesis nula es

H_0 : las distribuciones de las dos poblaciones son iguales

frente a la alternativa de que una de las poblaciones tiende a presentar valores sistemáticamente más altos (o más bajos) que la otra.

Requisitos: la variable dependiente debe ser, al menos, cualitativa ordinal (o cuantitativa), y las dos poblaciones deben ser independientes. No exige que la variable siga una distribución normal, por lo que es la alternativa natural al test t cuando no se cumple ese requisito.

Aunque en este caso `notaA` es normal en ambos grupos y el test t es aplicable, se muestra también el test U de Mann-Whitney a modo ilustrativo, ya que sería la opción adecuada si la normalidad no se hubiera cumplido:

Ejemplo 12.3.

```
wilcox.test(notaA ~ sexo, data = df, alternative = "two.sided")
```

Wilcoxon rank sum test with continuity correction

data: notaA by sexo

W = 1917, p-value = 0.3445

alternative hypothesis: true location shift is not equal to 0

El p-valor es 0.3445, superior a 0.05, por lo que tampoco con este contraste no paramétrico se rechaza la hipótesis nula: la distribución de `notaA` no difiere significativamente entre hombres y mujeres, confirmando la conclusión alcanzada con el test t.

12.2. Variable dependiente cualitativa

Cuando la variable dependiente es cualitativa, el interés no está en comparar medias sino en comparar **proporciones**, o, de forma equivalente, en contrastar si existe **asociación** entre las dos variables cualitativas. Como ejemplo se compara el resultado (Aprobado / Suspenso) de la primera prueba, `calificacionA`, entre hombres y mujeres.

La tabla de contingencia entre `sexo` y `calificacionA`, y las proporciones de aprobados dentro de cada sexo, son las siguientes:

```
tabla <- table(df$sexo, df$calificacionA)
tabla
```

	Aprobado	Suspenso
Hombre	58	13
Mujer	36	13

```
prop.table(tabla, margin = 1)
```

	Aprobado	Suspenso
Hombre	0.8169014	0.1830986
Mujer	0.7346939	0.2653061

El 81.7 % de los hombres aprueba la primera prueba, frente al 73.5 % de las mujeres. La pregunta que responden los contrastes de esta sección es si esa diferencia de casi 8 puntos porcentuales es lo bastante grande como para no poder explicarse por el azar del muestreo, o si, por el contrario, es compatible con que en la población no exista ninguna diferencia real entre sexos.

12.2.1. Test Chi-cuadrado de independencia

Definición 12.4 (Test Chi-cuadrado de independencia). El *test Chi-cuadrado de independencia* contrasta si existe relación (asociación) entre dos variables cualitativas, o, de forma equivalente cuando una de ellas define dos poblaciones, si las proporciones de las categorías de la otra variable son iguales en ambas poblaciones. La hipótesis nula es

H_0 : las dos variables son independientes (no hay asociación entre ellas)

Requisitos: las dos variables deben ser cualitativas, y no más del 20 % de las frecuencias esperadas de la tabla de contingencia debe ser inferior a 5 (ninguna frecuencia esperada debe ser, además, inferior a 1).

Ejemplo 12.4.

```
chi <- chisq.test(tabla)
chi
```

Pearson's Chi-squared test with Yates' continuity correction

```
data:  tabla  
X-squared = 0.72085, df = 1, p-value = 0.3959
```

```
chi$expected
```

	Aprobado	Suspenso
Hombre	55.61667	15.38333
Mujer	38.38333	10.61667

Las cuatro frecuencias esperadas de la tabla (55.6, 15.4, 38.4 y 10.6) son todas superiores a 5, por lo que se cumple el requisito de aplicación del test. El p-valor obtenido, con la corrección de continuidad de Yates propia de las tablas 2x2, es 0.3959, muy superior a 0.05, por lo que no se rechaza la hipótesis nula: no hay evidencia de asociación entre el sexo y el resultado de la primera prueba, es decir, la proporción de aprobados no difiere significativamente entre hombres y mujeres.

12.2.2. Test exacto de Fisher

Definición 12.5 (Test exacto de Fisher). El *test exacto de Fisher* contrasta la misma hipótesis de independencia que el test Chi-cuadrado, pero calculando de forma exacta (sin aproximación asintótica) la probabilidad de las tablas de contingencia al menos tan extremas como la observada. La hipótesis nula es la misma que la del test Chi-cuadrado:

H_0 : las dos variables son independientes (no hay asociación entre ellas)

Es la alternativa recomendada, especialmente en tablas 2x2, cuando no se cumple el requisito de frecuencias esperadas del test Chi-cuadrado (muestras pequeñas).

Requisitos: las dos variables deben ser cualitativas. A diferencia del test Chi-cuadrado, no exige ninguna condición sobre las frecuencias esperadas, por lo que es válido con cualquier tamaño muestral.

Ejemplo 12.5.

```
fisher.test(tabla)
```

Fisher's Exact Test for Count Data

```
data:  tabla
p-value = 0.3677
alternative hypothesis: true odds ratio is not equal to 1
95 percent confidence interval:
 0.609684 4.234633
sample estimates:
odds ratio
 1.604498
```

El p-valor del test exacto de Fisher es 0.3677, muy similar al obtenido con el test Chi-cuadrado (0.3959) y, de nuevo, muy superior a 0.05: no se rechaza la hipótesis nula de independencia. Este parecido entre ambos resultados es el esperable, ya que las frecuencias esperadas de la tabla de contingencia eran, como se comprobó antes, suficientemente grandes para que el test Chi-cuadrado fuera fiable; el test exacto de Fisher habría sido la opción obligada, en cambio, de haber tenido frecuencias esperadas por debajo de 5.

12.3. Resumen

En los cinco contrastes de este capítulo, ninguno ha encontrado diferencias estadísticamente significativas entre hombres y mujeres, ni en la nota media de la primera prueba ni en la proporción de aprobados, lo que es coherente con lo observado en las descriptivas y los gráficos iniciales: los dos grupos se comportan, en esta asignatura, de forma muy similar.

Todos los contrastes anteriores exigen que las dos poblaciones comparadas estén formadas por individuos distintos, es decir, que sean independientes. Cuando en cambio se comparan los mismos individuos medidos en dos ocasiones (por ejemplo, la nota de un mismo alumno en dos pruebas distintas, `notaA` y `notaB`), las poblaciones están pareadas y los contrastes anteriores dejan de ser válidos, siendo necesario recurrir a sus versiones para datos pareados, que se desarrollan en el capítulo de [Contrastes para dos poblaciones pareadas](#). Y cuando la variable independiente tiene más de dos categorías (por ejemplo, comparar la nota media entre los tres grupos de clase, A, B y C), es necesario recurrir a los contrastes que se desarrollan en el capítulo de [Contrastes para más de dos poblaciones independientes](#).

13. Contrastes para dos poblaciones pareadas

En el [capítulo anterior](#) las dos poblaciones comparadas estaban formadas por individuos distintos: por ejemplo, un grupo de hombres y un grupo de mujeres, sin ninguna relación entre las observaciones de un grupo y las del otro. Sin embargo, en muchos estudios las dos poblaciones que se comparan no son independientes, sino que están **pareadas** o **relacionadas**: los mismos individuos se miden dos veces, por ejemplo antes y después de una intervención, o en dos condiciones, momentos o pruebas distintas. En ese caso cada individuo aporta un **par de valores relacionados entre sí**, y esa relación debe tenerse en cuenta al elegir el contraste, porque ignorarla (tratando los datos como si procedieran de dos grupos independientes) desaprovecha información y puede llevar a conclusiones erróneas.

En el conjunto de datos del curso, `notaA` y `notaB` son las calificaciones obtenidas por los mismos 120 alumnos en dos asignaturas distintas, por lo que cada alumno aporta un par de notas relacionadas entre sí (un alumno con buen rendimiento tenderá a obtener buenas notas en ambas asignaturas). Lo mismo ocurre con `calificacionA` y `calificacionB`, la versión cualitativa (Aprobado / Suspenso) de esas mismas dos calificaciones. Este capítulo presenta los contrastes adecuados para este tipo de comparaciones, distinguiendo según si la variable dependiente es cuantitativa o cualitativa.


13.1. Variable dependiente cuantitativa: comparar `notaA` con `notaB`

Antes de plantear ningún contraste conviene visualizar la relación entre las dos notas de cada alumno, precisamente para comprobar que están pareadas y no son dos muestras independientes.

```
ggplot(df, aes(x = notaA, y = notaB)) +  
  geom_point(alpha = 0.6, color = "steelblue") +  
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "darkred") +  
  labs(  
    title = "Nota de la asignatura A frente a la nota de la asignatura B",  
    subtitle = "por alumno; la línea discontinua marca la igualdad notaA = notaB",  
    x = "notaA",
```

```
y = "notaB"
) +
theme_minimal()
```

Nota de la asignatura A frente a la nota de la asignatura B
por alumno; la línea discontinua marca la igualdad $\text{notaA} = \text{notaB}$



```
cor(df$notaA, df$notaB, use = "complete.obs")
```

```
[1] 0.8104926
```

La correlación entre **notaA** y **notaB** es de 0.81: un alumno con una nota alta en la asignatura A tiende a tener también una nota alta en la B, lo que confirma que ambas notas están relacionadas y proceden de los mismos individuos, y no de dos grupos de alumnos distintos. En el diagrama de dispersión se observa además que la mayoría de los puntos quedan por debajo de la línea discontinua $\text{notaA} = \text{notaB}$ (92 de los 115 alumnos con ambas notas), es decir, que la mayoría de los alumnos obtiene una nota más alta en B que en A. Precisamente por existir esta relación entre las dos mediciones, el contraste debe tener en cuenta el emparejamiento en lugar de tratar **notaA** y **notaB** como si procedieran de dos poblaciones independientes.

Para comparar las notas de la asignatura A y de la asignatura B de los mismos alumnos conviene empezar creando la variable que resume, para cada alumno, la diferencia entre ambas notas:

```
df <- df %>% mutate(diferencia_AB = notaA - notaB)
```

Esta variable `diferencia_AB` es la clave de todo este apartado: un contraste sobre dos poblaciones pareadas puede plantearse de forma equivalente como un contraste sobre esta única variable diferencia frente al valor 0, exactamente igual que los contrastes sobre la media o la mediana de una sola población que se vieron en el capítulo de [contrastes para una población](#). Si no hay diferencia real entre las dos asignaturas, la diferencia `diferencia_AB` debería distribuirse en torno a 0; si una de las dos asignaturas tiende a puntuar más alto que la otra, la diferencia se desplazará sistemáticamente por encima o por debajo de 0.

Cabe señalar que cinco alumnos no tienen registrada la nota de la asignatura B (son valores perdidos, NA), por lo que la diferencia también queda como NA en esos cinco casos. Todos los análisis siguientes se basan, por tanto, en los 115 alumnos con datos completos en ambas asignaturas.

Estadísticos descriptivos de la diferencia

```
library(moments)

df %>%
  summarise(
    n = sum(!is.na(diferencia_AB)),
    media = mean(diferencia_AB, na.rm = TRUE),
    dt = sd(diferencia_AB, na.rm = TRUE),
    minimo = min(diferencia_AB, na.rm = TRUE),
    Q1 = quantile(diferencia_AB, 0.25, na.rm = TRUE),
    mediana = median(diferencia_AB, na.rm = TRUE),
    Q3 = quantile(diferencia_AB, 0.75, na.rm = TRUE),
    maximo = max(diferencia_AB, na.rm = TRUE),
    asimetria = skewness(diferencia_AB, na.rm = TRUE),
    apuntamiento = kurtosis(diferencia_AB, na.rm = TRUE)
  )
```

```
# A tibble: 1 x 10
```


	n	media	dt	minimo	Q1	mediana	Q3	maximo	asimetria	apuntamiento
	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	115	-0.882	0.900	-3.2	-1.5	-0.8	-0.300	1.10	-0.430	2.86

Sobre los 115 alumnos con ambas notas, la diferencia `notaA - notaB` tiene una media de -0.88 y una desviación típica de 0.90, con un mínimo de -3.2 y un máximo de 1.1 (cuartiles -1.5, -0.8 y -0.3). El hecho de que la media y la mediana sean negativas indica que, en general, los alumnos obtienen una nota más alta en la asignatura B que en la A.

El coeficiente de asimetría, -0.43, muestra una ligera asimetría negativa (cola algo más larga hacia valores muy negativos), y el apuntamiento, 2.86, es muy próximo a 3, el valor de referencia de la distribución normal, lo que no sugiere colas especialmente pesadas ni ligeras.

Gráficos

```
ggplot(df, aes(y = diferencia_AB)) +  
  geom_boxplot(fill = "steelblue", alpha = 0.6) +  
  labs(  
    title = "Diagrama de caja y bigotes de la diferencia notaA - notaB",  
    y = "Diferencia (notaA - notaB)"  
  ) +  
  theme_minimal()
```



El diagrama de caja confirma lo observado en los estadísticos descriptivos: la caja se sitúa casi por completo por debajo de 0, sin valores atípicos, lo que refuerza la idea de que la mayoría de los alumnos sacan mejor nota en la asignatura B que en la A.

Test de normalidad de Shapiro-Wilk sobre la diferencia

```
shapiro.test(df$diferencia_AB)
```

Shapiro-Wilk normality test


```
data: df$diferencia_AB  
W = 0.9794, p-value = 0.07367
```

El test de Shapiro-Wilk proporciona un p-valor de 0.074, mayor que 0.05, por lo que no se rechaza la hipótesis nula de normalidad: puede asumirse que la diferencia `diferencia_AB` sigue una distribución aproximadamente normal. Este resultado, junto con el hecho de disponer de $n = 115$ pares (muy por encima de 30), respalda el uso del test t para datos pareados que se presenta a continuación.

13.1.1. Test t para datos pareados

Definición 13.1 (Test t para datos pareados). El *test t para datos pareados* contrasta si existe diferencia entre las medias de dos poblaciones pareadas, es decir, medidas sobre los mismos individuos. Si D es la variable que recoge, para cada individuo, la diferencia entre sus dos mediciones, y μ_D es la media poblacional de esa diferencia, el contraste plantea las hipótesis

$$H_0 : \mu_D = 0 \quad \text{frente a} \quad H_1 : \mu_D \neq 0,$$

siendo H_0 equivalente a afirmar que las medias de las dos poblaciones pareadas, μ_1 y μ_2 , coinciden.

Requisitos:

- La variable dependiente es cuantitativa y se mide dos veces sobre los mismos individuos (o sobre pares de individuos emparejados según algún criterio).
- La variable diferencia D sigue una distribución normal, o bien el tamaño muestral es suficientemente grande ($n \geq 30$) para que el teorema central del límite garantice la normalidad aproximada de la media de las diferencias.

En el ejemplo, la diferencia `diferencia_AB` no se ha podido rechazar como normal (Shapiro-Wilk, $p = 0.074$) y además se dispone de $n = 115$ pares, por lo que se cumplen ambos requisitos y puede aplicarse con garantías el test t para datos pareados para comparar las notas medias de los mismos alumnos en las asignaturas A y B.

Ejemplo 13.1.


```
t.test(df$notaA, df$notaB, alternative = "two.sided", paired = TRUE)
```

Paired t-test

```
data: df$notaA and df$notaB
t = -10.506, df = 114, p-value < 2.2e-16
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -1.048005 -0.715473
sample estimates:
mean difference
 -0.8817391
```

```
media_ic <- function(x) {
  x <- x[!is.na(x)]
  m <- mean(x)
  ee <- sd(x) / sqrt(length(x))
  ic <- qt(0.975, df = length(x) - 1) * ee
  data.frame(y = m, ymin = m - ic, ymax = m + ic)
}

ggplot(df, aes(x = "", y = diferencia_AB)) +
  stat_summary(fun.data = media_ic, geom = "errorbar", width = 0.2, color = "darkred") +
  stat_summary(fun = mean, geom = "point", size = 3, color = "darkred") +
  labs(
    title = "Media e intervalo de confianza al 95% de la diferencia notaA - notaB",
    x = NULL,
    y = "Diferencia (notaA - notaB)"
  ) +
  theme_minimal()
```



El test t para datos pareados proporciona un estadístico $t = -10.51$ con 114 grados de libertad y un p -valor menor que 2.2×10^{-16} , muy inferior a 0.05, por lo que se rechaza la hipótesis nula $H_0 : \mu_D = 0$. La media estimada de la diferencia es -0.88, con un intervalo de confianza al 95 % de $(-1.05, -0.72)$, que no contiene el 0. Se concluye, por tanto, que existe una diferencia significativa entre las notas medias de las asignaturas A y B para los mismos alumnos, siendo la nota media de la asignatura B significativamente superior a la de la asignatura A.

13.1.2. Test de Wilcoxon para datos pareados

Definición 13.2 (Test de Wilcoxon para datos pareados). El *test de Wilcoxon para datos pareados* (o test de los rangos con signo de Wilcoxon) es la alternativa no paramétrica al test t para datos pareados. Contrasta si existe diferencia entre las distribuciones (habitualmente interpretada como diferencia entre las medianas) de dos poblaciones pareadas, sin necesidad de asumir normalidad de la diferencia. La hipótesis nula es

$$H_0 : \text{la distribución de las diferencias es simétrica en torno a } 0$$

frente a la alternativa de que existe un desplazamiento sistemático de las diferencias por encima o por debajo de 0.

Requisitos:

- La variable dependiente es cuantitativa (o al menos ordinal) y se mide dos veces sobre los mismos individuos.

- No se requiere que la diferencia siga una distribución normal, lo que lo hace preferible al test t para datos pareados cuando ese supuesto no se cumple o el tamaño muestral es pequeño.

Aunque en el ejemplo anterior la diferencia `diferencia_AB` pudo asumirse normal y el test t era plenamente aplicable, se ilustra a continuación su alternativa no paramétrica, útil como contraste de robustez o para las situaciones en las que la normalidad de la diferencia no pueda asumirse.

Ejemplo 13.2.

```
wilcox.test(df$notaA, df$notaB, alternative = "two.sided", paired = TRUE)
```

Wilcoxon signed rank test with continuity correction

data: df\$notaA and df\$notaB

V = 398, p-value = 2.442e-15

alternative hypothesis: true location shift is not equal to 0

El test de Wilcoxon para datos pareados proporciona un estadístico $V = 398$ y un p-valor de 2.44×10^{-15} , muy inferior a 0.05, por lo que se rechaza la hipótesis nula de simetría de las diferencias en torno a 0. La conclusión coincide con la del test t: existe una diferencia significativa entre las calificaciones de los mismos alumnos en las asignaturas A y B.

13.2. Variable dependiente cualitativa: comparar calificacionA con calificacionB

Las variables `calificacionA` y `calificacionB` recogen, para los mismos 120 alumnos, el resultado cualitativo (Aprobado / Suspenso) de las asignaturas A y B. Al tratarse de la misma pareja de alumnos medidos dos veces con una variable cualitativa binaria, no puede aplicarse aquí un contraste de independencia habitual, sino uno diseñado específicamente para datos pareados.

13.2.1. Test de McNemar

Definición 13.3 (Test de McNemar). El *test de McNemar* contrasta si la proporción de una categoría de una variable cualitativa binaria cambia entre dos mediciones pareadas realizadas sobre los mismos individuos. Si b es el número de individuos que pasan de la categoría 1 a la categoría 2 entre la primera y la segunda medición, y c el número de individuos que pasan de la categoría 2 a la categoría 1, la hipótesis nula es

$$H_0 : p_b = p_c$$

es decir, que las proporciones marginales de las dos mediciones son iguales, o equivalentemente, que no hay un cambio neto entre la primera y la segunda medición (los cambios en un sentido y en el otro se compensan).

Requisitos:

- La variable dependiente es cualitativa binaria (dos categorías) y se mide dos veces sobre los mismos individuos.
- Los datos se organizan en una tabla de contingencia 2x2 **pareada**, en la que filas y columnas representan las categorías de la misma variable en la primera y en la segunda medición, y cada individuo contribuye a una única celda.

Nótese que en esta situación no puede utilizarse el test chi-cuadrado de independencia empleado en el capítulo de [contrastes para dos poblaciones independientes](#): allí las dos poblaciones comparadas estaban formadas por individuos distintos, de modo que cada observación era independiente de las demás, condición que exige el test chi-cuadrado. Aquí, en cambio, cada uno de los 120 alumnos aparece dos veces en la tabla (una en `calificacionA` y otra en `calificacionB`), por lo que las observaciones no son independientes entre sí, y aplicar un chi-cuadrado de independencia estándar sería incorrecto. El test de McNemar resuelve este problema centrándose únicamente en los alumnos que cambian de categoría entre las dos mediciones.

Ejemplo 13.3.

```
tabla <- table(df$calificacionA, df$calificacionB)
tabla
```

	Aprobado	Suspenso
Aprobado	86	3
Suspenso	12	14

```
mcnemar.test(tabla, correct = TRUE)
```

McNemar's Chi-squared test with continuity correction

```
data:  tabla
```

```
McNemar's chi-squared = 4.2667, df = 1, p-value = 0.03887
```

De los 115 alumnos con calificación registrada en ambas asignaturas, 86 aprueban las dos y 14 suspenden las dos: estos alumnos no cambian de categoría y no aportan información al contraste. De los 29 alumnos restantes, 12 suspenden la asignatura A pero aprueban la B, mientras que solo 3 aprueban la A y suspenden la B. El test de McNemar, aplicado sobre estos cambios discordantes, proporciona un estadístico $\chi^2 = 4.27$ con 1 grado de libertad y un p-valor de 0.039, menor que 0.05, por lo que se rechaza la hipótesis nula de igualdad de proporciones marginales. Se concluye que la proporción de aprobados no es la misma en la asignatura A que en la B para los mismos alumnos: de hecho, la proporción de aprobados pasa del 77.4 % (89 de 115) en la asignatura A al 85.2 % (98 de 115) en la asignatura B, un aumento que resulta ser estadísticamente significativo.

13.3. Para saber más

Este capítulo ha cubierto el caso de dos mediciones pareadas. Cuando las dos poblaciones comparadas están formadas por individuos distintos, sin ninguna relación entre ellos, el contraste adecuado es el que se presenta en el capítulo de [contrastes para dos poblaciones independientes](#). Y cuando se dispone de más de dos medidas repetidas sobre los mismos individuos (por ejemplo, las cinco notas `notaA` a `notaE` de cada alumno, en lugar de solo dos), los contrastes t y de Wilcoxon para datos pareados dejan de ser aplicables y hay que recurrir a los que se presentan en el capítulo de [contrastes para más de dos poblaciones relacionadas](#).

14. Contrastes para más de dos poblaciones independientes

El [capítulo anterior](#) trató el caso de dos poblaciones independientes. Sin embargo, en muchas ocasiones no se comparan dos grupos, sino tres o más, formados por individuos distintos entre sí. Este capítulo generaliza los contrastes anteriores a esa situación: cómo comparar una variable, cuantitativa o cualitativa, entre más de dos poblaciones independientes. En el conjunto de datos de ejemplo, la variable independiente natural para esta situación es `grupo`, que clasifica a los 120 alumnos en tres grupos de clase (A, B y C), formados por alumnos distintos: nadie pertenece a la vez a dos grupos, por lo que las tres poblaciones son independientes entre sí.

14.1. Estadísticos descriptivos por grupo

Antes de aplicar ningún contraste, conviene describir la variable cuantitativa de interés en cada uno de los grupos. Se utiliza aquí la variable `notaC`, que es la que muestra diferencias más claras entre los tres grupos de clase.

```
library(moments)

df |>
  group_by(grupo) |>
  summarise(
    n = sum(!is.na(notaC)),
    media = mean(notaC, na.rm = TRUE),
    de = sd(notaC, na.rm = TRUE),
    minimo = min(notaC, na.rm = TRUE),
    q1 = quantile(notaC, 0.25, na.rm = TRUE),
    mediana = median(notaC, na.rm = TRUE),
    q3 = quantile(notaC, 0.75, na.rm = TRUE),
    maximo = max(notaC, na.rm = TRUE),
    asimetria = skewness(notaC, na.rm = TRUE),
    apuntamiento = kurtosis(notaC, na.rm = TRUE)
  )
```

```
# A tibble: 3 x 11
  grupo      n media  de minimo  q1 mediana  q3 maximo asimetria
  <chr> <int> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 A      38  5.52  1.51    2    4.6   5.55  6.5   9.5   0.0121
2 B      34  5.95  1.35    2.8  5.3    6    6.9   8.8  -0.473
3 C      47  4.07  1.38    1.3  3.3    4    5.1   6.7  -0.0272
# i 1 more variable: apuntamiento <dbl>
```

El grupo C presenta la media más baja (4.07) y los grupos A y B medias parecidas y más altas (5.52 y 5.95, respectivamente), lo que ya sugiere que podría existir una diferencia real entre C y los otros dos grupos. Las tres distribuciones tienen una asimetría cercana a 0 y un apuntamiento próximo a 3, lo que es compatible con una distribución aproximadamente normal en los tres grupos.

Gráficos. Un diagrama de cajas y bigotes y un diagrama de violín permiten visualizar de un vistazo estas diferencias:

```
ggplot(df, aes(x = grupo, y = notaC, fill = grupo)) +
  geom_boxplot() +
  labs(x = "Grupo", y = "Nota C") +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 14.1.: Diagrama de cajas y bigotes de la nota C por grupo.


```
ggplot(df, aes(x = grupo, y = notaC, fill = grupo)) +
  geom_violin() +
  labs(x = "Grupo", y = "Nota C") +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 14.2.: Diagrama de violín de la nota C por grupo.

En ambos gráficos se aprecia que el grupo C tiene una posición más baja que A y B, y que las cajas de A y B se solapan bastante, mientras que la de C apenas se solapa con ellas.

Normalidad por grupo. Antes de decidir qué contraste aplicar (paramétrico o no paramétrico), es necesario comprobar si `notaC` sigue una distribución normal en cada uno de los tres grupos, mediante el test de Shapiro-Wilk:

```
df |>
  filter(!is.na(notaC)) |>
  group_by(grupo) |>
  summarise(
    estadistico = shapiro.test(notaC)$statistic,
    p.valor = shapiro.test(notaC)$p.value
  )
```

```
# A tibble: 3 x 3
  grupo estadistico p.valor
  <chr>      <dbl>    <dbl>
1 A          0.989    0.961
2 B          0.965    0.343
3 C          0.976    0.442
```

En los tres grupos el p-valor es muy superior a 0.05 (0.9614 en A, 0.3432 en B y 0.4420 en C), por lo que no hay evidencia para rechazar la normalidad de **notaC** en ninguno de ellos. Se cumple, por tanto, el requisito de normalidad necesario para aplicar los contrastes paramétricos que siguen.

14.1.1. Test de Levene de comparación de varianzas

Definición 14.1 (Test de Levene de comparación de varianzas). El *test de Levene* tiene como objetivo contrastar si las varianzas de una variable cuantitativa son iguales en más de dos poblaciones independientes. Es la generalización a más de dos grupos del test F de Fisher visto en el capítulo anterior. Las hipótesis del contraste son

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 \quad \text{frente a} \quad H_1 : \text{algún } \sigma_i^2 \text{ es distinto de los demás,}$$

donde k es el número de poblaciones comparadas.

Interpretación

- Si el p-valor del contraste es mayor que el nivel de significación (habitualmente 0.05), no se rechaza H_0 y se concluye que las varianzas de los k grupos pueden considerarse homogéneas.
- Si el p-valor es menor que el nivel de significación, se rechaza H_0 y se concluye que al menos uno de los grupos tiene una varianza distinta de las demás.
- Comprobar la homogeneidad de varianzas es un paso previo necesario para poder aplicar después el ANOVA de un factor, ya que este último asume que las varianzas de los grupos son iguales.

Requisitos:

- La variable comparada debe ser cuantitativa.
- Las poblaciones comparadas deben ser independientes entre sí (individuos distintos en cada grupo).
- La variable debe seguir una distribución normal en todos los grupos, o bien el tamaño de cada grupo debe ser igual o superior a 30 (en cuyo caso el teorema central del límite garantiza una aproximación razonable).

Comprobada la normalidad de `notaC` en los tres grupos, se puede aplicar el test de Levene con la función `leveneTest()` del paquete `car` para contrastar si las tres poblaciones tienen la misma varianza.

Ejemplo 14.1.

```
library(car)

df <- df |> mutate(grupo = factor(grupo))
leveneTest(notaC ~ grupo, data = df)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  2  0.3186 0.7278
116
```

El p-valor del contraste es 0.7278, muy superior a 0.05, por lo que no se rechaza H_0 : no hay evidencia de que las varianzas de `notaC` difieran entre los tres grupos de clase. Se cumple, por tanto, el requisito de homogeneidad de varianzas necesario para aplicar el ANOVA de un factor.

14.1.2. ANOVA de un factor

Definición 14.2 (ANOVA de un factor). El *análisis de varianza (ANOVA) de un factor* tiene como objetivo contrastar si existen diferencias entre las medias de una variable cuantitativa en más de dos poblaciones independientes. Las hipótesis del contraste son

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad \text{frente a} \quad H_1 : \text{alguna } \mu_i \text{ es distinta de las demás,}$$

donde k es el número de poblaciones comparadas.

Interpretación

- Si el p-valor del contraste es mayor que 0.05, no se rechaza H_0 y se concluye que no hay evidencia de diferencias entre las medias de los k grupos.
- Si el p-valor es menor que 0.05, se rechaza H_0 y se concluye que al menos una de las medias difiere de las demás, aunque el ANOVA por sí solo no indica cuál o cuáles.
- El ANOVA de un factor es la generalización a más de dos grupos del test t de comparación de medias visto en el capítulo anterior: de hecho, cuando $k = 2$, ambos contrastes son equivalentes.

Requisitos:

- La variable dependiente debe ser cuantitativa.
- Las poblaciones comparadas deben ser independientes entre sí.
- La variable debe seguir una distribución normal en cada uno de los grupos, o los grupos deben tener un tamaño igual o superior a 30.
- Las varianzas de los grupos deben ser homogéneas, requisito que se comprueba previamente con el test de Levene.

Como se cumplen los requisitos de normalidad y homogeneidad de varianzas, se puede aplicar el ANOVA de un factor con la función `aov()` para contrastar si existen diferencias entre las medias de `notaC` en los tres grupos.

Ejemplo 14.2.

```
modelo_anova <- aov(notaC ~ grupo, data = df)
summary(modelo_anova)
```

```

              Df Sum Sq Mean Sq F value    Pr(>F)
grupo           2  80.69   40.34   20.05 3.32e-08 ***
Residuals     116 233.41     2.01
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
1 observation deleted due to missingness
```

El p-valor del contraste ($\Pr(>F)$) es 3.32e-08, muy inferior a 0.05, por lo que se rechaza H_0 : existen diferencias significativas entre las medias de `notaC` en al menos dos de los tres grupos de clase.

Cuando, como en este caso, el ANOVA resulta significativo, este solo informa de que existe alguna diferencia entre los grupos, pero no indica entre cuáles. Es necesario entonces aplicar un **test de comparación múltiple por pares** que compare las medias de los grupos dos a dos, controlando el error global de realizar varias comparaciones simultáneas. El más habitual es el **test de Tukey** (`TukeyHSD()`), aunque también se utiliza, de forma algo más conservadora, la corrección de **Bonferroni**, que simplemente divide el nivel de significación entre el número de comparaciones realizadas.

```
TukeyHSD(modelo_anova)
```

```

Tukey multiple comparisons of means
 95% family-wise confidence level
```

```
Fit: aov(formula = notaC ~ grupo, data = df)
```

		diff	lwr	upr	p adj
B-A	0.4312693	-0.3637573	1.2262960	0.4048482	
C-A	-1.4455767	-2.1802858	-0.7108676	0.0000241	
C-B	-1.8768461	-2.6350758	-1.1186163	0.0000001	

Los resultados muestran que la diferencia entre B y A no es significativa (p-valor 0.4048), mientras que las diferencias entre C y A (p-valor 0.0000241) y entre C y B (p-valor 0.0000001) sí lo son. Es decir, el grupo C tiene una nota media en **notaC** significativamente inferior a la de los otros dos grupos, mientras que A y B no difieren significativamente entre sí.

Un diagrama de medias con sus intervalos de confianza al 95 % permite visualizar estas mismas conclusiones:

```
mean_ci <- function(x) {
  x <- x[!is.na(x)]
  m <- mean(x)
  se <- sd(x) / sqrt(length(x))
  ic <- se * qt(0.975, length(x) - 1)
  data.frame(y = m, ymin = m - ic, ymax = m + ic)
}

ggplot(df, aes(x = grupo, y = notaC, color = grupo)) +
  stat_summary(fun.data = mean_ci, geom = "errorbar", width = 0.2) +
  stat_summary(fun = mean, geom = "point", size = 3) +
  labs(x = "Grupo", y = "Nota C media") +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 14.3.: Medias de la nota C por grupo con intervalos de confianza al 95 %.

En el gráfico se aprecia que los intervalos de confianza de A y B se solapan ampliamente, mientras que el de C queda claramente por debajo y no se solapa con los de los otros dos grupos, en consonancia con el resultado del test de Tukey.

14.1.3. Test de Kruskal-Wallis (no paramétrico)

Definición 14.3 (Test de Kruskal-Wallis). El *test de Kruskal-Wallis* es la alternativa no paramétrica al ANOVA de un factor. Tiene como objetivo contrastar si las distribuciones de una variable cuantitativa u ordinal son iguales en más de dos poblaciones independientes, sin necesidad de asumir normalidad. Las hipótesis del contraste son

H_0 : las distribuciones (medianas) son iguales en las k poblaciones frente a H_1 : alguna difiere de las demás.

i Interpretación

- Si el p-valor del contraste es mayor que 0.05, no se rechaza H_0 y se concluye que no hay evidencia de diferencias entre las distribuciones de los k grupos.
- Si el p-valor es menor que 0.05, se rechaza H_0 y se concluye que al menos una de las distribuciones difiere de las demás.
- El test de Kruskal-Wallis es la generalización a más de dos grupos del test

U de Mann-Whitney visto en el capítulo anterior, del mismo modo que el ANOVA generaliza al test t.

Requisitos:

- La variable comparada debe ser, al menos, ordinal (cuantitativa o cualitativa ordinal).
- Las poblaciones comparadas deben ser independientes entre sí.
- A diferencia del ANOVA, no exige que la variable siga una distribución normal en los grupos, lo que lo convierte en la alternativa natural cuando no se cumple ese requisito o cuando la variable es solo ordinal.

Cuando no se cumple el requisito de normalidad del ANOVA (o directamente se quiere evitar esa suposición), se recurre al test de Kruskal-Wallis. A modo de ejemplo, se aplica ahora a la variable `notaA`, que no se ha comprobado que sea normal en los tres grupos:

Ejemplo 14.3.

```
kruskal.test(notaA ~ grupo, data = df)
```

Kruskal-Wallis rank sum test

data: notaA by grupo

Kruskal-Wallis chi-squared = 62.218, df = 2, p-value = 3.087e-14

El p-valor del contraste es 3.087e-14, muy inferior a 0.05, por lo que se rechaza H_0 : existen diferencias significativas entre las distribuciones de `notaA` en al menos dos de los tres grupos.

Igual que ocurre con el ANOVA, un resultado significativo en el test de Kruskal-Wallis no indica entre qué grupos concretos hay diferencias. El test de comparación múltiple por pares equivalente es el **test de Wilcoxon por pares**, aplicando una corrección (aquí, el método de Benjamini-Hochberg, "BH") para controlar el error acumulado al hacer varias comparaciones:

```
pairwise.wilcox.test(df$notaA, df$grupo, p.adjust.method = "BH")
```

Pairwise comparisons using Wilcoxon rank sum test with continuity correction

data: df\$notaA and df\$grupo

	A	B
B	0.19	-
C	4.2e-10	1.3e-11

P value adjustment method: BH

La diferencia entre A y B no es significativa (p-valor 0.19), mientras que las diferencias entre A y C (p-valor 4.2e-10) y entre B y C (p-valor 1.3e-11) sí lo son. La conclusión es, por tanto, coherente con la obtenida antes para **notaC**: el grupo C se diferencia claramente de los otros dos, que no difieren significativamente entre sí.

14.2. Variable dependiente cualitativa

Cuando la variable dependiente es cualitativa y se compara entre más de dos poblaciones independientes, el contraste apropiado sigue siendo el **test Chi-cuadrado de independencia**, ya presentado en el capítulo de [Contrastes para dos poblaciones independientes](#). Allí se aplicaba a una tabla de contingencia 2×2 , construida cruzando una variable independiente con dos categorías y una variable dependiente también con dos categorías; aquí la única diferencia es que la tabla de contingencia tiene más de dos filas (o más de dos columnas), al tener **grupo** tres categorías en lugar de dos.

Así, para contrastar si existe relación entre el grupo de clase y el resultado (aprobado o suspenso) en la asignatura A, bastaría con construir la tabla de contingencia `table(df$grupo, df$calificacionA)`, de dimensión 3×2 , y aplicar sobre ella `chisq.test()` exactamente igual que en el caso de dos grupos. El estadístico de contraste, sus grados de libertad (que ahora dependen del número de filas y columnas de la tabla) y la interpretación del p-valor obtenido no cambian en absoluto respecto al procedimiento ya descrito para dos poblaciones independientes.

14.3. Cierre

Este capítulo ha mostrado cómo comparar más de dos poblaciones independientes, tanto cuando la variable dependiente es cuantitativa (Levene, ANOVA y Tukey, o su alternativa no paramétrica, Kruskal-Wallis con comparaciones de Wilcoxon por pares) como cuando es cualitativa (Chi-cuadrado de independencia). El siguiente capítulo, [Contrastes para más de dos poblaciones relacionadas](#), trata la situación análoga pero cuando los más de dos grupos comparados no están formados por individuos distintos, sino que son medidas repetidas tomadas sobre los mismos sujetos.

15. Contrastes para más de dos poblaciones relacionadas (medidas repetidas)

Este capítulo generaliza el [capítulo anterior](#), dedicado a dos poblaciones pareadas, al caso de **más de dos** medidas relacionadas tomadas sobre los mismos individuos. Corresponde a la fila de la [tabla de decisión](#) en la que la variable independiente es cualitativa con más de dos categorías, pero, a diferencia del [capítulo dedicado a poblaciones independientes](#), esas categorías no distinguen grupos de individuos distintos, sino ocasiones de medida repetidas sobre los mismos individuos. El conjunto de datos del curso dispone de cinco calificaciones distintas, `notaA`, `notaB`, `notaC`, `notaD` y `notaE`, obtenidas por los **mismos** 120 alumnos (pueden interpretarse como cinco pruebas o exámenes distintos realizados por cada alumno a lo largo del curso). Estas cinco notas no son, por tanto, cinco poblaciones independientes, sino cinco **medidas repetidas** por individuo, y esa dependencia entre ellas es la que obliga a utilizar contrastes distintos de los vistos en el capítulo anterior sobre poblaciones independientes: ignorarla y tratar las cinco notas como si procedieran de alumnos distintos infravaloraría la precisión real de las comparaciones y podría llevar a conclusiones erróneas.

15.1. Preparación de los datos: de formato ancho a formato largo

En `df`, cada alumno ocupa una única fila y cada una de sus cinco notas ocupa una columna distinta (`notaA`, ..., `notaE`): es el llamado **formato ancho**. Los contrastes de este capítulo, sin embargo, necesitan el **formato largo**, en el que cada fila representa una única combinación de alumno y prueba. Para pasar de un formato a otro se crea primero un identificador de alumno (el número de fila) y después se reorganizan las cinco columnas de notas en dos columnas nuevas, `prueba` (con el nombre de la prueba) y `nota` (con la calificación), usando `tidyr::pivot_longer()`:

```
df_largo <- df %>%
  mutate(alumno = row_number()) %>%
  select(alumno, notaA, notaB, notaC, notaD, notaE) %>%
  pivot_longer(cols = starts_with("nota"), names_to = "prueba", values_to = "nota") %>%
  mutate(prueba = factor(prueba))
```

```
head(df_largo, 10)
```

```
# A tibble: 10 x 3
  alumno prueba  nota
  <int> <fct> <dbl>
1     1 1 notaA  5.2
2     1 1 notaB  6.3
3     1 1 notaC  3.4
4     1 1 notaD  2.3
5     1 1 notaE  2
6     2 2 notaA  5.7
7     2 2 notaB  5.7
8     2 2 notaC  4.2
9     2 2 notaD  3.5
10    2 2 notaE  2.7
```

Cada alumno pasa de ocupar una fila a ocupar cinco (una por prueba), de modo que `df_largo` tiene $120 \times 5 = 600$ filas. Algunas notas son valores perdidos (10 en total, repartidos entre `notaB`, `notaC`, `notaD` y `notaE`), que se mantienen en `df_largo` y se tratarán más adelante según lo exija cada contraste.

Estadísticos descriptivos por prueba

```
df_largo %>%
  group_by(prueba) %>%
  summarise(
    n = sum(!is.na(nota)),
    media = mean(nota, na.rm = TRUE),
    dt = sd(nota, na.rm = TRUE)
  )
```

```
# A tibble: 5 x 4
  prueba      n media  dt
  <fct> <int> <dbl> <dbl>
1 notaA   120  6.03  1.34
2 notaB   115  6.81  1.54
3 notaC   119  5.07  1.63
4 notaD   118  4.12  1.68
5 notaE   118  2.70  1.80
```

La nota media desciende de forma bastante regular a lo largo del curso, de $\bar{x} = 6.03$ en la prueba A a $\bar{x} = 2.70$ en la prueba E, con desviaciones típicas parecidas entre sí

(entre 1.34 y 1.80). Esta caída progresiva de la media ya sugiere que las cinco pruebas no tienen el mismo nivel de dificultad o de exigencia, algo que los contrastes de este capítulo permitirán confirmar formalmente.

Gráficos

El diagrama de cajas y bigotes de **nota** según **prueba** permite comparar de un vistazo la posición y la dispersión de las cinco pruebas:

```
ggplot(df_largo, aes(x = prueba, y = nota, fill = prueba)) +  
  geom_boxplot() +  
  scale_fill_brewer(palette = "Set2") +  
  labs(x = "Prueba", y = "Nota") +  
  theme_minimal() +  
  theme(legend.position = "none")
```




Figura 15.1.: Diagrama de cajas y bigotes de la nota en cada una de las cinco pruebas.

Como el interés de este capítulo está en las medidas repetidas sobre los mismos individuos, conviene también visualizar la trayectoria de cada alumno a través de las cinco pruebas. Para no saturar el gráfico se representan solo los 10 primeros alumnos, junto con la trayectoria de la media general (en rojo) calculada sobre todos los alumnos:

```
ggplot(df_largo %>% filter(alumno <= 10), aes(x = prueba, y = nota)) +
  geom_line(aes(group = alumno), alpha = 0.4) +
  stat_summary(data = df_largo, aes(group = 1), fun = mean, geom = "line", color = "firebrick") +
  labs(x = "Prueba", y = "Nota") +
  theme_minimal()
```




Figura 15.2.: Trayectoria de las notas de los 10 primeros alumnos a través de las cinco pruebas, con la media general superpuesta en rojo.

Tanto las cajas como las trayectorias individuales confirman la tendencia descendente ya apuntada por las medias: la mayoría de los alumnos obtiene notas cada vez más bajas a medida que avanzan las pruebas, aunque con un orden entre alumnos que se mantiene razonablemente estable (quien saca más nota en la prueba A tiende también a sacar más nota en las siguientes).

Comprobación de la normalidad

El ANOVA de medidas repetidas que se presenta en la sección siguiente exige que la variable sea normal en cada una de las medidas repetidas. Antes de aplicarlo conviene comprobarlo, con el test de Shapiro-Wilk visto en el capítulo de [contrastes para una población](#), en cada una de las cinco pruebas por separado:

```
df_largo %>%
  group_by(prueba) %>%
```

```

summarise(
  n = sum(!is.na(nota)),
  `p-valor` = shapiro.test(nota[!is.na(nota)])$p.value
)

# A tibble: 5 x 3
  prueba      n `p-valor`
  <fct>  <int>    <dbl>
1 notaA    120  0.907
2 notaB    115  0.0675
3 notaC    119  0.412
4 notaD    118  0.575
5 notaE    118  0.00000407

```

En `notaA`, `notaB`, `notaC` y `notaD` el p-valor del test de Shapiro-Wilk es superior a 0.05 (0.907, 0.068, 0.412 y 0.575, respectivamente), por lo que no hay evidencia para rechazar la normalidad en ninguna de ellas. En `notaE`, en cambio, el p-valor es 4.07×10^{-6} , muy inferior a 0.05, por lo que se rechaza la normalidad: esta última prueba tiene una distribución claramente no normal (coherente con concentrar más alumnos suspensos en valores bajos, lo que genera asimetría). El requisito de normalidad del ANOVA de medidas repetidas no se cumple, por tanto, de forma estricta en las cinco pruebas a la vez, lo que hace especialmente pertinente comprobar también el resultado con la alternativa no paramétrica, el test de Friedman, que se presenta a continuación.

15.2. Comparación de las medidas repetidas

Con los datos ya en formato largo, el objetivo es contrastar si existen diferencias entre las medias (o las distribuciones) de las cinco pruebas. Según pueda asumirse o no la normalidad de las notas, se dispone de una versión paramétrica (el ANOVA de medidas repetidas) y de una alternativa no paramétrica (el test de Friedman).

15.2.1. ANOVA de medidas repetidas de un factor

Definición 15.1 (ANOVA de medidas repetidas de un factor). El *ANOVA de medidas repetidas de un factor* contrasta si las medias de una variable cuantitativa son iguales en más de dos medidas relacionadas (tomadas sobre los mismos individuos). La hipótesis nula es

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k,$$

donde $\mu_1, \dots, \mu_k$ son las medias poblacionales de las k medidas repetidas, frente a la alternativa de que al menos una de esas medias difiere de las demás.

Requisitos: la variable dependiente debe ser cuantitativa y seguir una distribución normal en cada una de las medidas repetidas (o un tamaño muestral suficientemente grande en cada una). Además debe cumplirse el supuesto de **esfericidad**, que exige que las varianzas de las diferencias entre todos los pares posibles de medidas repetidas sean aproximadamente iguales; cuando no se cumple, el contraste se vuelve demasiado liberal (rechaza H_0 con más facilidad de la debida) y conviene corregirlo o recurrir a la alternativa no paramétrica de la sección siguiente. Su comprobación formal (con el test de esfericidad de Mauchly y correcciones como la de Greenhouse-Geisser) queda fuera del alcance de este capítulo introductorio.

En R, el ANOVA de medidas repetidas se ajusta con la función `aov()` habitual, pero añadiendo un término `Error()` que identifica al alumno como la unidad sobre la que se repiten las medidas: `Error(alumno/prueba)` indica que `prueba` varía dentro de cada `alumno`. Este contraste exige que todos los individuos tengan las cinco medidas completas, así que primero se eliminan de `df_largo` los alumnos con alguna nota perdida.

Ejemplo 15.1.

```
df_largo_completo <- df_largo %>%
  group_by(alumno) %>%
  filter(!any(is.na(nota))) %>%
  ungroup() %>%
  mutate(alumno = factor(alumno))

n_distinct(df_largo_completo$alumno)
```

```
[1] 111
```

```
modelo <- aov(nota ~ prueba + Error(alumno/prueba), data = df_largo_completo)
summary(modelo)
```

```
Error: alumno
      Df Sum Sq Mean Sq F value Pr(>F)
Residuals 110   688.9    6.262

Error: alumno:prueba
      Df Sum Sq Mean Sq F value Pr(>F)
prueba   4 1122.2   280.56   192.5 <2e-16 ***
```

```
Residuals 440 641.4 1.46
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

De los 120 alumnos, 111 tienen las cinco notas completas y son los que entran en el análisis (los 9 restantes se descartan por tener algún valor perdido). El resultado se organiza en dos estratos: el primero (**Error: alumno**) recoge la variabilidad debida a las diferencias globales entre alumnos, y el segundo (**Error: alumno:prueba**) es el que contiene el contraste de interés, sobre **prueba**. El estadístico es $F = 192.5$ con 4 y 440 grados de libertad, y un p-valor inferior a 2×10^{-16} , muy por debajo de 0.05, por lo que se rechaza H_0 : existen diferencias significativas entre las medias de las cinco pruebas. A la vista de las medias descendentes ya observadas (de 6.03 en la prueba A a 2.70 en la prueba E), la conclusión es que el nivel de exigencia (o el rendimiento medio) no se mantiene constante a lo largo del curso.

El ANOVA de medidas repetidas solo informa de que **alguna** de las cinco medias difiere de las demás, pero no de **cuáles**. Para averiguarlo se puede completar el análisis con comparaciones por pares (una versión del test t pareado para cada par de pruebas), corrigiendo el nivel de significación de cada comparación individual con el método de Bonferroni para controlar la probabilidad de cometer al menos un error de tipo I al hacer varias comparaciones a la vez:

```
pairwise.t.test(df_largo_completo$nota, df_largo_completo$prueba,
                paired = TRUE, p.adjust.method = "bonferroni")
```

Pairwise comparisons using paired t tests

data: df_largo_completo\$nota and df_largo_completo\$prueba

	notaA	notaB	notaC	notaD
notaB	< 2e-16	-	-	-
notaC	2.1e-14	< 2e-16	-	-
notaD	< 2e-16	< 2e-16	< 2e-16	-
notaE	< 2e-16	< 2e-16	< 2e-16	7.9e-07

P value adjustment method: bonferroni

Los diez p-valores de la tabla son inferiores a 0.05 (el mayor, entre **notaD** y **notaE**, es 7.9×10^{-7}), por lo que las cinco pruebas difieren significativamente entre sí dos a dos: no se trata de que una única prueba se aparte de las demás, sino de un descenso generalizado y progresivo del rendimiento a lo largo de las cinco pruebas.

15.2.2. Test de Friedman

Definición 15.2 (Test de Friedman). El *test de Friedman* es la alternativa no paramétrica al ANOVA de medidas repetidas: contrasta si existen diferencias entre más de dos medidas relacionadas sin necesidad de asumir que la variable sigue una distribución normal. La hipótesis nula es

$$H_0 : \text{no hay diferencias entre las medidas repetidas.}$$

El contraste se basa en los rangos que ocupa cada medida dentro de cada individuo, en lugar de en los valores originales de la variable.

Requisitos: la variable dependiente debe ser, al menos, cualitativa ordinal (o cuantitativa), y las medidas deben proceder de los mismos individuos. No exige normalidad, por lo que es la opción adecuada cuando no puede garantizarse el requisito de normalidad (o de esfericidad) del ANOVA de medidas repetidas.

En R, `friedman.test()` no trabaja sobre el formato largo, sino que espera una matriz con los individuos en las filas y las medidas repetidas en las columnas (es decir, prácticamente el formato ancho original), y no admite valores perdidos, por lo que hay que eliminarlos antes con `na.omit()`.

Ejemplo 15.2.

```
mat_notas <- df %>%
  select(notaA, notaB, notaC, notaD, notaE) %>%
  as.matrix() %>%
  na.omit()

nrow(mat_notas)
```

```
[1] 111
```

```
friedman.test(mat_notas)
```

```
Friedman rank sum test
```

```
data: mat_notas
```

```
Friedman chi-squared = 316.59, df = 4, p-value < 2.2e-16
```


Tras eliminar los valores perdidos quedan, de nuevo, 111 alumnos con las cinco notas completas (los mismos que en el ANOVA anterior). El estadístico del contraste es $\chi^2 = 316.59$ con 4 grados de libertad y un p-valor inferior a 2.2×10^{-16} , muy inferior a 0.05, por lo que también se rechaza H_0 : hay diferencias significativas entre las cinco pruebas. La conclusión coincide plenamente con la del ANOVA de medidas repetidas, lo cual es tranquilizador dado que, como se vio antes, `notaE` no cumplía estrictamente el requisito de normalidad: al no depender de ese supuesto, el resultado del test de Friedman es, en este caso concreto, la referencia más fiable de las dos, y el hecho de que ambos contrastes coincidan en su conclusión refuerza la confianza en el resultado.

Al igual que con el ANOVA, el test de Friedman solo indica que existen diferencias globales, no entre qué pares de pruebas concretas. La versión no paramétrica de las comparaciones por pares, con la misma corrección de Bonferroni, se obtiene con `pairwise.wilcox.test()`:

```
pairwise.wilcox.test(df_largo_completo$nota, df_largo_completo$prueba,
                    paired = TRUE, p.adjust.method = "bonferroni")
```

Pairwise comparisons using Wilcoxon signed rank test with continuity correction

data: df_largo_completo\$nota and df_largo_completo\$prueba

	notaA	notaB	notaC	notaD
notaB	1.3e-13	-	-	-
notaC	8.8e-12	5.2e-16	-	-
notaD	< 2e-16	< 2e-16	< 2e-16	-
notaE	< 2e-16	< 2e-16	9.1e-13	8.8e-07

P value adjustment method: bonferroni

De nuevo los diez p-valores son inferiores a 0.05 (el mayor, 8.8×10^{-7} , vuelve a corresponder al par `notaD-notaE`), confirmando con un método que no depende de la normalidad la misma conclusión obtenida con las comparaciones paramétricas: cada una de las cinco pruebas difiere significativamente de las demás.

Tip

Ante datos de medidas repetidas conviene aplicar primero el test de Shapiro-Wilk (u otro contraste de normalidad) en cada una de las medidas por separado. Si todas son razonablemente normales, el ANOVA de medidas repetidas es la opción más potente; si alguna se aparta claramente de la normalidad, como ocurre aquí con `notaE`, el test de Friedman es la alternativa más segura. Cuando, como en este

ejemplo, ambos contrastes coinciden en su conclusión, puede reportarse cualquiera de los dos con tranquilidad. La comprobación formal del supuesto adicional de esfericidad que exige el ANOVA de medidas repetidas (con el test de Mauchly y las correcciones de Greenhouse-Geisser o Huynh-Feldt) se desarrolla con detalle en el [Manual de Estadística](#).

15.3. Resumen

Los dos contrastes de este capítulo llegan a la misma conclusión: el rendimiento de los alumnos no es constante a lo largo de las cinco pruebas del curso, sino que desciende de forma significativa y, según muestran las comparaciones por pares, de forma generalizada entre todas ellas. Un resultado así, obtenido sobre datos de medidas repetidas, sugiere una pregunta que el contraste estadístico por sí solo no puede responder: si el descenso se debe a que las pruebas son cada vez más difíciles, a que la materia se acumula y exige más al alumno conforme avanza el curso, o a otra causa distinta (por ejemplo, cansancio o pérdida de motivación); dar respuesta a esa pregunta exigiría un diseño adicional, no solo un contraste de hipótesis.

Ambos contrastes son, además, la generalización, a más de dos medidas repetidas, del contraste paramétrico visto en [Contrastes para dos poblaciones pareadas](#) para el caso particular de solo dos medidas: de hecho, cuando solo hay dos medidas repetidas, el estadístico F del ANOVA de medidas repetidas coincide con el cuadrado del estadístico t del test t pareado, y ambos contrastes dan exactamente el mismo p-valor. El test de Friedman, en cambio, no se reduce al test de Wilcoxon para datos pareados cuando solo hay dos medidas, porque Friedman se basa únicamente en el orden (el rango) que ocupa cada medida dentro de cada individuo, mientras que Wilcoxon tiene en cuenta también la magnitud de las diferencias; con dos medidas, la generalización natural del test de Friedman es más bien el test de los signos.

Con esto se cierra la parte de la tabla de decisión dedicada a comparar medias o distribuciones entre dos o más poblaciones, ya sean independientes o relacionadas; el [último capítulo de esta parte](#) aborda una cuestión distinta: la relación y la predicción entre dos variables cuantitativas.

16. Relación y predicción entre dos variables

Este último capítulo cierra la tabla de decisión presentada en [Selección del contraste estadístico](#) con las filas que faltaban: aquellas en las que se quiere estudiar la **relación** entre dos variables cuantitativas, o **predecir** una variable cuantitativa (o cualitativa binaria) a partir de otra cuantitativa. La correlación y la regresión son temas amplios, con mucha teoría, propiedades y variantes detrás. Como ese desarrollo ya está hecho, y con detalle, en el [Manual de Estadística](#) del mismo autor, aquí no se repite: este capítulo se limita a situar cada contraste en la tabla de decisión y a mostrar el ejemplo mínimo de código en R necesario para aplicarlo sobre el conjunto de datos del curso. Para las definiciones formales, las fórmulas y las propiedades de estos contrastes, así como para el coeficiente chi-cuadrado y el coeficiente de contingencia entre dos variables cualitativas (mencionados pero no desarrollados en el capítulo introductorio de esta parte), acúdase al Manual.

16.1. Relación entre dos variables cuantitativas

Cuando ambas variables son cuantitativas y (aproximadamente) normales, la pregunta habitual es si existe una **relación lineal** entre ellas. El coeficiente de correlación de Pearson mide la fuerza y el sentido de esa relación lineal, y toma valores en el intervalo $[-1, 1]$: cerca de 1 indica relación lineal positiva fuerte, cerca de -1 relación lineal negativa fuerte, y cerca de 0 ausencia de relación lineal.

Cuando alguna de las variables es cualitativa ordinal, o cuando las variables son cuantitativas pero no puede asumirse normalidad, se utiliza en su lugar el coeficiente de correlación de Spearman, que mide la relación de orden (monótona) entre las dos variables en lugar de la relación estrictamente lineal. También toma valores en $[-1, 1]$ y se interpreta igual.

```
cor.test(df$notaA, df$notaB, method = "pearson")
```

Pearson's product-moment correlation

data: df\$notaA and df\$notaB

t = 14.709, df = 113, p-value < 2.2e-16

alternative hypothesis: true correlation is not equal to 0

```
95 percent confidence interval:
 0.7367182 0.8651991
sample estimates:
      cor
0.8104926
```

El coeficiente de correlación de Pearson entre `notaA` y `notaB` es $r = 0.81$, y el contraste de hipótesis nula $H_0 : \rho = 0$ da un p-valor prácticamente nulo ($p < 2.2 \times 10^{-16}$), por lo que se rechaza la hipótesis nula: existe una relación lineal positiva fuerte y significativa entre las dos calificaciones.

```
ggplot(df, aes(x = notaB, y = notaA)) +
  geom_point() +
  geom_smooth(method = "lm")
```




Figura 16.1.: Diagrama de dispersión entre `notaA` y `notaB`, con la recta de regresión ajustada.

16.2. Regresión simple

Cuando el objetivo no es solo contrastar si existe relación, sino construir un **modelo predictivo** que permita estimar el valor de una variable cuantitativa a partir de otra, se recurre a la regresión lineal simple. El modelo ajusta la recta que mejor explica la

variable dependiente en función de la independiente, y el contraste de hipótesis asociado a la pendiente indica si esa relación es estadísticamente significativa.

```
modelo <- lm(notaA ~ notaB, data = df)
summary(modelo)
```

Call:

```
lm(formula = notaA ~ notaB, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.02596	-0.46667	0.03761	0.46790	1.43947

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1.34679	0.31938	4.217	5.02e-05	***
notaB	0.67286	0.04575	14.709	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7501 on 113 degrees of freedom

(5 observations deleted due to missingness)

Multiple R-squared: 0.6569, Adjusted R-squared: 0.6539

F-statistic: 216.3 on 1 and 113 DF, p-value: < 2.2e-16

Por cada punto que sube `notaB`, `notaA` sube en promedio 0.673 puntos ($\hat{\beta}_1 = 0.673$), y esa pendiente es significativamente distinta de cero ($p < 2 \times 10^{-16}$), lo que confirma la relación lineal ya detectada con la correlación. El coeficiente de determinación, $R^2 = 0.657$, indica que el modelo explica un 65.7% de la variabilidad de `notaA`.

16.3. Regresión logística simple

Cuando la variable que se quiere predecir es cualitativa binaria (por ejemplo, aprobar o suspender una prueba) y la variable predictora es cuantitativa, el modelo lineal deja de ser adecuado y se sustituye por la regresión logística simple, que modela la probabilidad de la categoría de interés en función de la variable independiente.

```
df <- df %>%
  mutate(aprobado = as.numeric(calificacionA == "Aprobado"))
```

```
modelo_log <- glm(aprobado ~ notaE, data = df, family = "binomial")
summary(modelo_log)
```

Call:

```
glm(formula = aprobado ~ notaE, family = "binomial", data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.18250	0.40104	2.949	0.00319 **
notaE	0.03036	0.12613	0.241	0.80978

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 124.45 on 117 degrees of freedom
Residual deviance: 124.39 on 116 degrees of freedom
(2 observations deleted due to missingness)
AIC: 128.39

Number of Fisher Scoring iterations: 4

El coeficiente de `notaE` es positivo ($\hat{\beta}_1 = 0.030$), lo que indicaría que una nota más alta en la prueba E se asocia a una mayor probabilidad de aprobar la prueba A, pero el p-valor asociado ($p = 0.81$) está muy lejos de ser significativo: con estos datos no hay evidencia de que la calificación obtenida en la prueba E prediga el resultado (aprobado/suspenso) de la prueba A.

16.4. Cierre de esta parte del libro

Este libro ha recorrido dos preguntas distintas pero complementarias sobre un mismo estudio estadístico. La primera parte trató sobre el **diseño**: cómo se recogen los datos, según los distintos tipos de estudios descriptivos, transversales, de cohortes, de casos y controles, ecológicos, experimentales, cuasiexperimentales o basados en encuestas, y qué conclusiones de causalidad permite extraer cada uno. La segunda parte, cerrada con este capítulo, trató sobre el **análisis**: una vez recogidos los datos, cómo elegir el contraste de hipótesis adecuado según el número y el tipo de variables involucradas y la relación entre las poblaciones comparadas. Conviene no perder de vista que ambas preguntas son necesarias pero ninguna es suficiente por sí sola: un contraste estadístico perfectamente elegido y ejecutado sobre datos mal recogidos —con sesgos de selección, factores de

confusión no controlados u otras amenazas a la validez discutidas en la primera parte—no produce conclusiones válidas, por muy pequeño que sea el p-valor obtenido. El buen análisis estadístico empieza en el buen diseño. Quien llegue a este capítulo sin haber pasado antes por el principio del libro puede retomarlo en [Introducción a los tipos de estudios estadísticos](#), y quien busque de nuevo el mapa completo de contrastes puede volver a [Selección del contraste estadístico](#).